




Разведочный анализ данных

Занятие №2



Что такое разведочный анализ данных

EDA

Exploratory
Data Analysis

Изучаем структуру, качество и закономерности в данных с помощью статистик и графиков.

Результат: обоснованные наблюдения и гипотезы для дальнейшей проверки.

Зачем исследовать данные



01

Качество

Ошибки сбора
искажают расчёты
и выводы.

02

Структура

Группы и зависимости
не видны в одном
среднем значении.

03

Решения

Подготовка данных
и проверка модели
должны это учитывать.

Основные вопросы EDA



Что наблюдаем?

Какие объекты представлены и как получены их измерения?


Как устроены данные?

Каковы распределения, разброс, пропуски, выбросы и связи между признаками?

Что можно заключить?

Какие объяснения правдоподобны и каких данных не хватает для проверки?

Как строится исследование данных



↪ Уточняем вопрос и выбираем следующий способ проверки

Смысл и происхождение данных



Что является наблюдением?

Человек, событие или повторное измерение?

Кого охватывает выборка?

Кто включён и кто не мог в неё попасть?

Что означает признак?

Единицы, допустимые значения, числовые коды.

Когда собраны данные?

Период, порядок и изменения способа сбора.

Центр и разброс распределения



Центр

Среднее

Сумма значений, делённая на число наблюдений.

Медиана

Центральное значение в упорядоченной выборке.*

Разброс

Стандартное отклонение

Корень из дисперсии.
Чувствительно к крайним значениям.

Межквартильный размах

$IQR = Q_3 - Q_1$: ширина интервала между 25-м и 75-м процентилями.

* При чётном числе наблюдений — среднее двух центральных значений.

Тип данных определяет график

Один числовой признак

Гистограмма, ECDF, boxplot

Один категориальный

Частоты и доли категорий

Два числовых

Диаграмма рассеяния

Числовой + категория


Распределения по группам

Две категории

Таблица сопряжённости, доли

Влияние выброса на среднее и медиану

Пример: в выборке из 101 значения заменяем одно наблюдение x_j на M .



$$\Delta \bar{x} = (M - x_j) / n$$


Среднее меняется вместе с M .

Медиана зависит от положения значений в упорядоченном ряду.


Как читать распределение

На трёх графиках — одна выборка. У гистограмм разное число интервалов.


7 интервалов



35 интервалов



ECDF




Гистограмма: форма, асимметрия, несколько пиков

ECDF: доля значений $\leq x$

Настройка графика может менять впечатление о данных

Что показывает boxplot

Медиана, центральные 50% значений и наблюдения за пределами «усов».




«Усы» доходят до крайних наблюдений в пределах $1,5 \cdot IQR$ от квартилей.

Точки за «усами» требуют проверки.

Линейная и логарифмическая шкалы


Линейная шкала

Равные расстояния =
равные разности значений.




Логарифмическая шкала

Равные расстояния =
равные отношения значений.



Q-Q plot: сравнение квантилей

Сопоставляем квантили выборки с квантилями выбранного распределения.



**Сравниваем
форму
распределений**

На графике крайние значения отклоняются от прямой сильнее: хвосты тяжелее, чем у нормального распределения.

Не каждый метод требует нормального распределения

Выброс — ещё не ошибка

Выброс — наблюдение, заметно отличающееся от остальных по одному или нескольким признакам.

Возможные причины Ошибка измерения, редкое событие или объект из другой группы.

IQR-правило Границы: $Q_1 - 1,5 \cdot IQR$ и $Q_3 + 1,5 \cdot IQR$.
Выход за границу — повод для проверки.

Выбросы по нескольким признакам

Каждая точка — объект. Два признака меняются согласованно у большинства объектов.



**По отдельности
значения не
выделяются**

Но их сочетание
не соответствует
основной зависимости.

Поколочная проверка
этого не замечает.

Розовая точка выделяется сочетанием двух значений

Расстояние Махаланобиса

Учитываем масштаб признаков и направление основного разброса.

$$D^2(x) = (x - \mu)^T \Sigma^{-1} (x - \mu)$$

μ — центр облака

Σ — ковариационная матрица

Выбросы искажают оценки μ и Σ .
Разные группы могут требовать
отдельного описания.

Пропуски: важна причина

01

MCAR

Вероятность пропуска не зависит от значений.

Пример: случайная потеря измерения.

02

MAR

После учёта известных признаков вероятность пропуска не зависит от скрытого значения.


03

MNAR

Даже после учёта известных признаков вероятность пропуска зависит от скрытого значения.

Как пропуски искажают распределение

Сравним полные данные со случайным удалением и удалением верхней четверти.



**Отсутствие значений
может смещать
оценку**

Если большие значения
не записываются,
наблюдаемое среднее
снижается без изменения
самого процесса.

Как изучать зависимости



Диаграмма рассеяния

Показывает форму связи числовых признаков: линейность, кривизну, группы и выбросы.

Корреляция


Пирсон характеризует линейную связь, Спирмен — монотонную связь через ранги.

Сравнение групп

Для категорий сравниваем частоты и распределения числовых признаков.

Нулевая корреляция не исключает связь

Для симметричной выборки X построим $Y = X^2$. Значение Y однозначно задаётся X .



Зависимость есть

Она нелинейная
и немонотонная.

Пирсон и Спирмен
могут давать ноль
при такой связи.

Коэффициент корреляции нужно интерпретировать вместе с графиком

Откуда берется высокая корреляция

01

Свойства объекта

Признаки могут отражать реально связанные свойства.

02

Способ расчёта

Один признак вычислен из другого: площадь и её логарифм.


03

Общая причина

Третий фактор может изменять сразу оба признака.

Общая связь и связь внутри групп

Цвет обозначает группу. Внутри каждой группы X и Y связаны отрицательно.



**В общей выборке
знак другой**

Различия между
средними групп
могут перевесить
связь внутри групп.

Из чего складывается общая ковариация

G — группа объекта. Общая ковариация складывается из двух эффектов.

Внутри групп

$\text{Cov}(X, Y) =$

$$E[\text{Cov}(X, Y | G)]$$


+

Между средними групп

$$\text{Cov}(E[X | G], E[Y | G])$$

Порядок наблюдений тоже важен

После середины последовательности меняется уровень показателя.



**Гистограмма
скрывает порядок**

Два пика могут быть
следствием смены
режима во времени.

Сравниваем периоды.

При нерегулярном сборе используйте время, а не порядковый номер измерения

Поиск среди множества вариантов

Ищем связь независимых признаков со случайной целевой переменной

200

наблюдений

10 → 1000


независимых признаков

max |r|

результат поиска

Найденная связь требует проверки

На новых данных проверяем именно тот признак, который выбрали при поиске.



**Больше вариантов —
выше максимум**

На новых данных
выбранный признак
теряет преимущество.

Широкий поиск повышает
риск случайной находки.

Наблюдение, гипотеза, проверка

01

Наблюдение

Что именно видно
на графике или
в расчётах?

02

Гипотеза

Какое объяснение
согласуется
с наблюдением?

03

Проверка

Какие новые данные
помогут отличить
это объяснение
от альтернатив?

Корреляция и причинность

Одна и та же наблюдаемая связь допускает разные причинные объяснения.

$$X \rightarrow Y$$


$$X \leftarrow Y$$

$$X \leftarrow Z \rightarrow Y$$

Причинный вопрос: что изменится в Y , если вмешаться в X ?

Для ответа нужны исследовательский дизайн и обоснованные предположения

После курса статистики



Главные выводы из примеров

Числовой сводки недостаточно

Среднее и корреляция могут скрывать форму распределения и нелинейную связь.

Контекст меняет интерпретацию

Общая зависимость может отличаться от зависимостей внутри групп.

Найденная связь требует проверки

При переборе множества признаков можно выбрать случайную корреляцию.

Переходим к практике



Открываем Jupyter Notebook

Исследуем реальные данные
и проверим свои предположения.