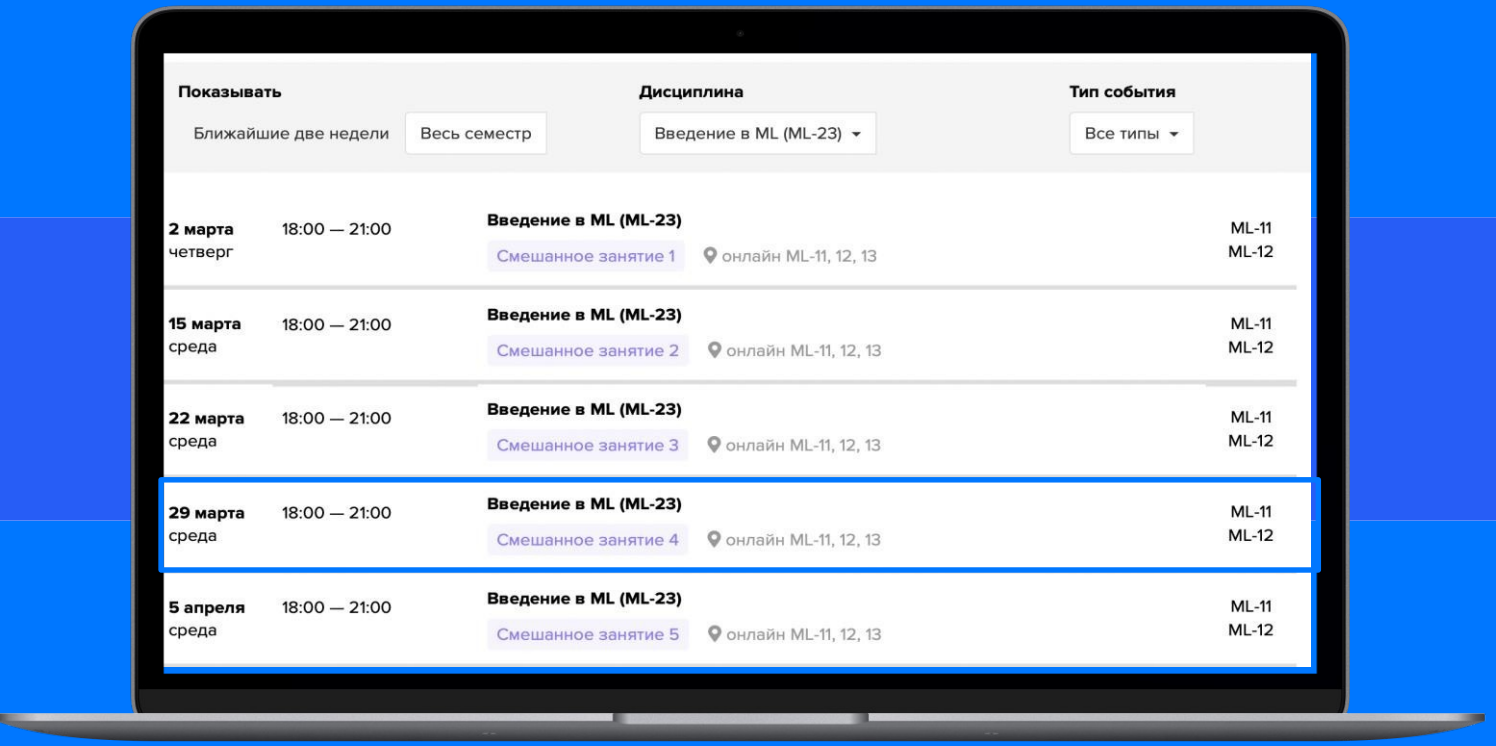
education

Признаки и предобработка данных

Занятие №3

To Do



education



План лекции

1. **Метрики качества**
    - 1.1 Метрики качества
    - 1.2 Оценка качества моделей

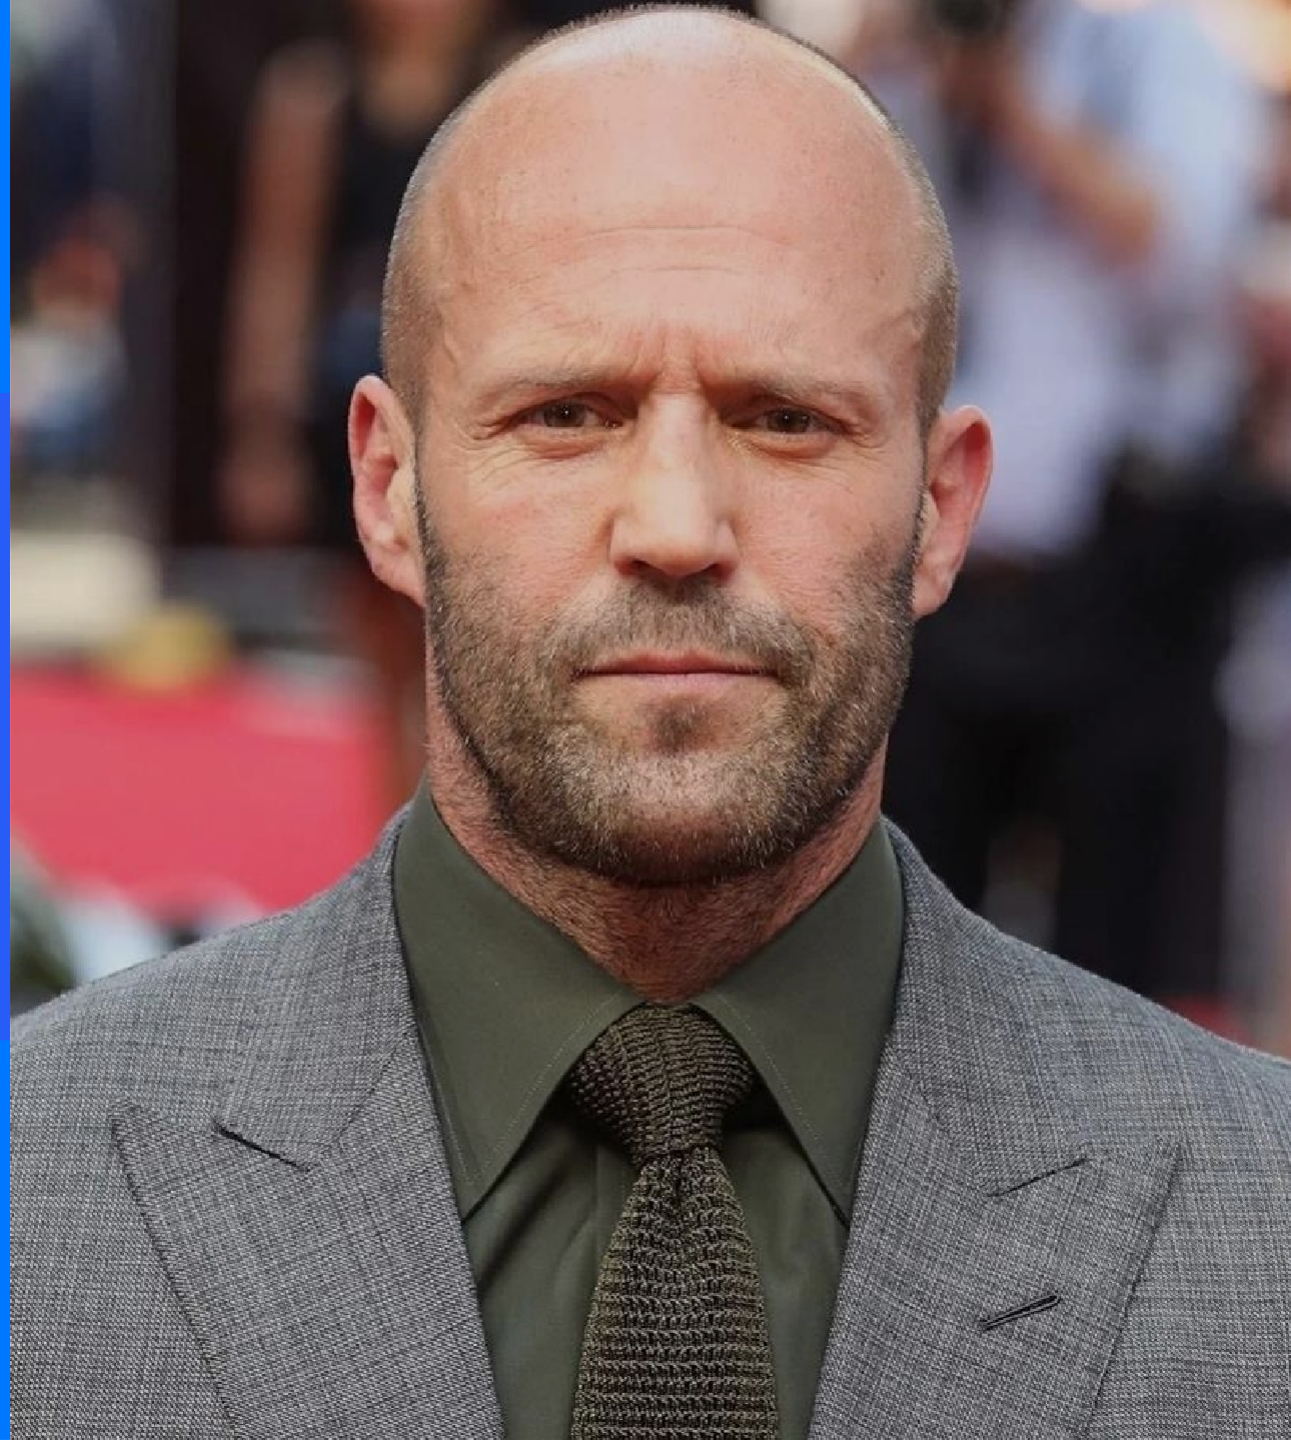
2. **Работа с признаками**
    - 2.1 Извлечение признаков
    - 2.2 Преобразование признаков
    - 2.3 Работа с пропущенными данными
    - 2.4 Отбор признаков

Метрики

«If you can not measure it, you can not improve it.»

- Lord Kelvin

education



Зачем нужны метрики?

- **Для оценки качества** работы моделей
- **Для сравнения** моделей
- **Для интерпретации** результатов

Постановка задачи

X – множество объектов

$Y \in \mathbb{R}$ – множество ответов

$\{x_1, \ldots, x_l\} \subset X$ – обучающая выборка

$y_i = y(x_i), i = 1, \ldots, l$ – известное множество ответов

$a : X \longrightarrow Y$ – алгоритм, ставящий в соответствие объекту x некоторый ответ y

$a_i = a(x_i), i = 1, \ldots, l$ – ответы (предсказания) нашего алгоритма на выборке X

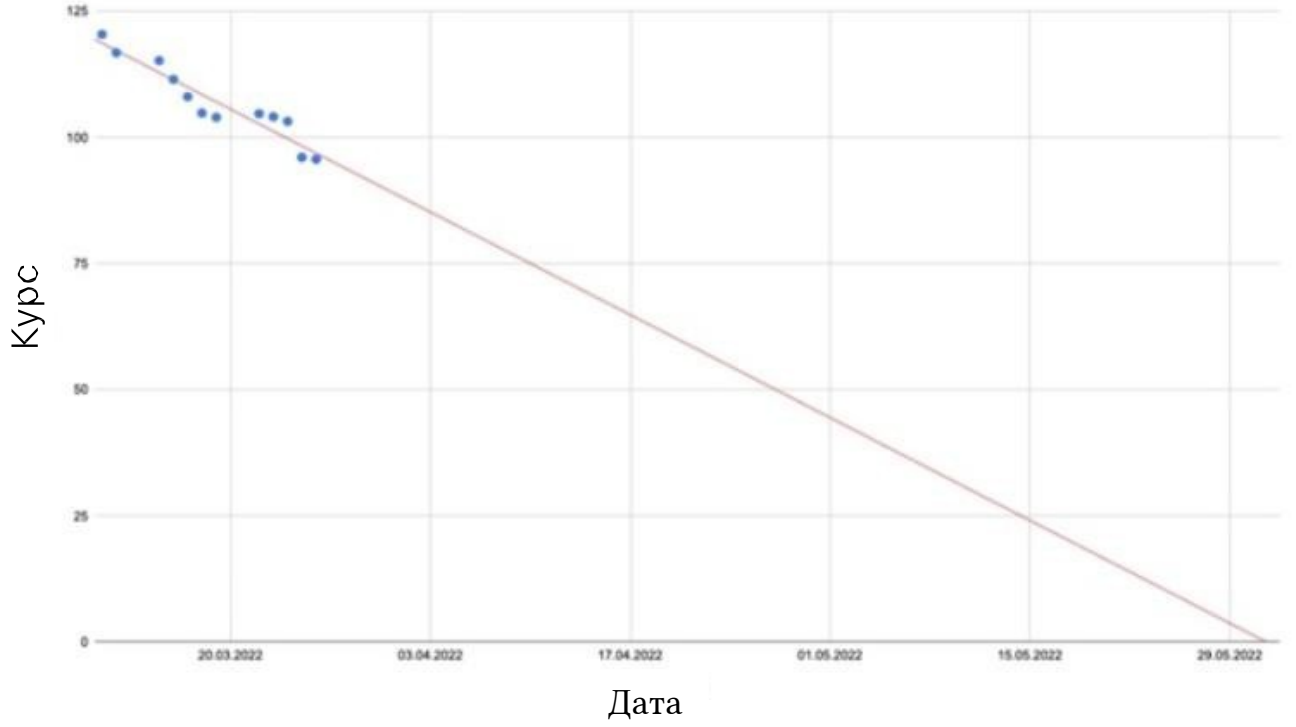
Задача регрессии

Физкек запись закреплена
26 мар 2022 в 18:53

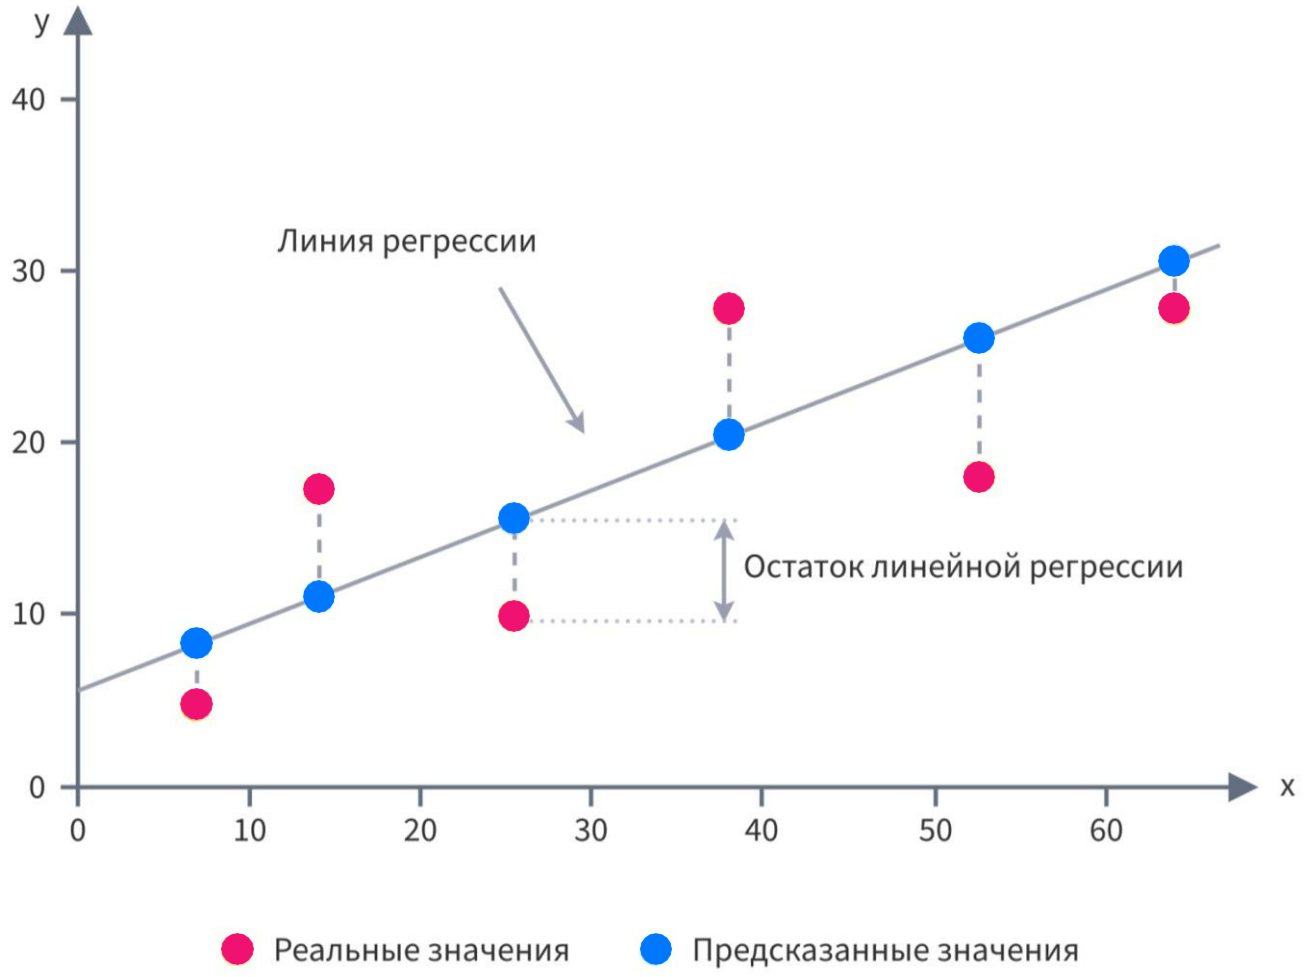
+ Подписаться

примерно к началу лета наши аналитики ожидают бесплатного доллара

Курс доллара США к рублю. Экстраполяция



Остатки (residuals)

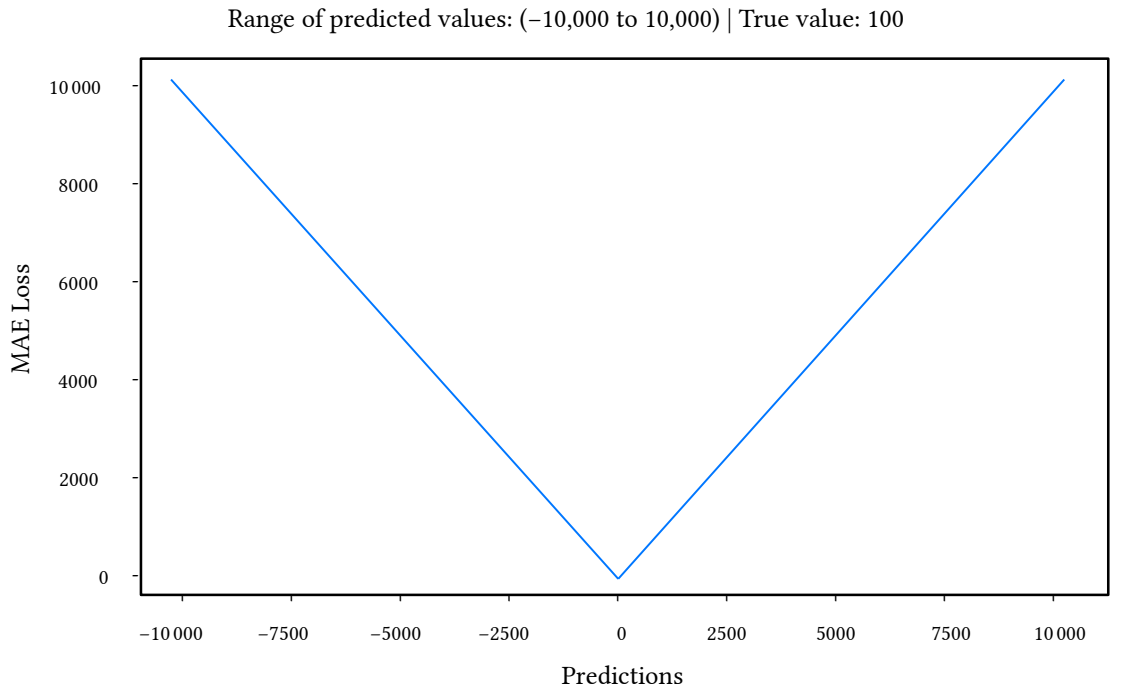


MAE

$$\mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

Оптимальное статичное решение – медиана ответов Y.

- Единицы измерения как у таргета
- Сложно интерпретировать
- Нечувствителен к выбросам
- Не дифференцируемая

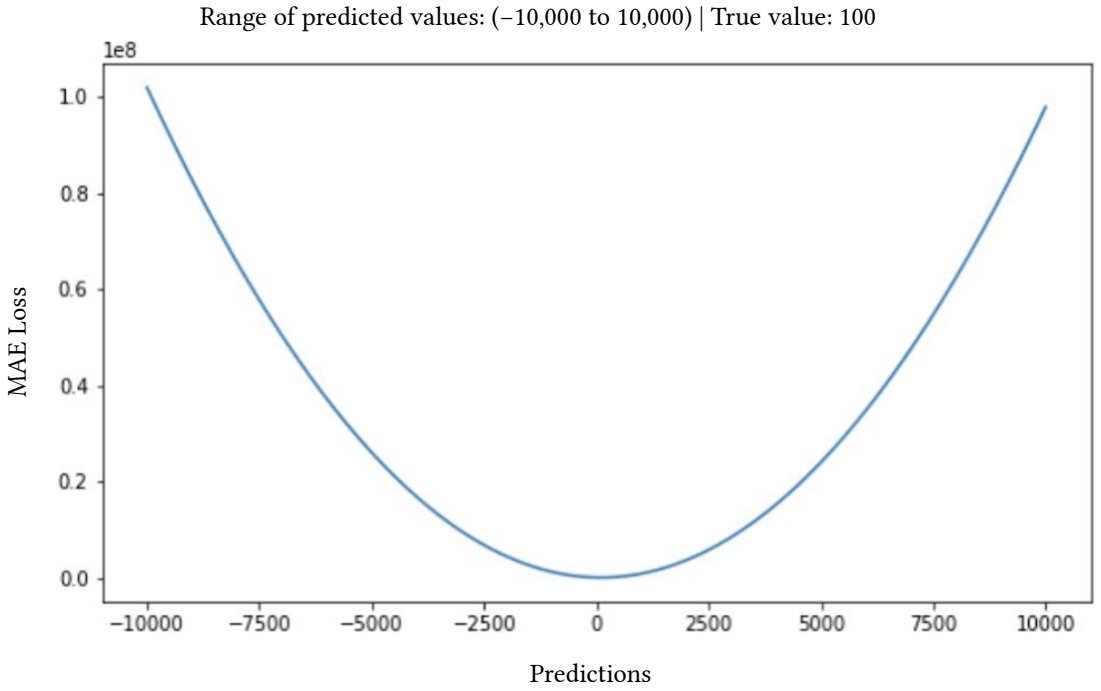


MSE

$$\mathrm{MSE} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

Оптимальное статичное решение – среднее ответов Y.

- Дифференцируемая
- Чувствительна к выбросам
- Сложно интерпретировать



RMSE

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2} = \sqrt{\mathrm{MSE}}$$

Оптимальное статичное решение – среднее ответов Y.

- Дифференцируемая
- Чувствительна к выбросам
- Интерпретация: стандартное отклонение ответа

R-квадрат

$$R^2 = 1 - \frac{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\frac{1}{N}\sum_{i=1}^{N}(y_i - \bar{y})^2} = 1 - \frac{MSE}{\frac{1}{N}\sum_{i=1}^{N}(y_i - \bar{y})^2}$$

$$\bar{y} = \frac{1}{N}\sum_{i=1}^{N} y_i$$

- Дифференцируемая
- Чувствительна к выбросам
- Хорошо интерпретируется: насколько наша модель лучше, чем константное решение

MSPE и MAPE

$$\text{MSPE} = \frac{100\%}{N}\sum_{i=1}^{N}\left(\frac{y_i - \hat{y}_i}{y_i}\right)^2$$

$$\text{MAPE} = \frac{100\%}{N}\sum_{i=1}^{N}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

Оптимальное константное решение:

взвешенное среднее таргета

взвешенная медиана таргета

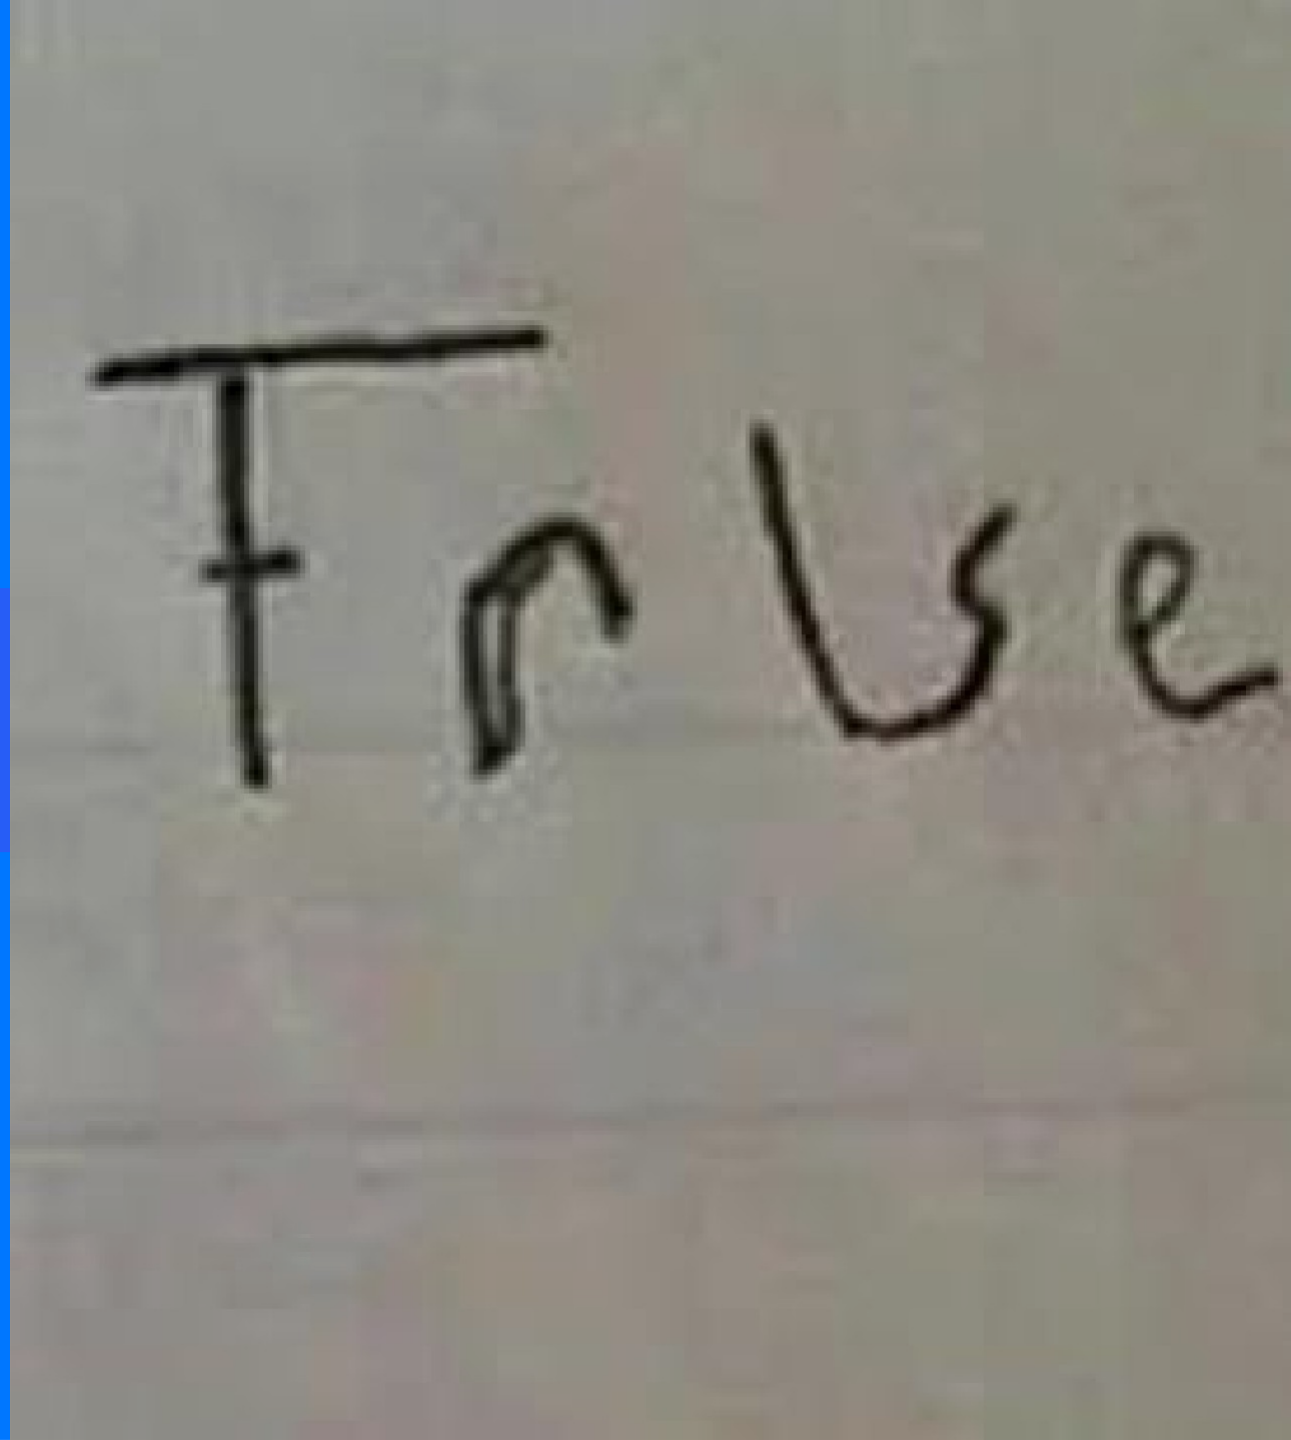
- Присваивают большой вес абсолютно более маленьким объектам => смещены
- Нечувствительны к выбросам
- Хорошо интерпретируются: относительный прирост

Выводы

		Аномальные значения	
		Учитываем	Не учитываем (выбросы)
Интерпретируемость	Важна	RMSE, R-квадрат	MSPE, MAPE
	Не важна	MSE	MAE

Задача классификации

When your binary classification model outputs 0.5



education

Accuracy

$$\text{Accuracy} = \frac{1}{N}\sum_{i=1}^{N}[\hat{y}_i = y_i]$$ - доля правильных предсказаний

target = np.array([1, 1, 1, 2, 1, 1, 1, 2]) – какое лучшее константное предсказание?

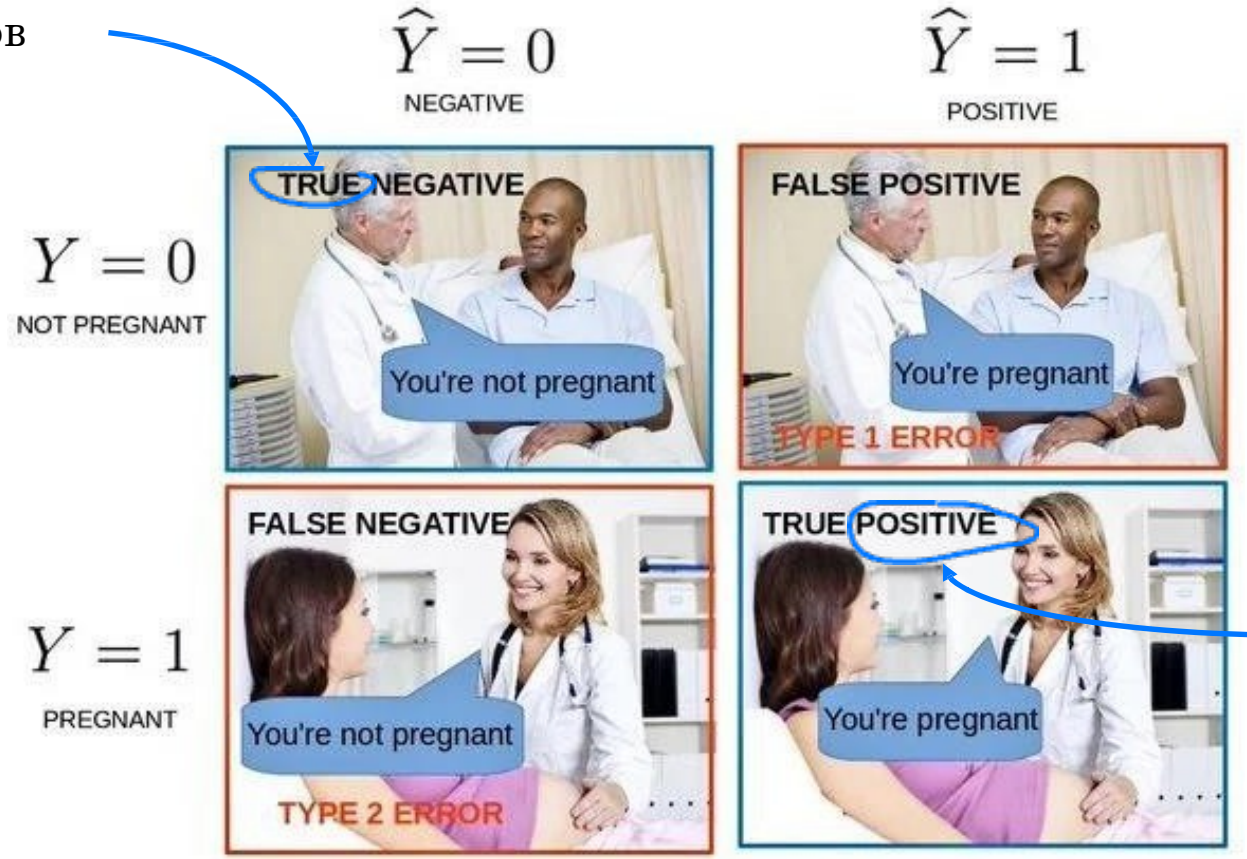
Accuracy

$$\text{Accuracy} = \frac{1}{N}\sum_{i=1}^{N}[\hat{y}_i = y_i]$$ - ОЧЕНЬ большая чувствительность к дисбалансу классов

Оптимальное статичное решение – самый популярный класс.

Confusion matrix

True – совпадение ответов



Positive – значение предсказания

Confusion matrix

		Predicted: Positive	Predicted: Negative	
Actual	Positive	True Positive (TP)	False Negative (FN)	Sensitivity or Recall or True Positive Rate = TP/(TP+FN)
	Negative	False Positive (FP)	True Negative (TN)	Specificity or True Negative Rate = TN/(TN+FP)
		Precision or Positive Predictive Value = TP/(TP+FP)	Negative Predictive Value = FN/(FN+TN)	Accuracy = TP+TN/TP+TN+FP+FN

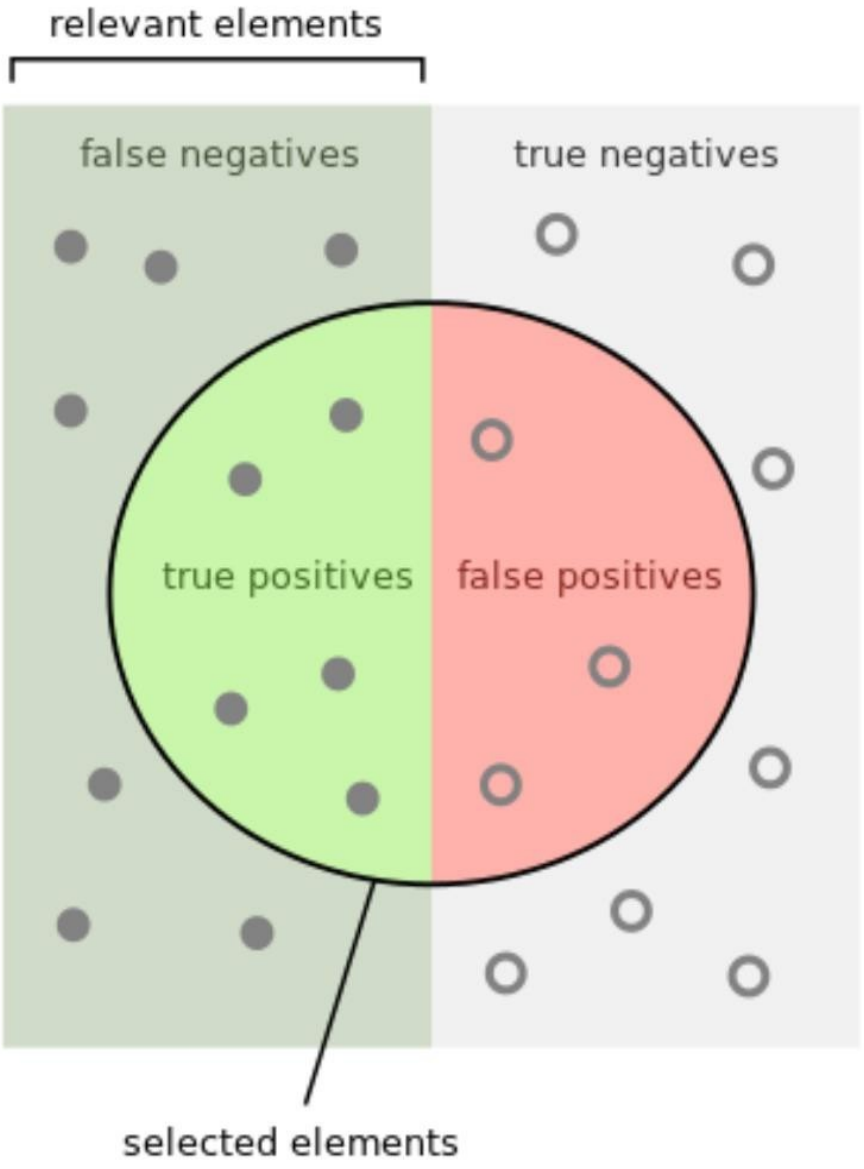
Confusion matrix

How many selected items are relevant?

Precision = 

How many relevant items are selected?

Recall = 

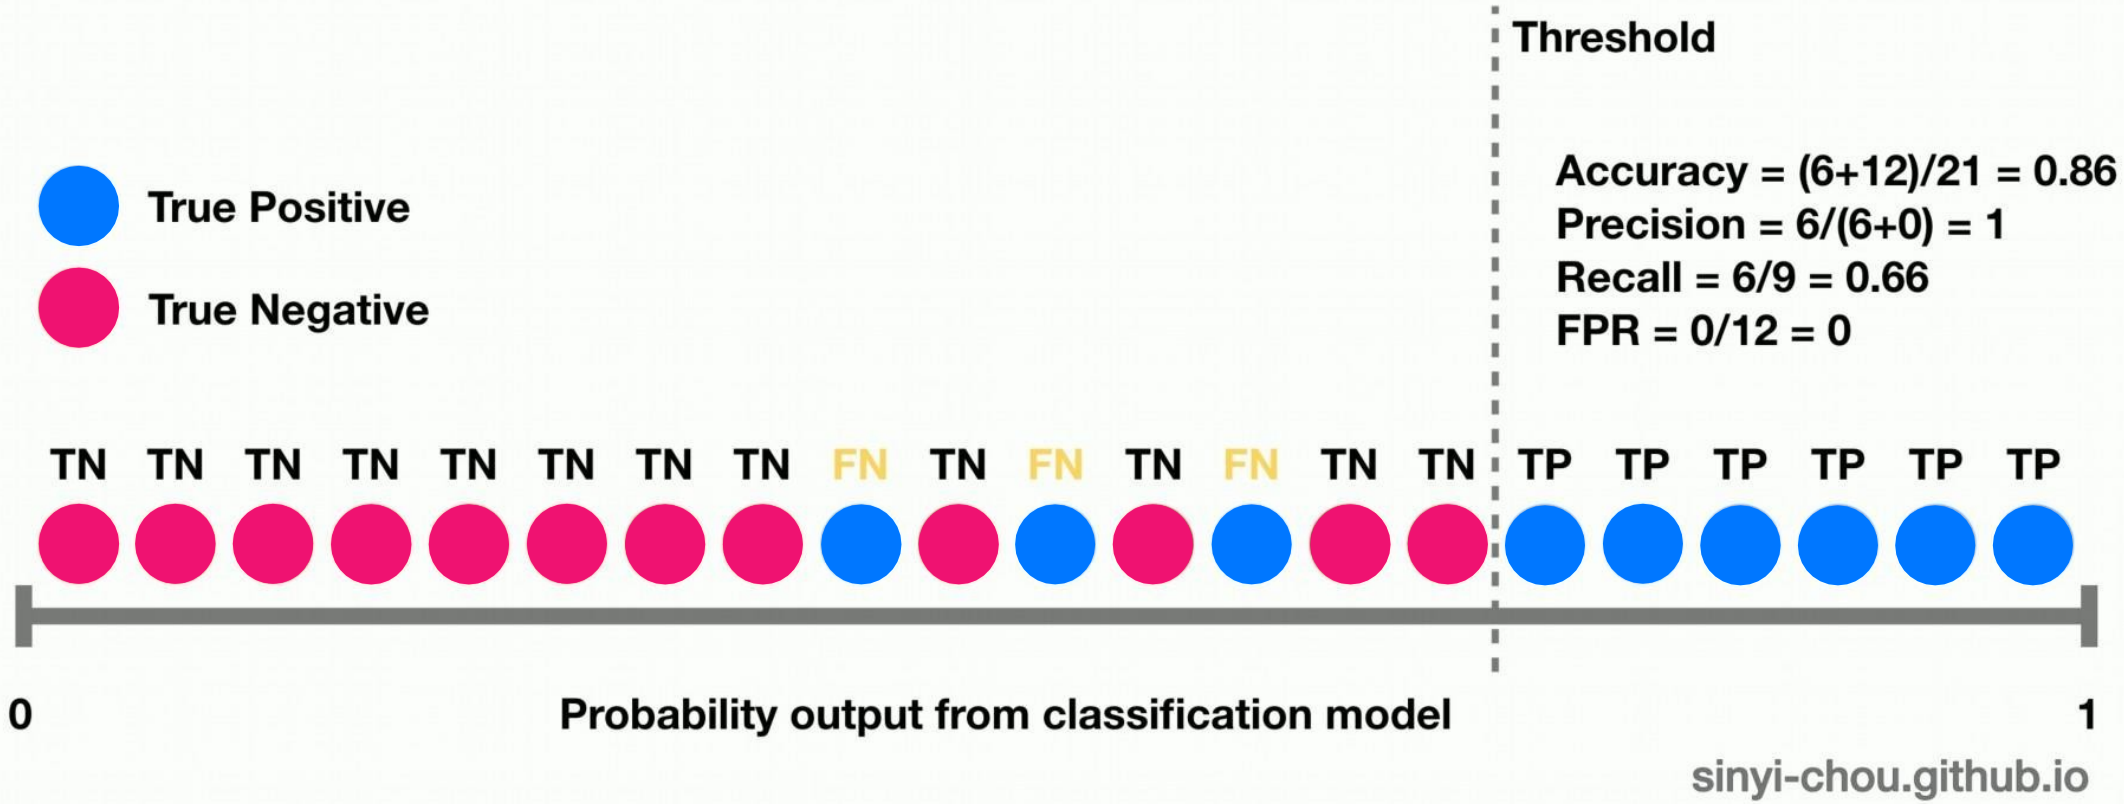


Soft target

a : X ⟶ Y',Y' ∈ (0,1) – алгоритм предсказывает значение от 0 до 1 (например, вероятность принадлежности к положительному классу



Confusion matrix




Precision
1
Recall
2

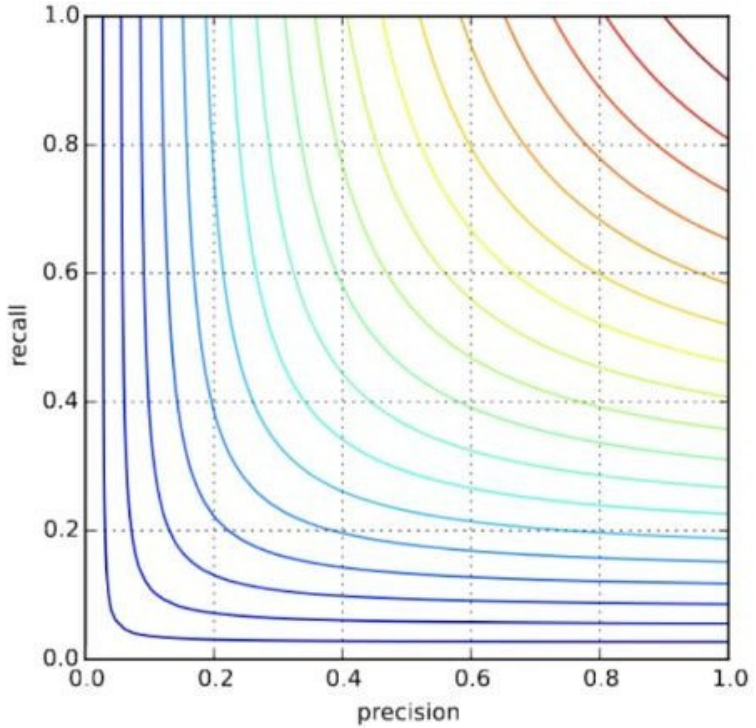


F-measure

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{\beta^2 \cdot \text{precision} + \text{recall}}$$

$$F_\beta = \frac{(1 + \beta^2) \cdot \text{true positive}}{(1 + \beta^2) \cdot \text{true positive} + \beta^2 \cdot \text{false negative} + \text{false positive}}$$

$$F_1 = \left(\frac{2}{\text{recall}^{-1} + \text{precision}^{-1}} \right) = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

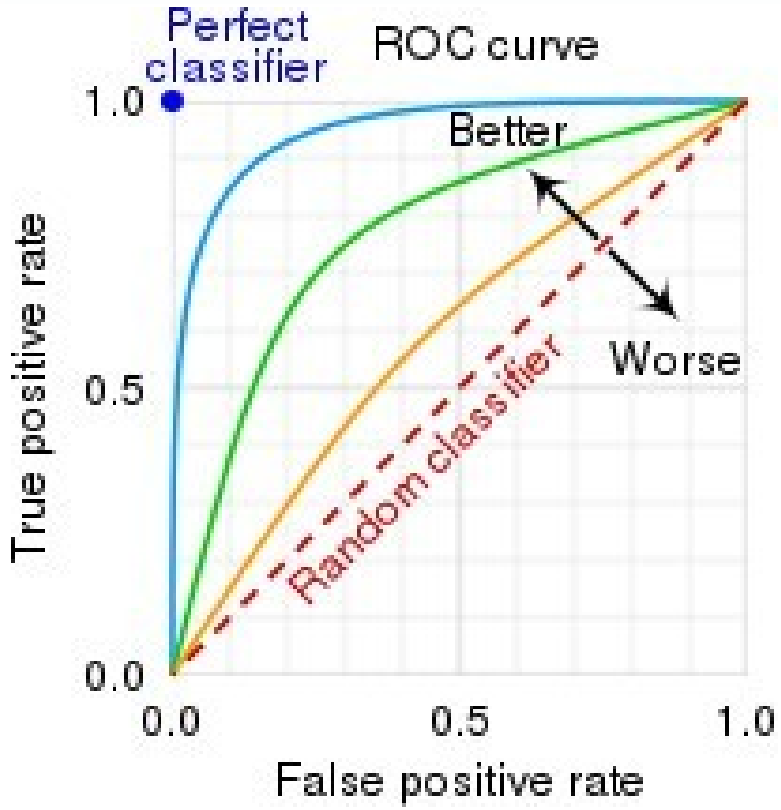


Стремится к нулю, если precision или recall близки к нулю.

Коэффициент β отвечает за пропорцию между метриками.

AUC-ROC

Area Under the ROC curve определяет долю правильно отранжированных пар



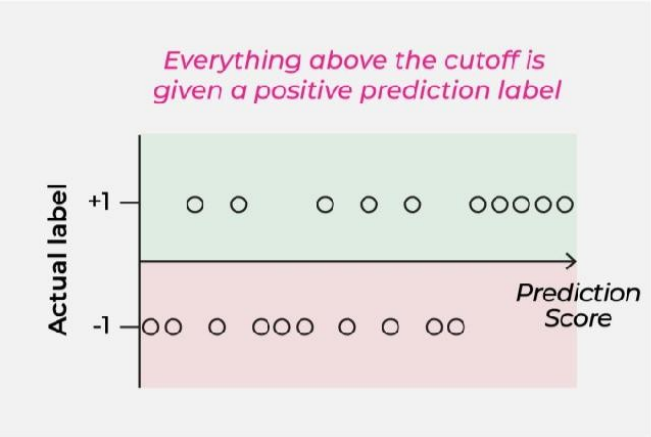
$$\text{TPR (sensitivity)} = \frac{TP}{TP + FN}$$

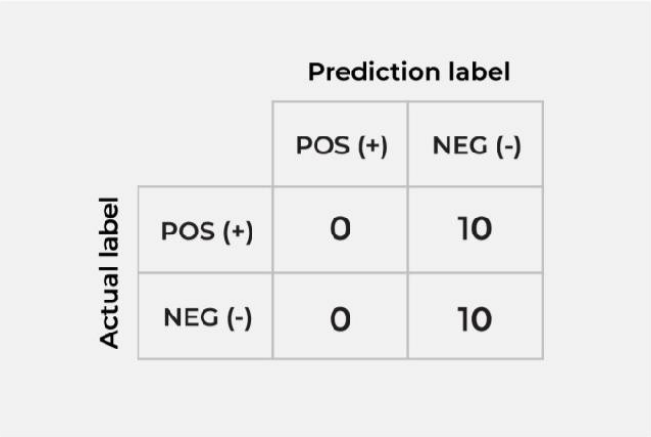
$$\text{FPR (1-specificity)} = \frac{FP}{TN + FP}$$

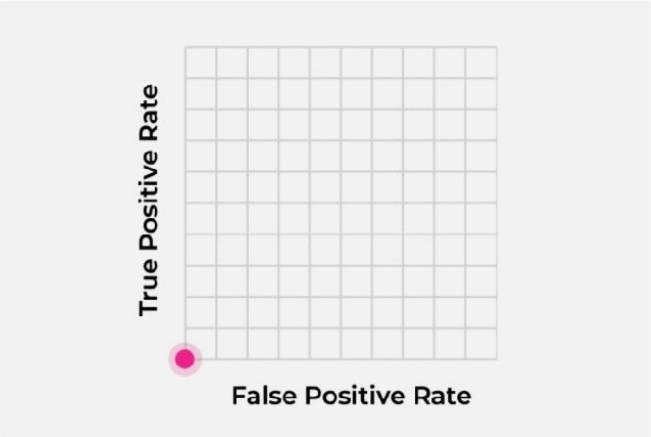
AUC-ROC

True Positive Rate: 0/10

False Positive Rate: 0/10





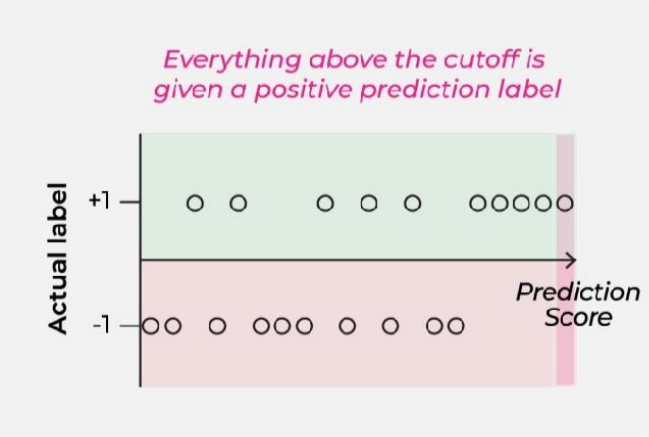


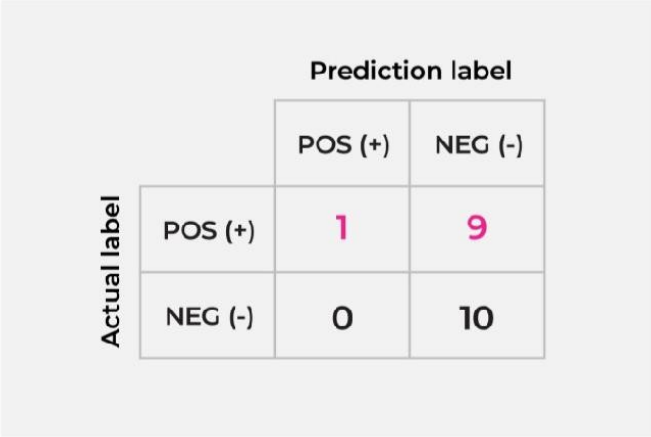
https://arize.com/blog/what-is-auc/

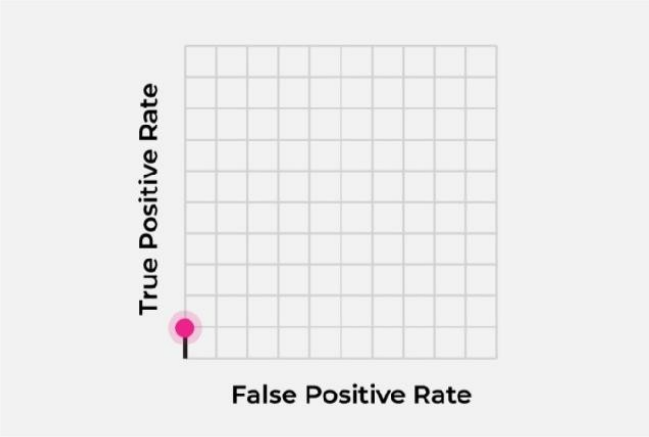
AUC-ROC

True Positive Rate: 1/10

False Positive Rate: 0/10







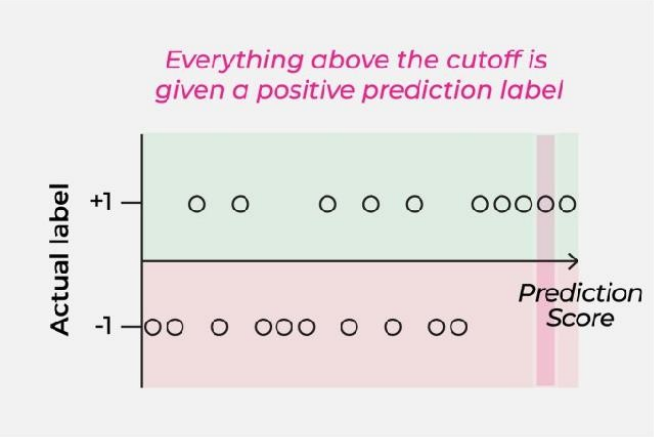
---

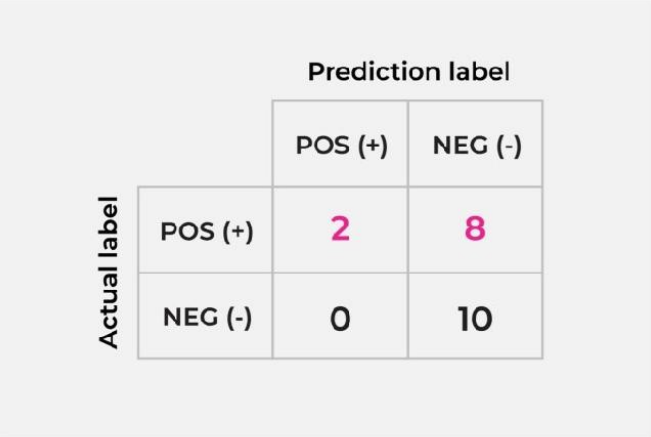
https://arize.com/blog/what-is-auc/

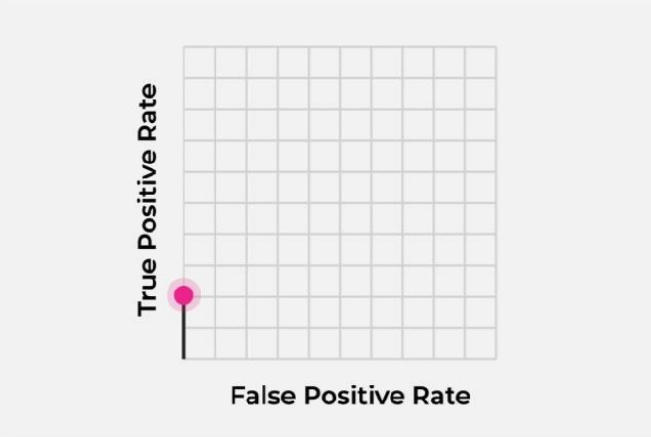
AUC-ROC

True Positive Rate: 2/10

False Positive Rate: 0/10





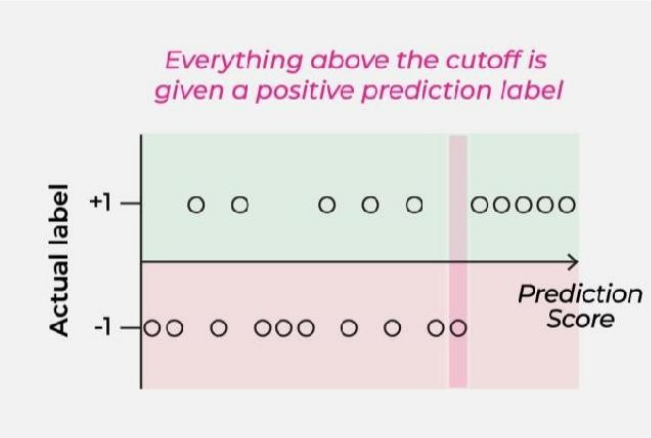


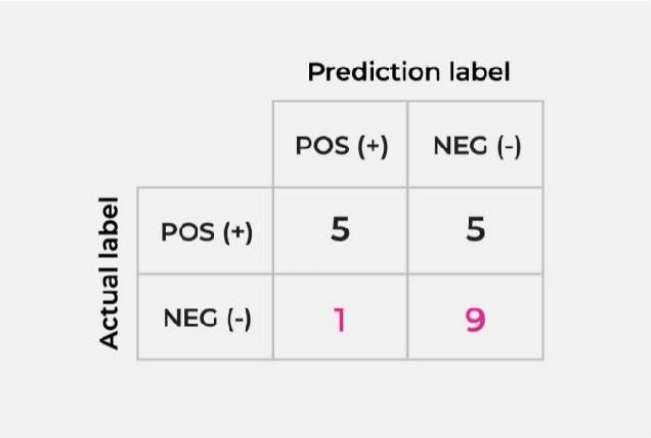
https://arize.com/blog/what-is-auc/

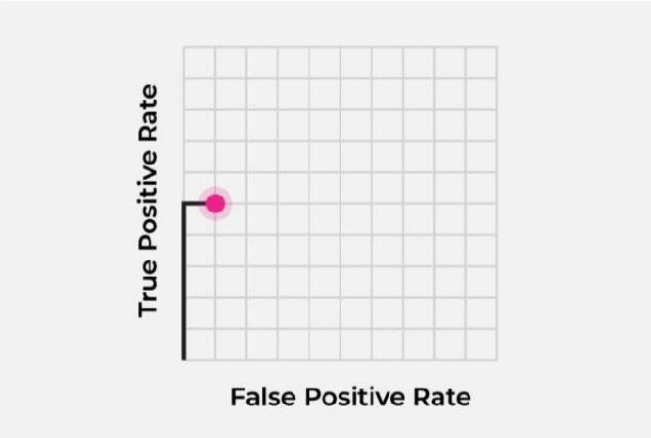
AUC-ROC

True Positive Rate: 5/10

False Positive Rate: 1/10





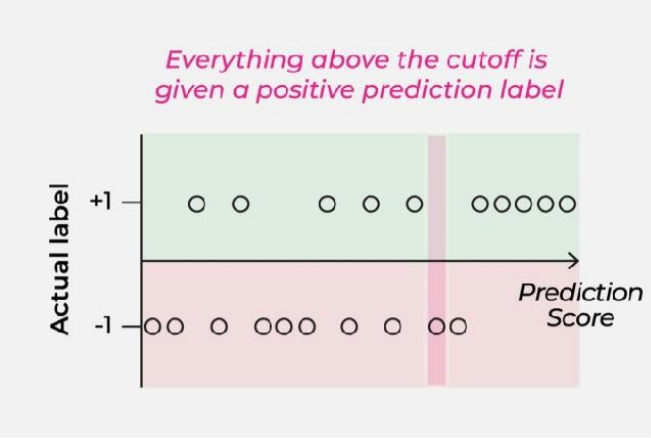


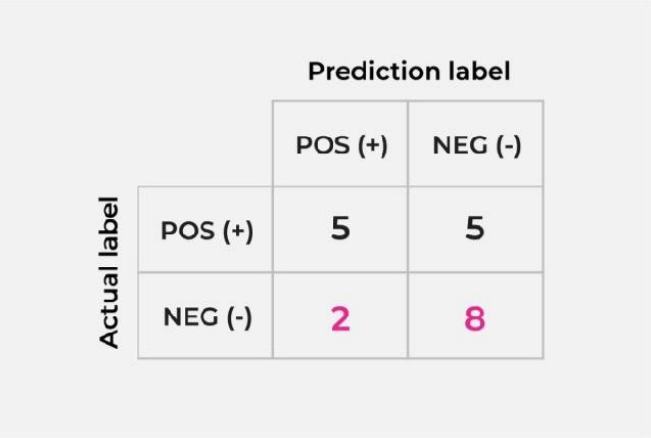
https://arize.com/blog/what-is-auc/

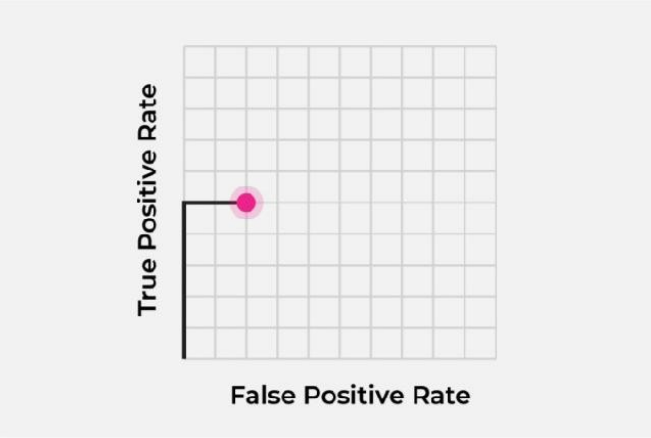
AUC-ROC

True Positive Rate: 5/10

False Positive Rate: 2/10





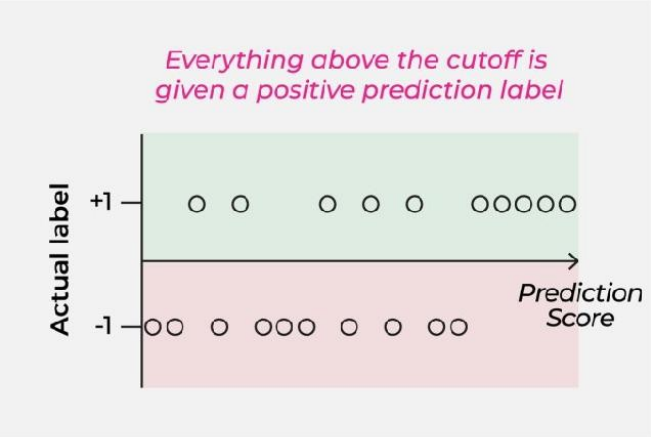


https://arize.com/blog/what-is-auc/

AUC-ROC

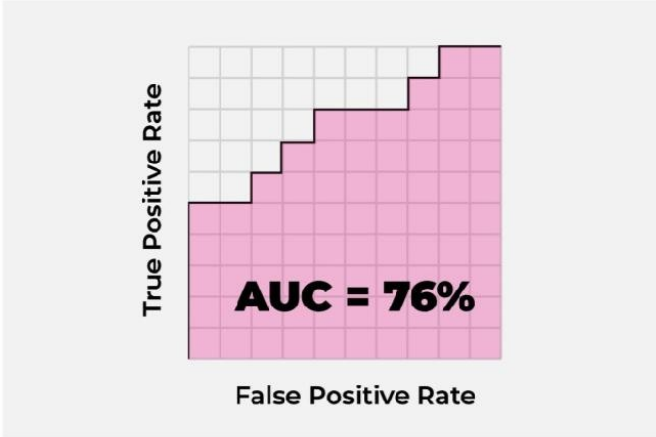
True Positive Rate: 10/10

False Positive Rate: 10/10



Prediction label

Actual label	POS (+)	NEG (-)
POS (+)	10	0
NEG (-)	10	0

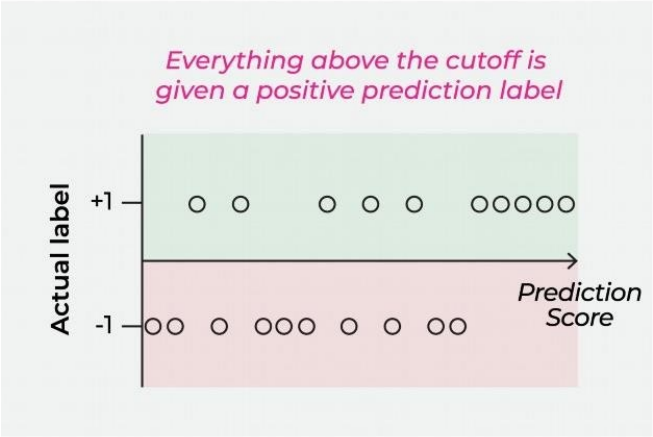


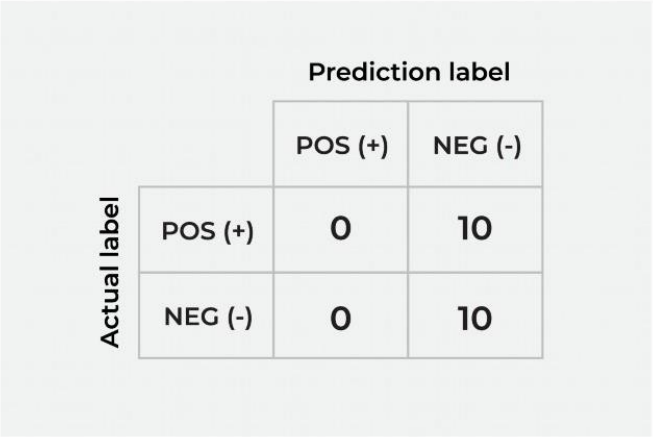
https://arize.com/blog/what-is-auc/

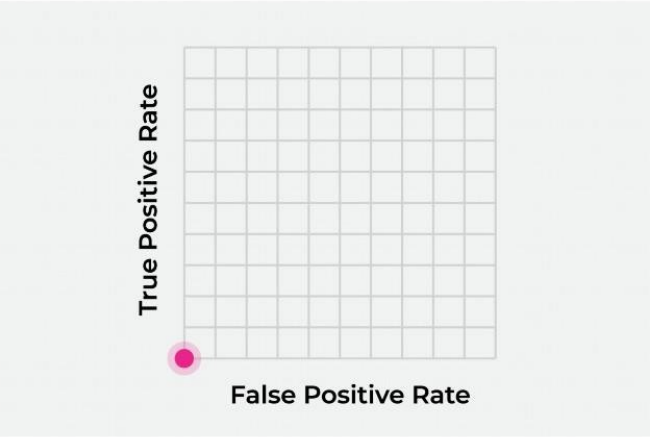
AUC-ROC

True Positive Rate: 0/10

False Positive Rate: 0/10







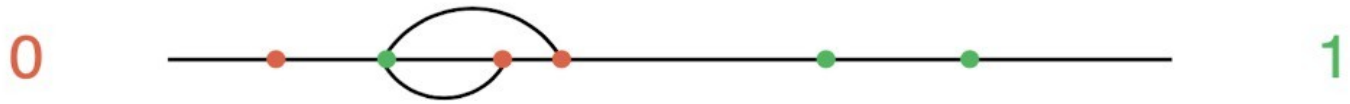
https://arize.com/blog/what-is-auc/

AUC-ROC

*только пары с разными метками

$$\text{AUC} = \frac{\#\text{ correctly ordered pairs}}{\text{total number of pairs}} = 1 - \frac{\#\text{ incorrectly ordered pairs}}{\text{total number of pairs}}$$

$$= 1 - 2 / 9 = 7 / 9$$



Соответственно, ROC-AUC слабо чувствительна на несбалансированных выборках.

Очень интересный тест

LogLoss

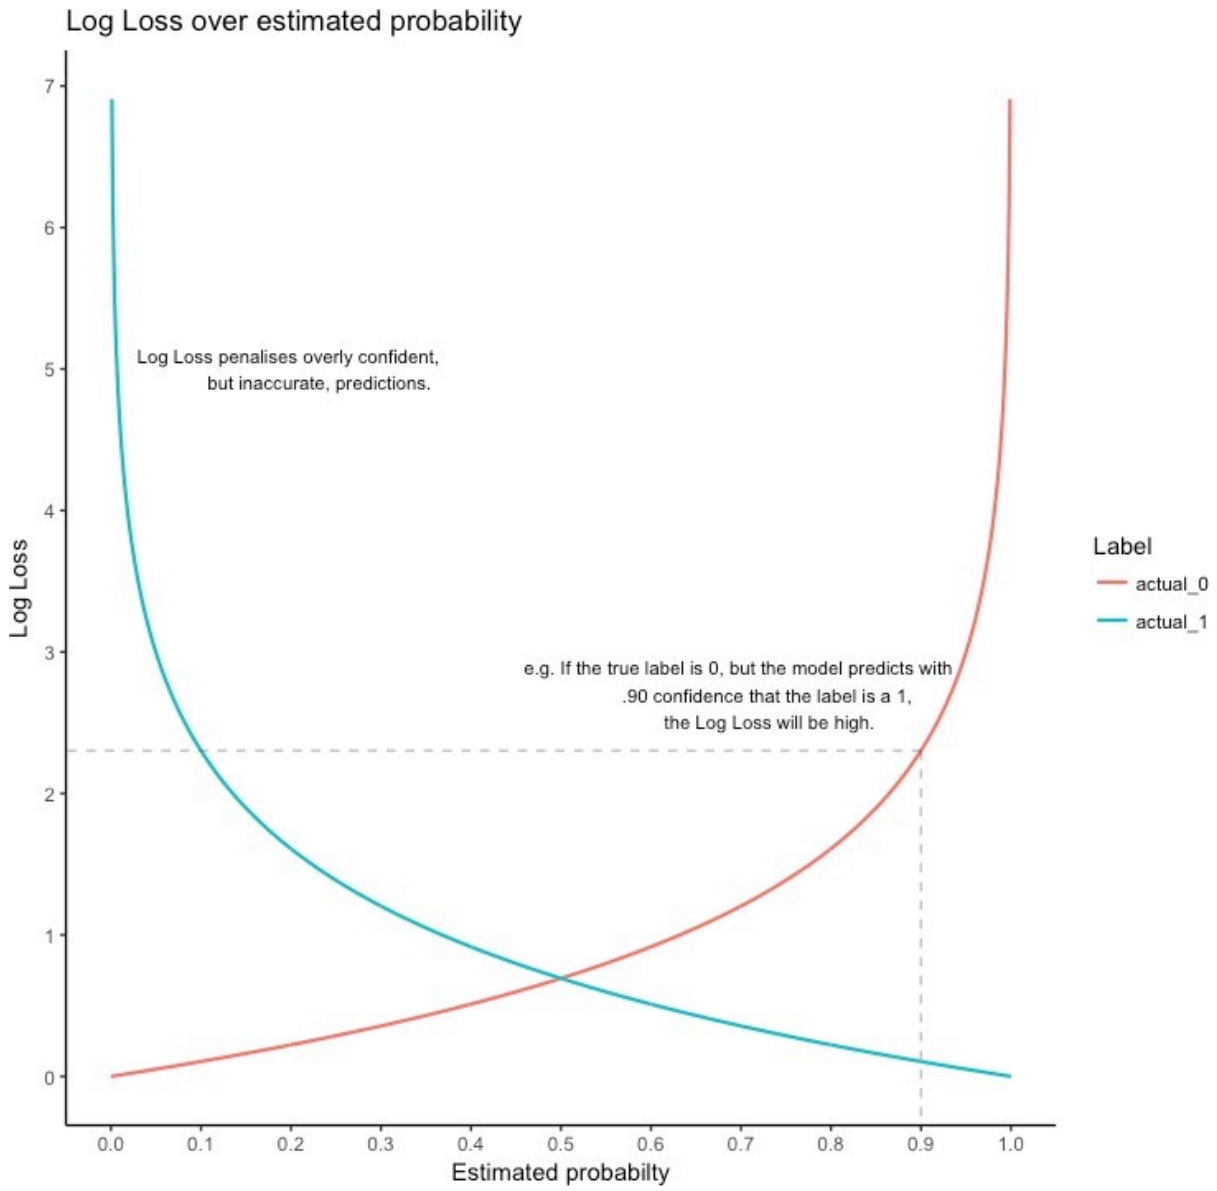
$$\text{LogLoss} = -\frac{1}{N}\sum_{i=1}^{N} y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)$$

- Выводится из метода максимального правдоподобия
- В ходе построения алгоритма данное выражение минимизируется

LogLoss

При неправильном предсказании значение функционала уходит в бесконечность.

> Лечится ограничением значений функции.



Практическая часть

Открываем jupyter notebook)

education



Classification report

```
from sklearn.metrics import classification_report

print(classification_report(y_test,y_hat_test))
```

```
              precision    recall  f1-score   support

           0       0.74      0.84      0.79     12733
           1       0.96      0.92      0.94     48532

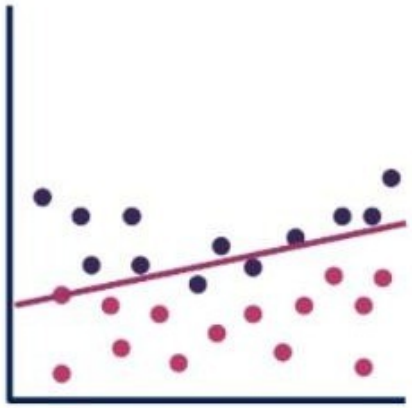
   micro avg       0.91      0.91      0.91     61265
   macro avg       0.85      0.88      0.86     61265
weighted avg       0.91      0.91      0.91     61265
```

Оценка качества моделей

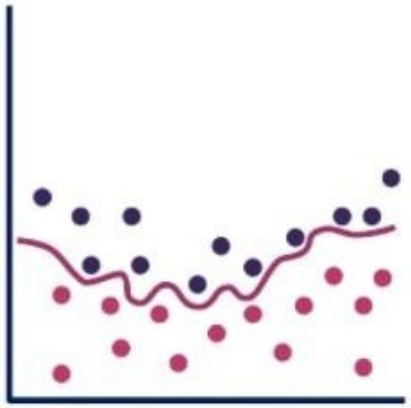
Как выбрать лучшую модель?

При построении модели есть 2 пути:

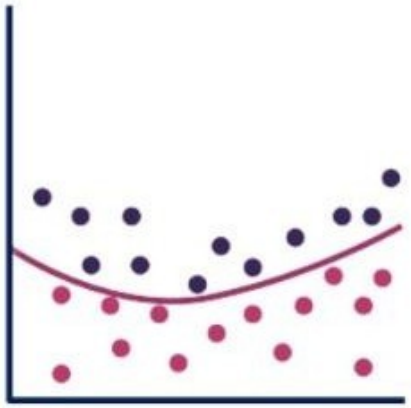
1. построить алгоритм улавливающий общие закономерности данных (путь воина)
2. запомнить ответы обучающей выборки



Underfitting



Overfitting



Balanced

Как построить обучение?

Нужно разбить выборку на несколько частей



Строим набор моделей-кандидатов

Выбираем модель

Проверяем, что все хорошо

Как делить выборку?

Shuffle and split

Перемешиваем и делим в желаемой пропорции.

Для возможности повторить результаты важно фиксировать random_state.

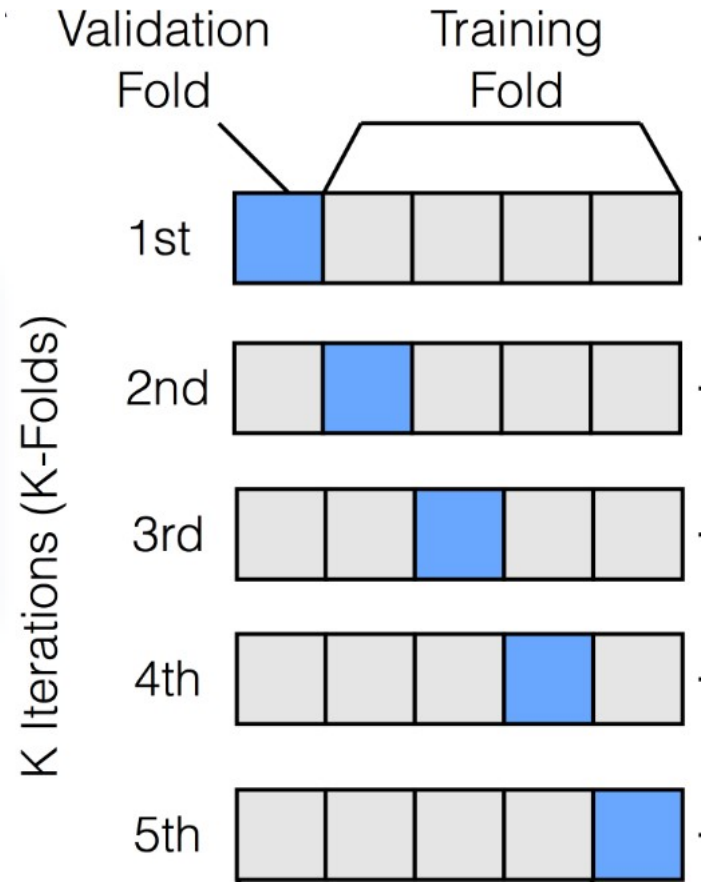
Как делить выборку?

K-fold

Разбиваем датасет на K равных частей, затем строим K моделей где в качестве Test берем одну из частей, а все остальные используем как Train. На Train обучаем модель, на Test оцениваем качество.

Особенности:

- Используем все данные как для построения моделей, так и для оценки качества
- Один из наиболее популярных методов оценки качества моделей



Как делить выборку?

Leave-one-out

Экстремальный случай K-fold, когда K равно числу самплов в наборе данных.

Особенности:

- Модель на датасете без одного сампла практически идентична модели на полном датасете
- Может быть эффективно посчитан для некоторых видов моделей

Как делить выборку?

Repeated K-fold/Shuffle and split

Повторяем N раз построение модели с разными разбиениями (можно просто менять random_state)

Особенности:

- В N раз увеличивает сложность построения
- Помогает на маленьких выборках

Как делить выборку?

Stratified K-fold/Shuffle and split

Сохраняем некоторые распределения из исходной выборки при разбиениях

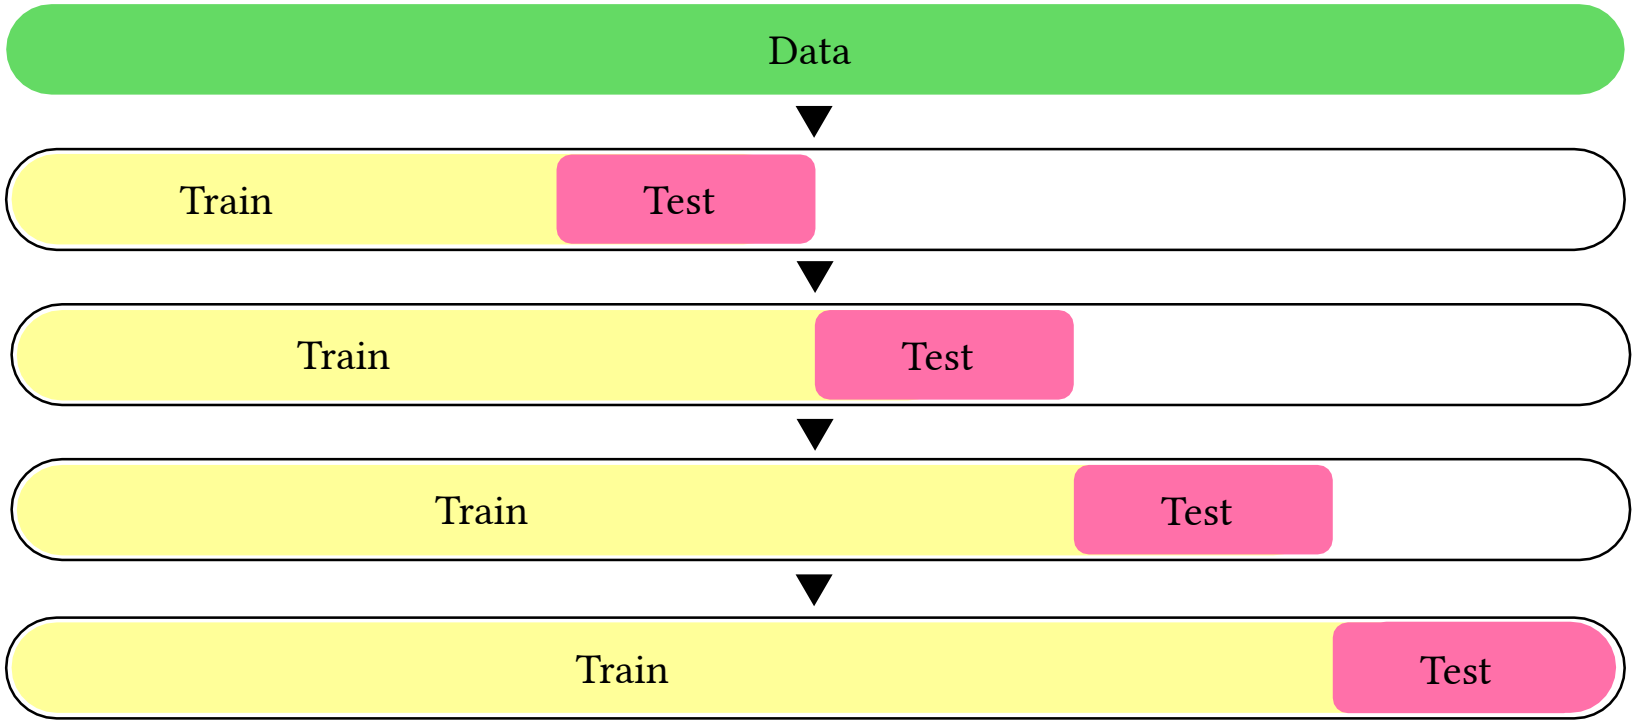
Например:

- Распределение признака (пол/возраст/дата и тд)
- Распределение таргета

Разбиение временных рядов

Разбиваем датасет на K частей, у каждой из которых test лежит правее на временной оси, чем train.

Пример использования



Работа
с признаками

Извлечение признаков

- File123.csv – сырой набор численных и не только признаков
- Sample – объект из обучающей выборки, представлен вектором
- Feature extraction – превращение данных, специфических для предметной области, в понятные для модели векторы

Типы признаков

- Бинарные – принимают значение 0/1 (флаг подключения услуги)
- Категориальные – их множество значений конечно
- Количественные – их множество значений вся числовая прямая
- Порядковые – их множество значений конечно и упорядочено

Примеры признаков

- Числовые
- Дата и время
- Геоданные
- Временные ряды
- Текстовые данные
- Картинки
- Звук
- Графы

Геоданные

- Количество объектов в некотором радиусе
- Расстояние до важных оъектов
- Что находится по заданной координате
- Признаки маршрута между несколькими точками

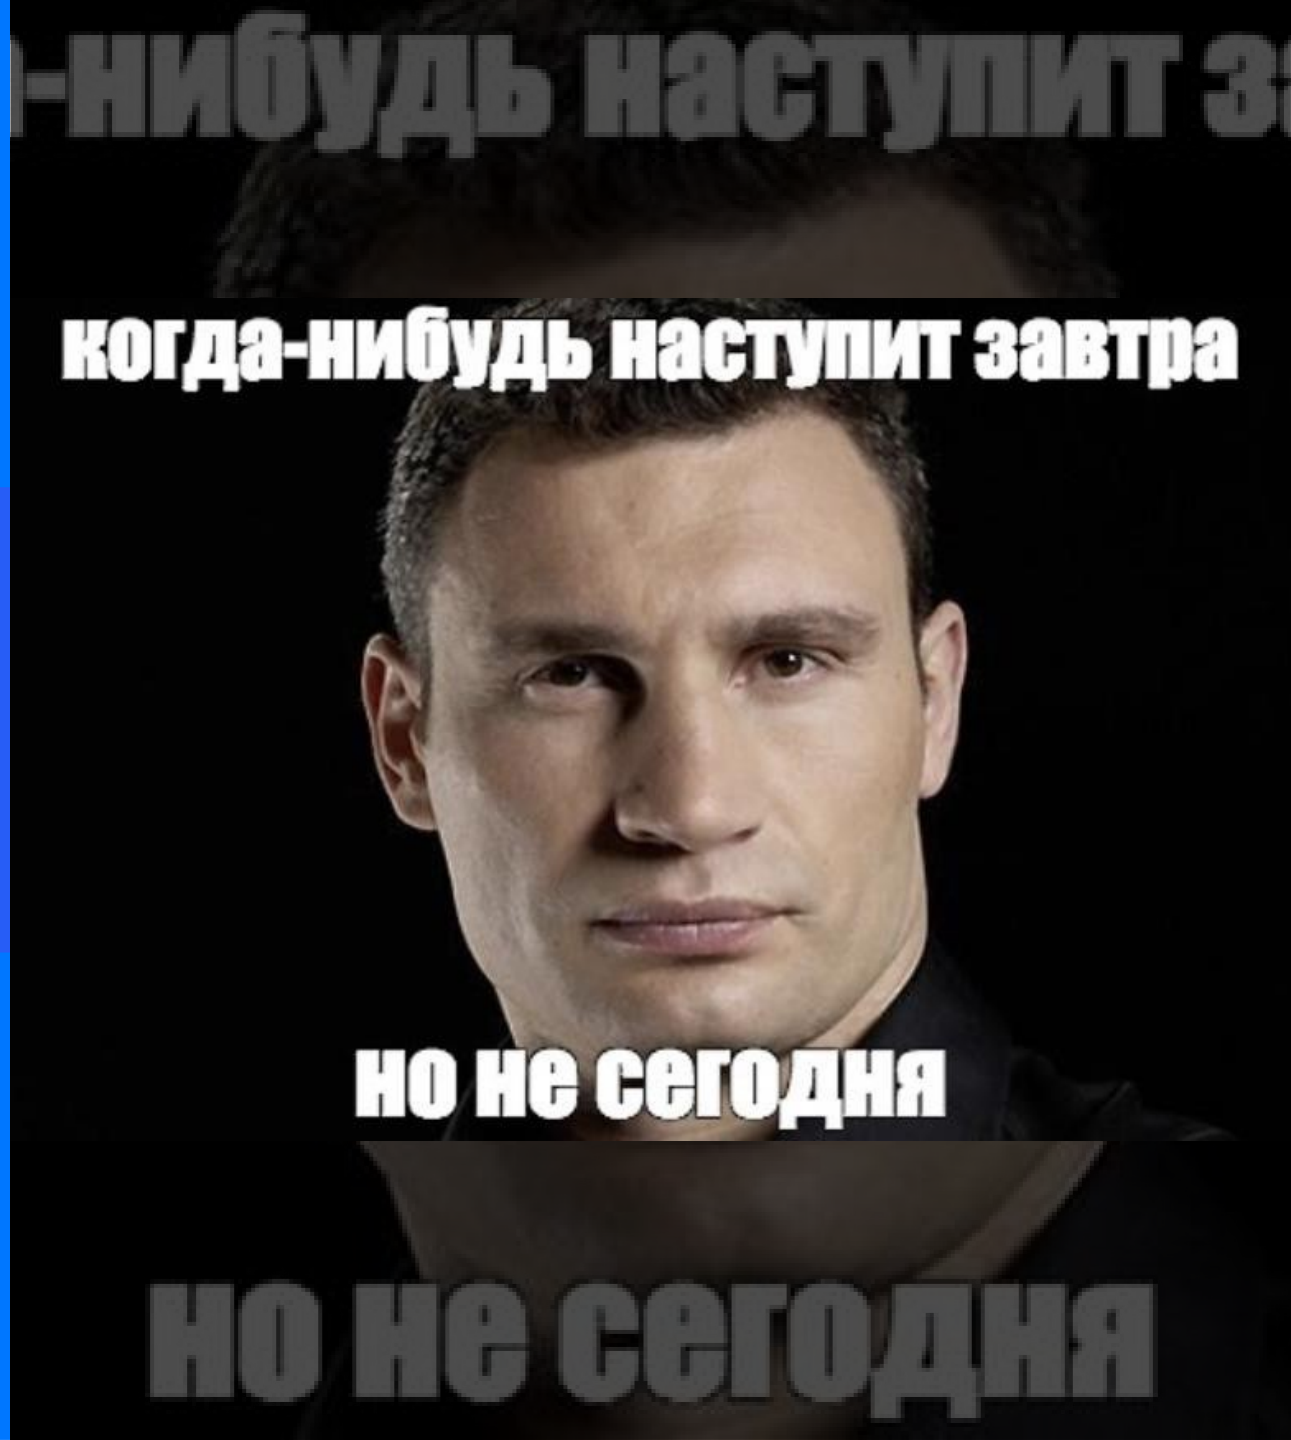
education



Дата и время

- Абсолютное время
- Периодичность
- Временной интервал до особого события

education



Временные ряды

- Среднее значение/медиану/дисперсию за период
- Тренд за период
- Количество пиков
- Коэффициенты асимметрии и эксцесса



education

Извлечение признаков

Год выпуска	**2011**
Пробег	**98 000 км**
Кузов	Внедорожник 5 дв.
Цвет	Белый
Двигатель	6.2 л / 409 л.с. / бензин
Коробка	Автоматическая
Привод	Полный
Руль	Левый
Состояние	Не требует ремонта
Владельцы	3 владельца
ПТС	Оригинал
Владение	9 месяцев
Таможня	Растаможен
VIN	XWFS47EF*C0****62
Автокод	Без ограничений

Характеристики модели в каталоге



Преобразование признаков

Зачем нужны преобразования?

1. Чтобы конкретный алгоритм машинного обучения их правильно интерпретировал

2. Чтобы конкретный алгоритм машинного обучения эффективно находил взаимосвязи

3. Чтобы внести априорные знания о наборе данных или свойствах признаков

Нормализация

Нормализация — это преобразование данных к неким безразмерным единицам. Иногда — в рамках заданного диапазона, например, [0..1] или [−1..1]. Иногда — с какими-то заданным свойством, как, например, стандартным отклонением равным 1.

Ключевая цель нормализации — приведение различных данных в самых разных единицах измерения и диапазонах значений к единому виду, который позволит сравнивать их между собой или использовать для расчёта схожести объектов. На практике это необходимо, например, для кластеризации и в некоторых алгоритмах машинного обучения.

Примеры нормализации

Стандартизация	Масштабирование	Монотонные преобразования	Бинаризация
Для каждого признака в наборе вычитаем среднее и делим на стандартное отклонение.	Значения каждого признака в наборе приводят к диапазону [0,1].	Применение монотонного преобразования к признаку (например: логарифмирование, возведение в степень)	Область значений количественного или порядкового признака делим на N участков и представляем в виде N бинарных признаков.

Преобразование категориальных признаков

- Замена на порядковый признак
- One-hot encoding
- Binning and woe (только для бинарной классификации)
- Hashing trick

Замена порядковым признаком

	Feature
1	School
2	Basic
3	University
4	School

	Feature
1	1
2	0
3	2
4	1

One-hot-encoding

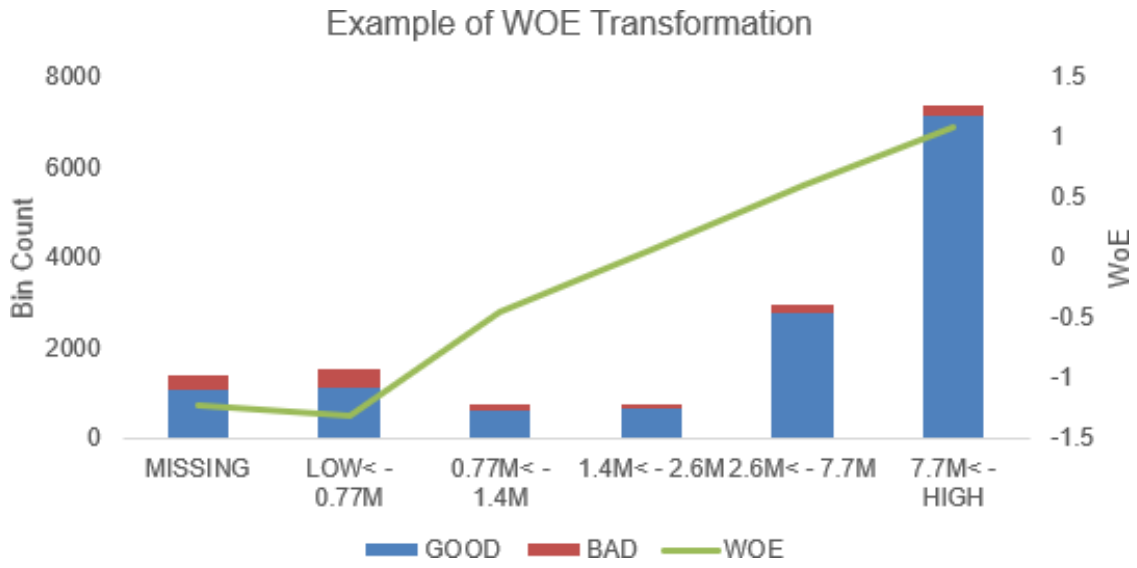
	Feature
1	School
2	Basic
3	University
4	School

	F=School	F=Basic	F=University
1	1	0	0
2	0	1	0
3	0	0	1
4	1	0	0

Binning and woe

$$WOE = \ln\left(\frac{\text{Event\%}}{\text{Non Event\%}}\right)$$

- Подсчет WOE каждой категории
- Объединение бинов с близким WOE для максимизации разницы между группами
- Замена значения признака на WOE в бине



Hashing trick

	Feature
1	School
2	Basic
3	University
4	School

	F=S	F=B,U
1	1	0
2	0	1
3	0	1
4	1	0

Задача

Алгоритм: k ближайших соседей с евклидовым расстоянием

Признаки:

1. категория кинотеатра [1..43]
2. день недели [0..6]
3. час суток [0..23]
4. цена билета [100..1000]

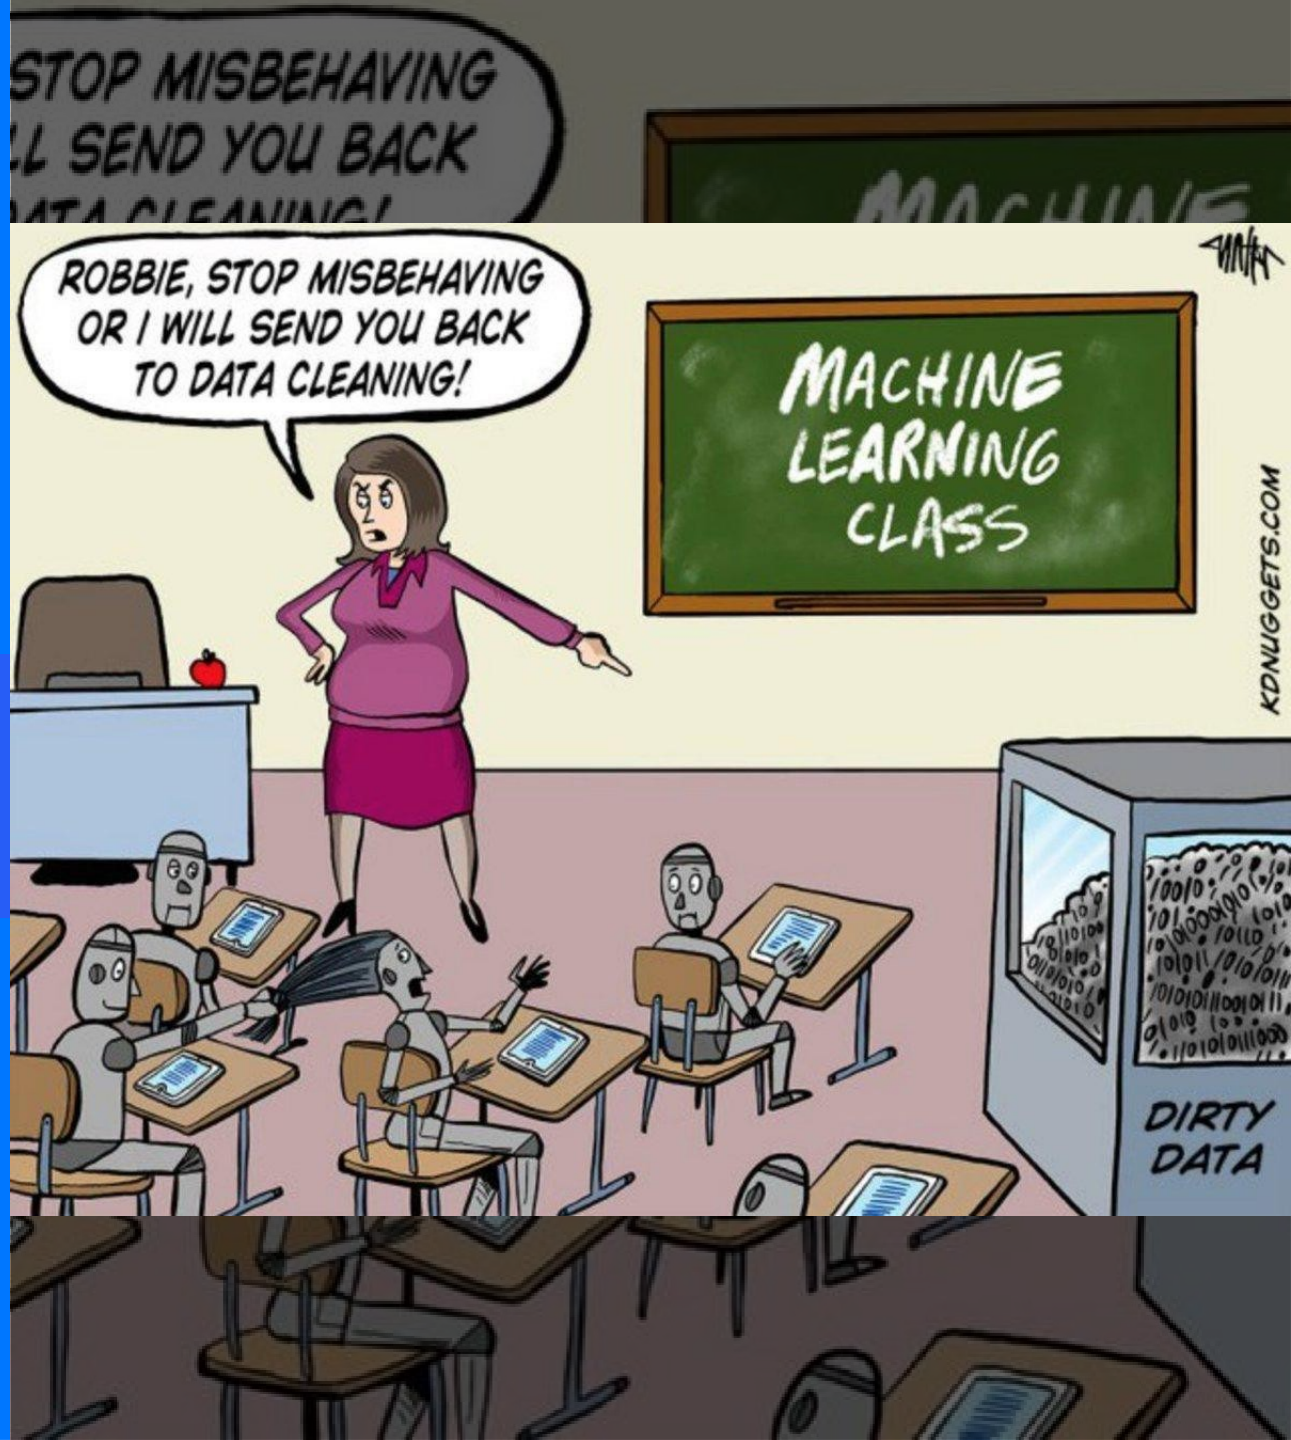
Целевая переменная: заполненность зала в % Что делать?



Практическая часть

Открываем jupyter notebook)

education



Очистка данных

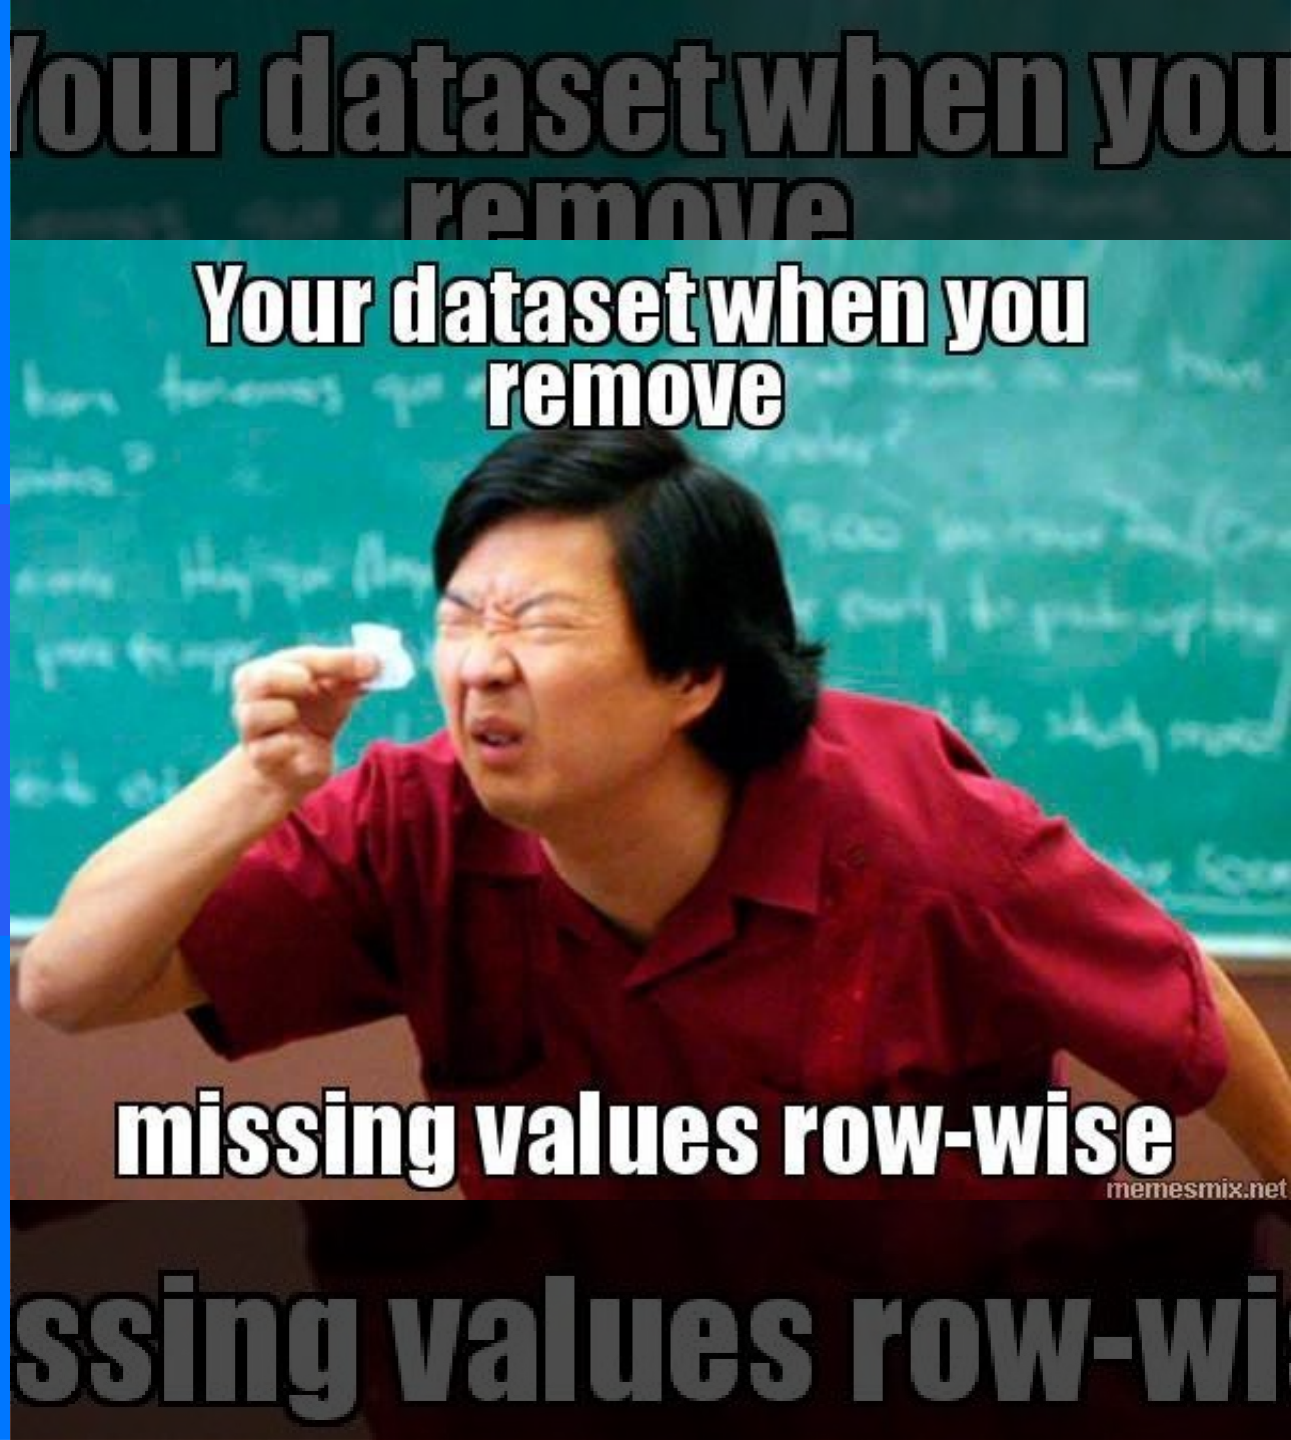
- Удаление или преобразование пропущенных значений
- Удаление дублей
- Удаление/обработка выбросов



education

Пропуски

- Ошибки при записи
- Ошибки при сборке данных
- Невозможность сбора



education

Обработка пропусков

Замена на более вероятное значение

Замена на случайное значение из распределение признака

Замена средним/медианой

Замена средним значением целевой переменной на пропущенных значениях признака

Отбор признаков

Выбор признаков, имеющих наиболее тесные взаимосвязи с целевой переменной

- Уменьшает переобучение
- Повышает точность
- Ускорение обучения

1. Однофакторный анализ
2. Рекурсивное исключение признаков
3. PCA
4. Отбор на основе важности признаков

Методы отбора признаков

Отбор признаков по взаимосвязи с целевой переменной. Например по качеству модели на 1 признаке, стабильности, корреляции с таргетом и тд.

1. Однофакторный анализ
2. Рекурсивное исключение признаков
3. PCA
4. Отбор на основе важности признаков

Методы отбора признаков

Отбор признаков с помощью recursive feature elimination.

1. Однофакторный анализ
2. Рекурсивное исключение признаков
3. PCA
4. Отбор на основе важности признаков

Методы отбора признаков

Метод главных компонент позволяет уменьшить количество используемых признаков с помощью взятия проекций пространства признаков на подпространство меньшей размерности.

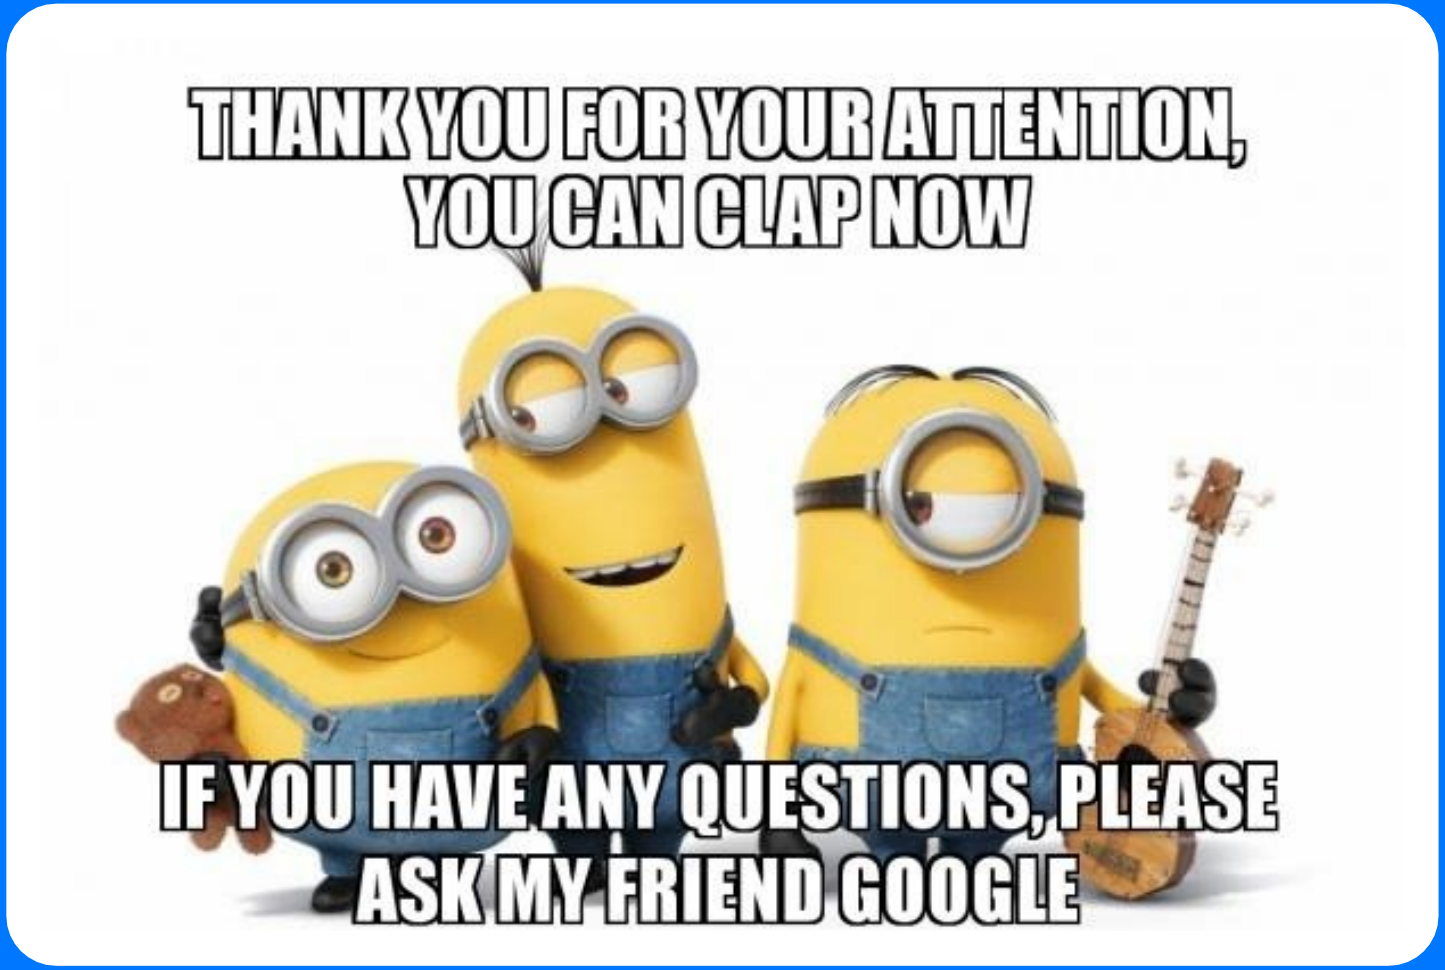
1. Однофакторный анализ
2. Рекурсивное исключение признаков
3. PCA
4. Отбор на основе важности признаков

Методы отбора признаков

По коэффициентам построенной модели/по feature importance некоторых алгоритмов.

1. Однофакторный анализ
2. Рекурсивное исключение признаков
3. PCA
4. Отбор на основе важности признаков

Слайд для ваших вопросов



Слайд для вашего отзыва ;)



Поставьте ~~хорошую~~
Оценку, пожалуйста