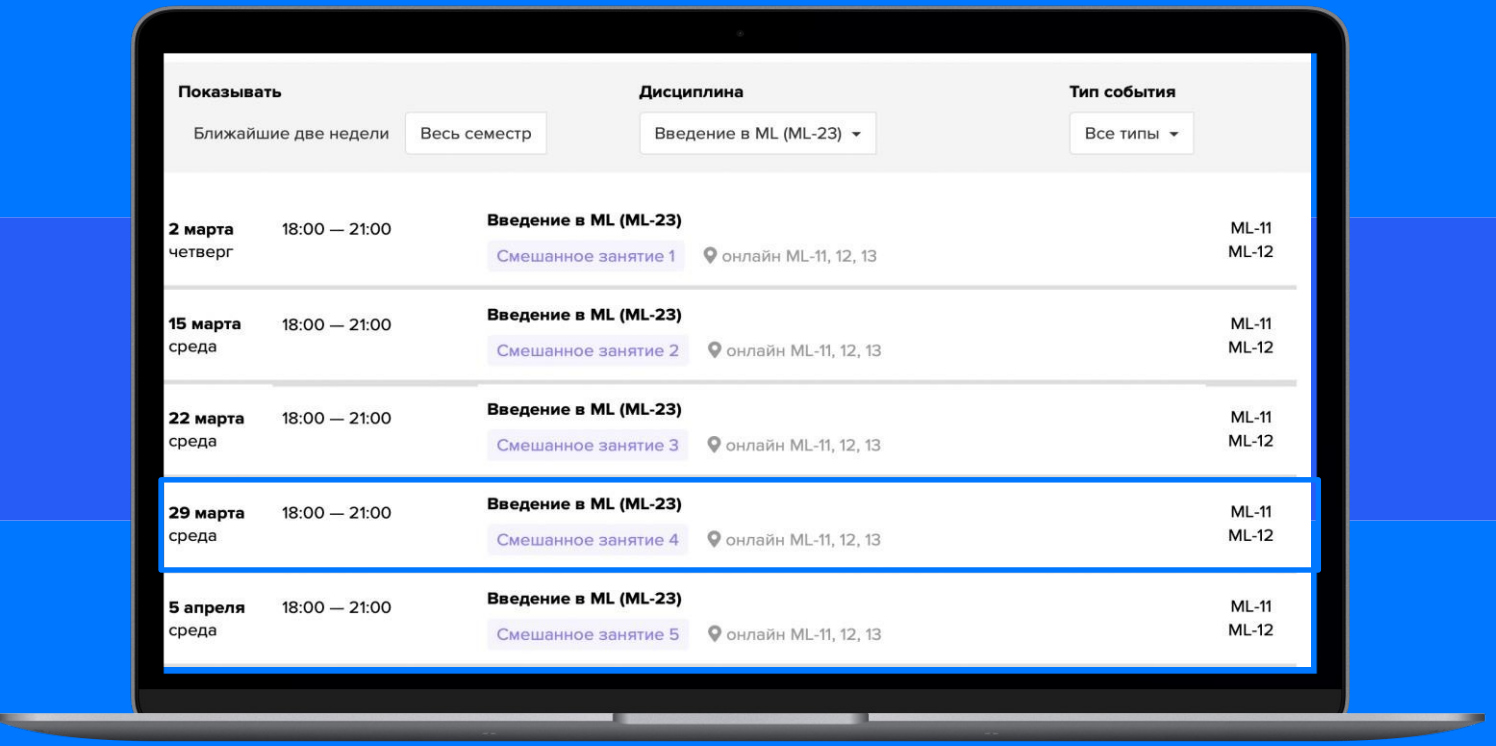
education

Признаки и предобработка данных

To Do

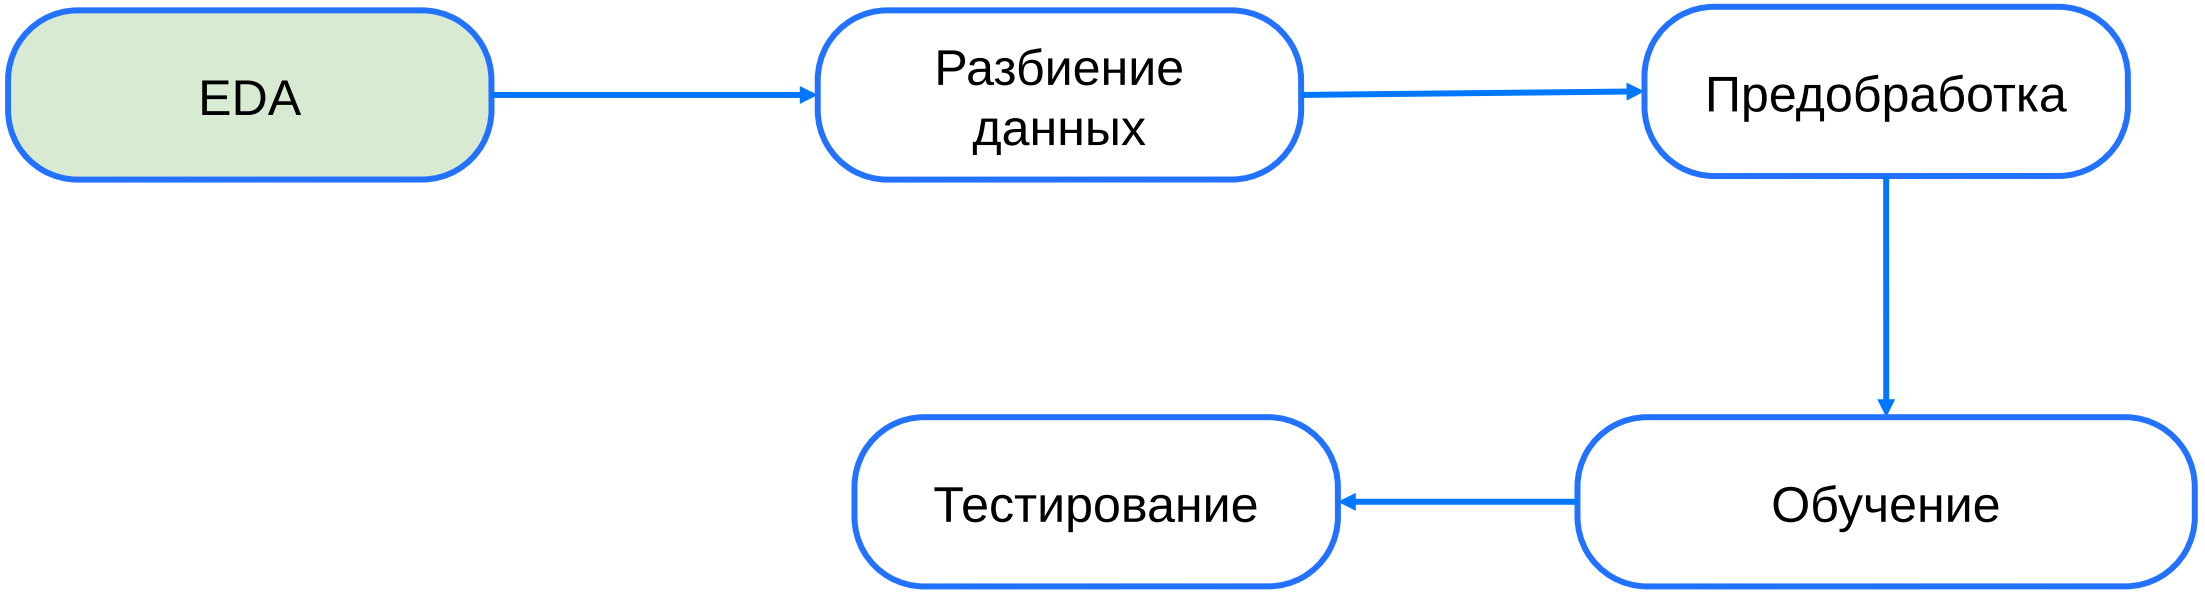


education



Последовательность действий

education



education

Признаки и данные

раздел 1

Данные и признаки

education

- Будем называть $X = (\vec{x_1}, \dots, \vec{x_N})$ **набором данных** или **датасетом**
- Каждая строка $\vec{x_i} = (x_i^{(1)}, \dots, x_i^{(M)})$ — это **объект** датасета
- Каждый столбец $(x_1^{(j)}, \dots, x_N^{(j)}$ — это **признак (feature)**
- N — количество объектов (размер датасета), M — количество признаков

Признаки (Features)

education

Виды признаков:

Тип признака	**En**	**Множество**
Бинарные	Binary	F = {true, false} или {0, 1}
Номинальные	Categorical	F - конечно
Порядковые	Ordinal	F - конечно и упорядочено
Количественные	Numerical	F = $\mathbb{R}$

ЭТО БАЗА

Признаки (Features)

education

Задача: Необходимо спрогнозировать стоимость дома
Признаки, характеризующие стоимость жилья

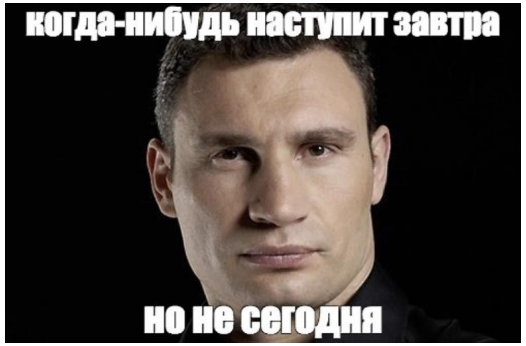
Бинарные	**Номинальные**	**Порядковые**	**Количественные**
Наличие/отсутствие газа (электричества)	Регион расположения	Качество отделки	Удаленность от общественного транспорта
Наличие/отсутствие подвального помещения		Класс дома	Удаленность от водоёма

Признаки (Features)

education

Виды признаков:

Тип признака	**En**	**Множество**
Бинарные	Binary	F = {true, false} или {0, 1}
Номинальные	Categorical	F - конечно
Порядковые	Ordinal	F - конечно и упорядочено
Количественные	Numerical	F = $\mathbb{R}$
Временные признаки	Datetime	Связанные с датой и временем



Геоданные

- Количество объектов в некотором радиусе
- Расстояние до важных объектов Что находится по заданной координате
- Признаки маршрута между несколькими точками



education

Преобразование признаков

раздел 2

Виды стандартизации данных

education

1. Структурная стандартизация — это приведение данных к единым форматам и типам.
Например: *15.08.2025, Aug 15, 2025 или 15/08/25*

2. Семантическая стандартизация — приведение к единому смыслу.
Например: РФ, Россия, Российская Федерация



3. Масштабирование числовых признаков — процесс преобразования числовых данных таким образом, чтобы они находились в общем, сопоставимом масштабе.
Например: возраст и доход

Зачем нужны преобразования?

education

Чтобы конкретный алгоритм машинного обучения их правильно интерпретировал

Чтобы конкретный алгоритм машинного обучения эффективно находил взаимосвязи

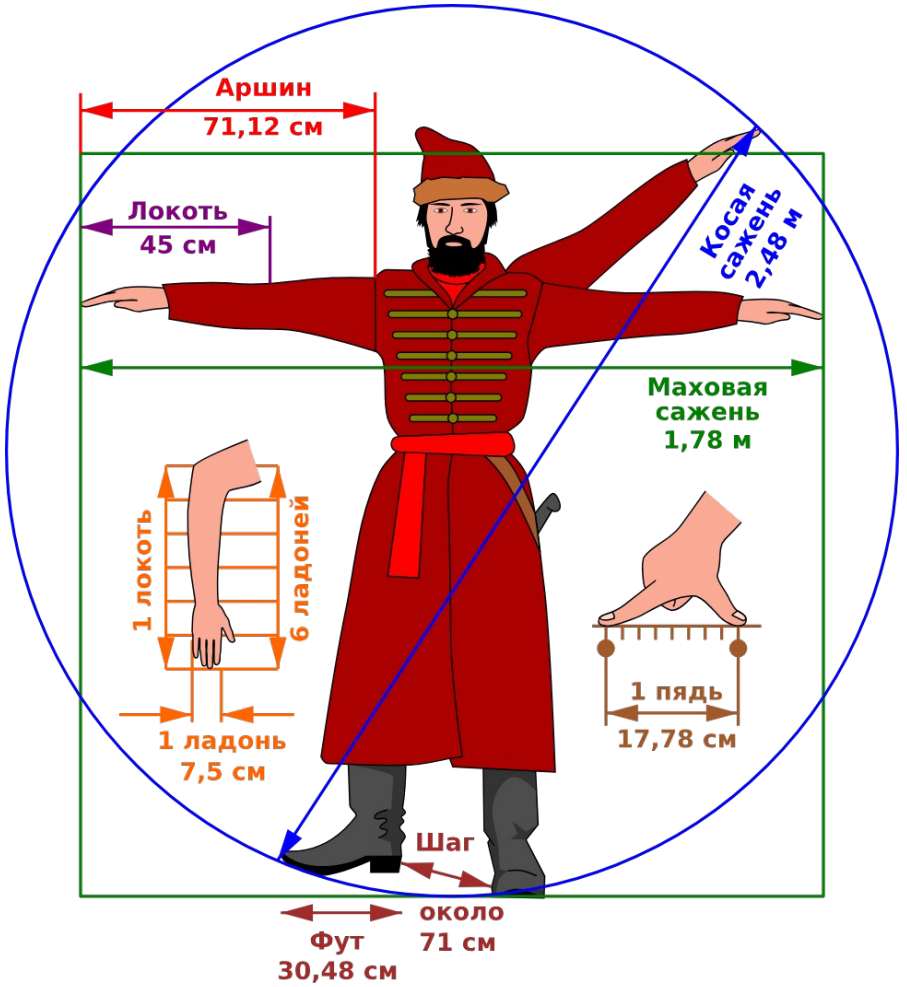
Чтобы внести априорные знания о наборе данных или свойствах признаков



Нормализация данных

Нормализация - это преобразование данных к неким безразмерным единицам. Иногда — в рамках заданного диапазона, например, [0..1] или [–1..1]. Иногда — с какими-то заданным свойством, как, например, стандартным отклонением равным 1.

Ключевая цель нормализации - приведение различных данных в самых разных единицах измерения и диапазонах значений к единому виду, который позволит сравнивать их между собой или использовать для расчёта схожести объектов. На практике это необходимо, например, для кластеризации и в некоторых алгоритмах машинного обучения.



Примеры нормализации

education

Стандартизация

Для каждого признака в наборе вычитаем среднее и делим на стандартное отклонение.

StandardScaler

$$z = \frac{x - \mu}{\sigma}$$

Масштабирование

Значения каждого признака в наборе приводят к диапазону [0,1].

Min-Max Scaling

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Монотонные преобразования

Применение монотонного преобразования к признаку (например: логарифмирование, возведение в степень)

X_scaled = log(X)

Бинаризация

Область значений количественного или порядкового признака делим на N участков и представляем в виде N бинарных признаков.



дискретизация

Преобразование категориальных признаков

education

- **One-hot encoding**: бинарные значения (1/0) для каждой категории
  Плюс: прозрачно без ложного порядка
  Минус: “проклятие размерности”, мультиколлинеарность
- **Label encoding**: присвоение категорий целым числам
  Плюс: компактно
  Минус: вводит ложный порядок (1 важнее 2, 2 важнее 3 и т.д.)
- **Target encoding**: заменяет категорию на статистику целевой переменной для этой категории (напр., среднее)
  Плюс: использовать, когда много уникальных значений и важна связь с таргетом
- **Ordinal encoding**: присвоение категориям чисел в соответствии с их естественным порядком
  Плюс: использовать, когда важен порядок (low -> medium -> high)

Ordinal encoding

education

	Feature
1	School
2	Basic
3	University
4	School

	Encoded feature
1	1
2	0
3	2
4	1

Target encoding

education

Feature	Target
Школа 1445	14
Школа 1223	21
Школа 1445	18
Школа 1223	55
Школа 1551	46

Среднее(Школа 1445) = 16

Среднее(Школа 1223) = 38

Школа 1551 = 46

Encoded feature	
Школа 1445	16
Школа 1223	38
Школа 1551	46

One-hot encoding

education

	Feature
1	School
2	Basic
3	University
4	School

	F=School	F=Basic	F=University
1	1	0	0
2	0	1	0
3	0	0	1
4	1	0	0

Label encoding

education

	Feature
1	School
2	Basic
3	University
4	School

	Encoded feature
1	1
2	2
3	3
4	4

Задача

Прогнозируем среднюю длительность поездки на самокате (в минутах)
с помощью KNN и евклидова расстояния. Нужно определить тип каждого признака,
предложить способ кодирования с обоснованием для KNN, объяснить предобработку

Признаки:

1. Тип самоката [A, B, C]
2. Район старта [0…50]
3. Час суток [0..23]
4. Температура воздуха [−10…35]

Целевая переменная: длительность поездки (мин)

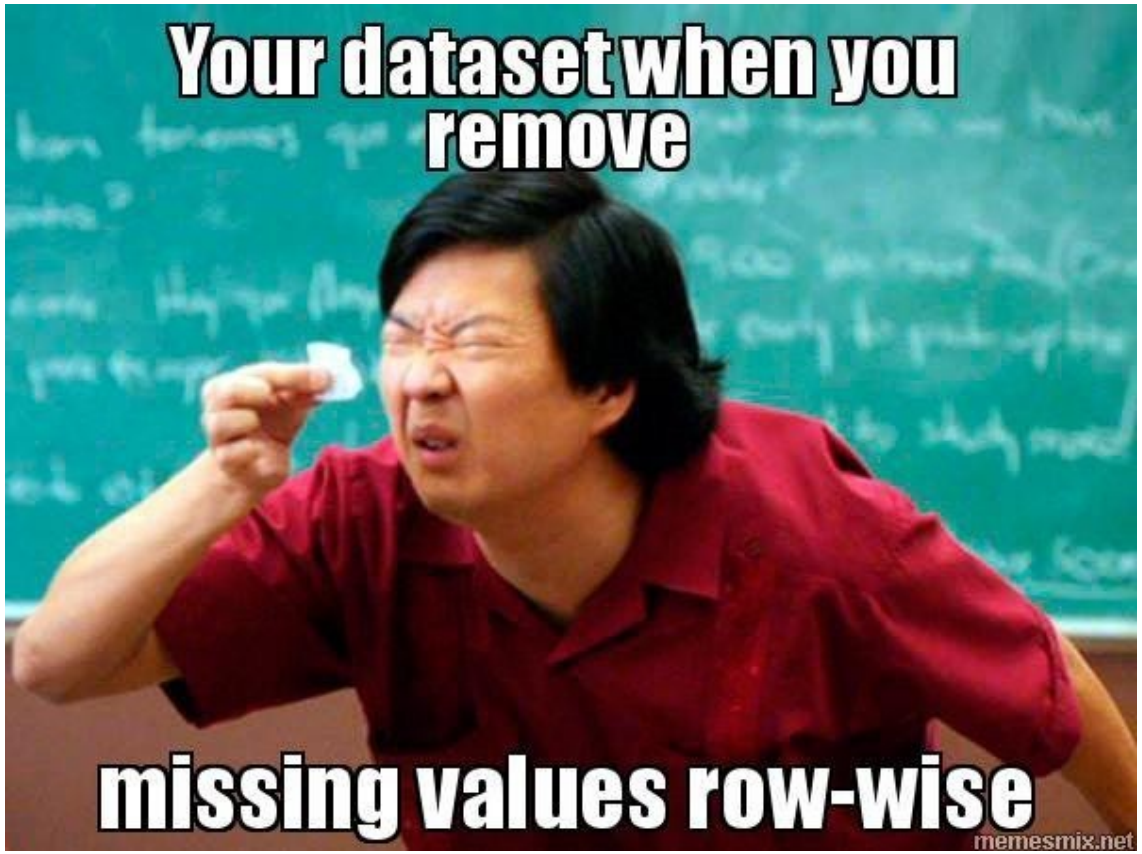


Обработка пропусков

education

- Замена на более вероятное значение
- Замена средним/медианой
- Замена на случайное значение из распределение признака
- Группировка данных по значениям таргета и замена средним/медианой в каждой группе

...и это еще не все!



Обработка выбросов

education

- Удаление
- Обрезание до верхних и/или нижних границ (5 и 95 перцентили, например)
- Преобразование (например, Log)
- Замена



education

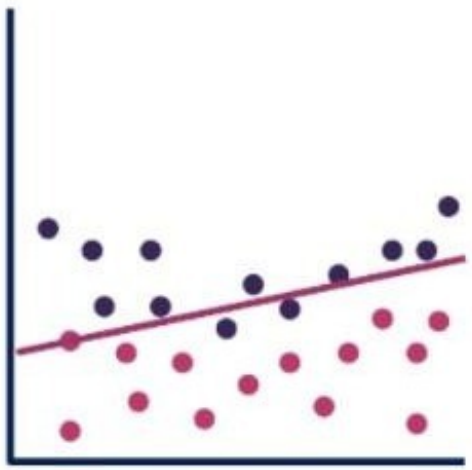
Оценка качества моделей

раздел 3

Как выбрать лучшую модель

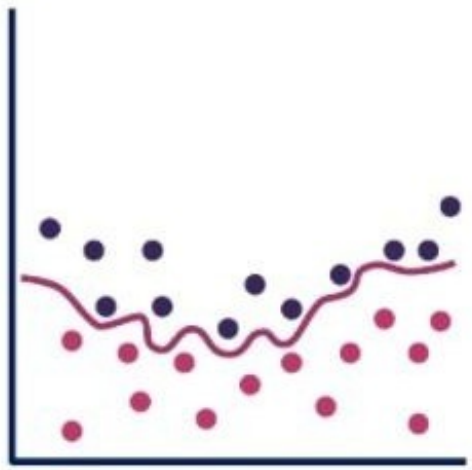
При обучении модели есть 3 пути:

Ничего не понять и не запомнить



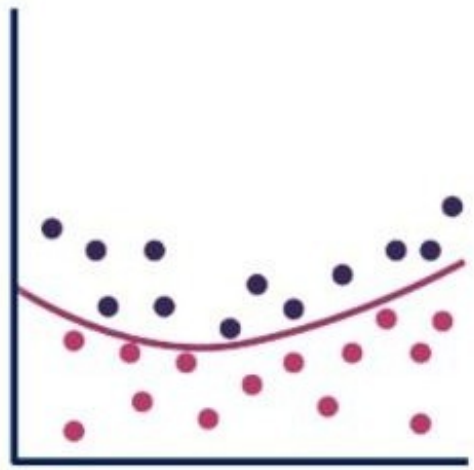
Underfitting

Запомнить ответы обучающей выборки



Overfitting

Построить алгоритм улавливающий общие закономерности данных (путь воина)



Balanced

Как выбрать лучшую модель

education

Нужно разбить выборку на несколько частей



Строим набор моделей-кандидатов

Выбираем модель

Проверяем, что все хорошо

Как делить выборку

education

Shuffle and split

Перемешиваем и делим в желаемой пропорции
Для возможности повторить результаты нужно/важно фиксировать random_state

K-fold

Разбиваем датасет на K равных частей, затем строим K моделей где в качестве Test берем одну из частей, а все остальные используем как Train. На Train обучаем модель, на Test оцениваем качество.

Stratified K-fold

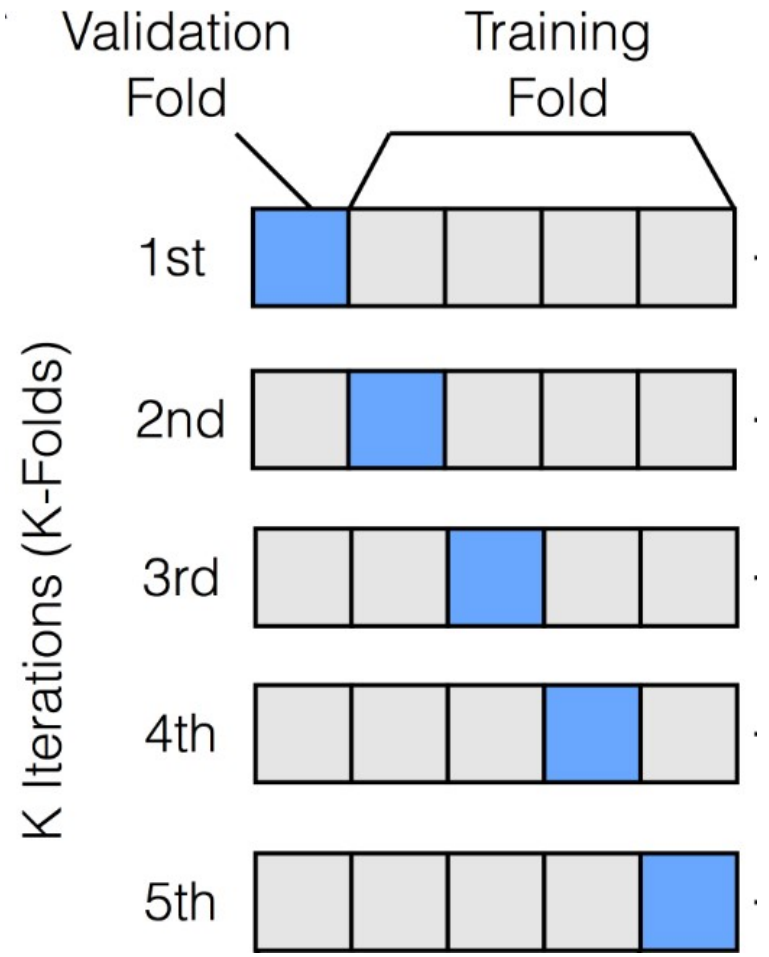
Модификация метода перекрёстной проверки (k-fold cross-validation)
Сохраняет некоторые распределения из исходной выборки при разбиениях



K-fold

education

Разбиваем датасет на K равных частей, затем строим K моделей где в качестве Test берем одну из частей, а все остальные используем как Train. На Train обучаем модель, на Test оцениваем качество.



Особенности

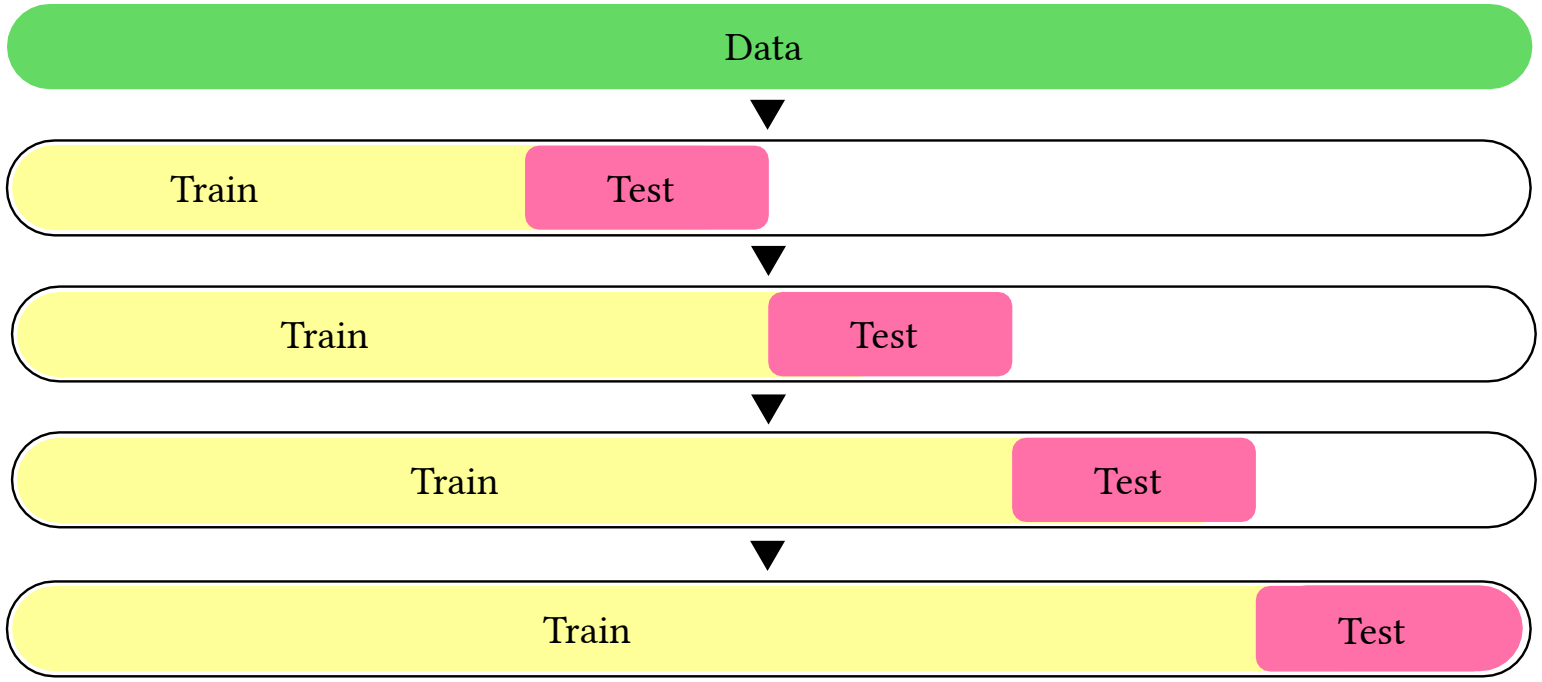
Используем все данные как для построения моделей, так и для оценки качества

Один из наиболее популярных методов оценки качества моделей

Разбиение данных временных рядов

education

Разбиваем датасет на K частей, у каждой из которых test лежит правее на временной оси, чем train.



education

Метрики регрессии

раздел 4

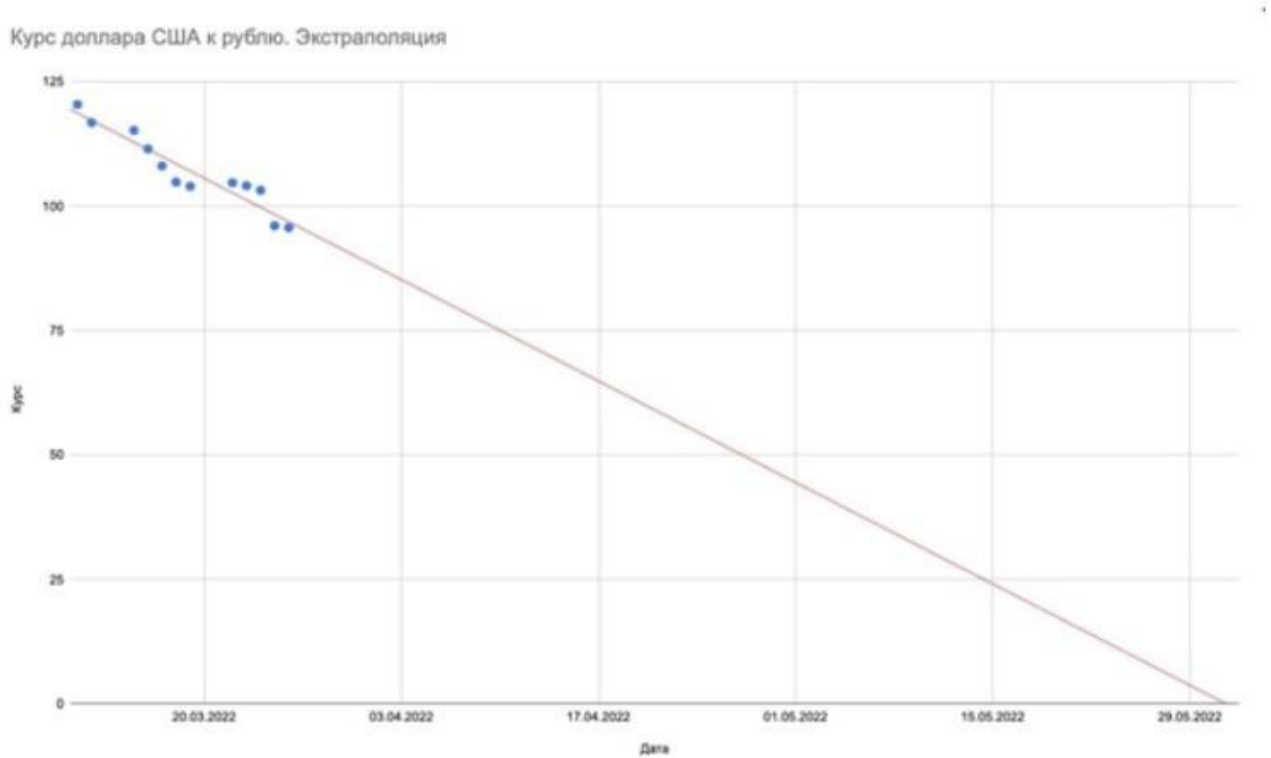
Задача регрессии

education

Физкек запись закреплена
26 мар 2022 в 18:53

+ Подписаться

примерно к началу лета наши аналитики ожидают бесплатного доллара

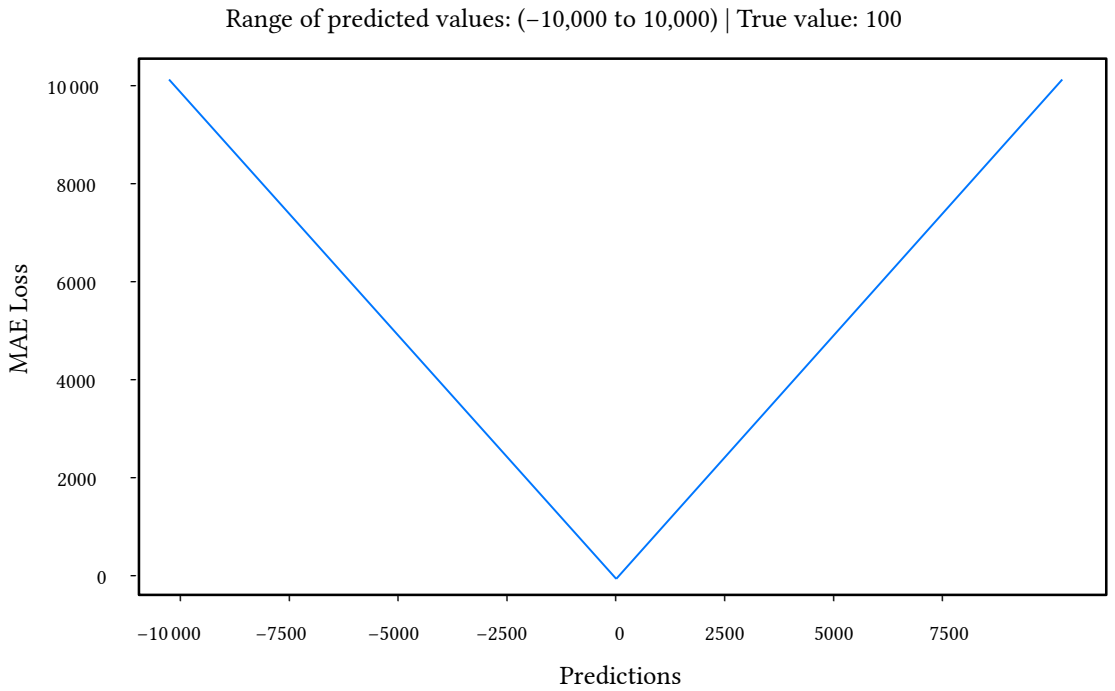


MAE

MAE (Mean Absolute Error или средняя абсолютная ошибка) - среднее значение модулей разницы между предсказанными и реальными значениями

$$\text{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

- Единицы измерения как у таргета
- Нечувствителен к выбросам
- Не дифференцируемая

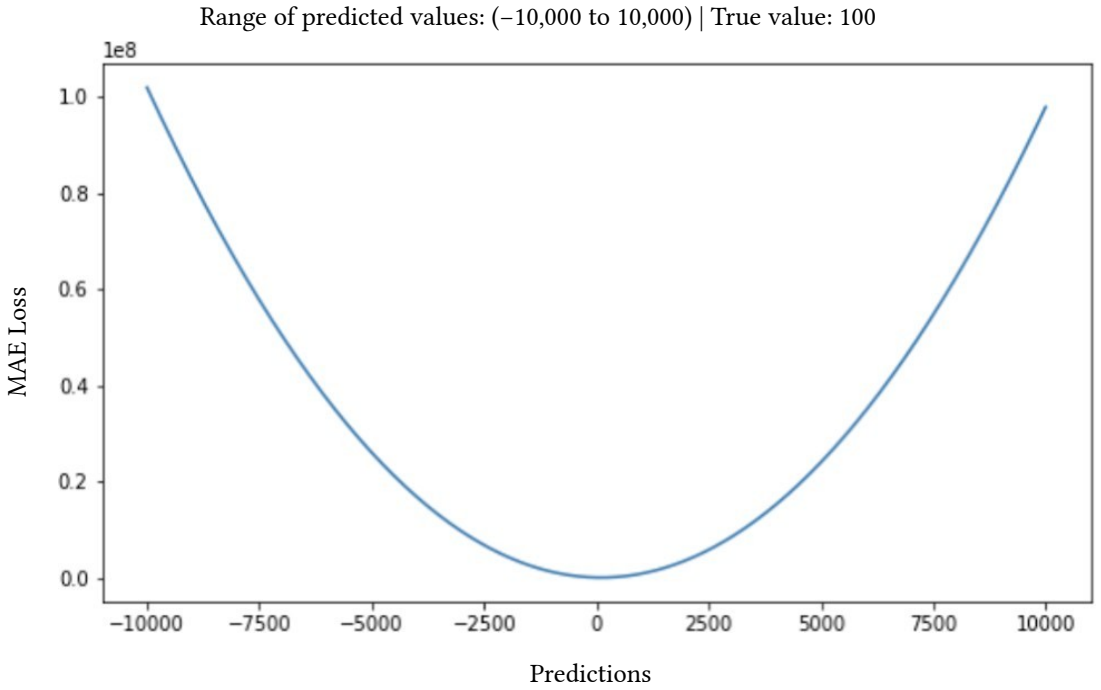


MSE

MSE (Mean Squared Error или среднеквадратичная ошибка) —показывает среднее значение квадратов разностей между реальными и предсказанными величинами

$$\text{MSE} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

- Дифференцируемая
- Чувствительна к выбросам
- Сложно интерпретировать

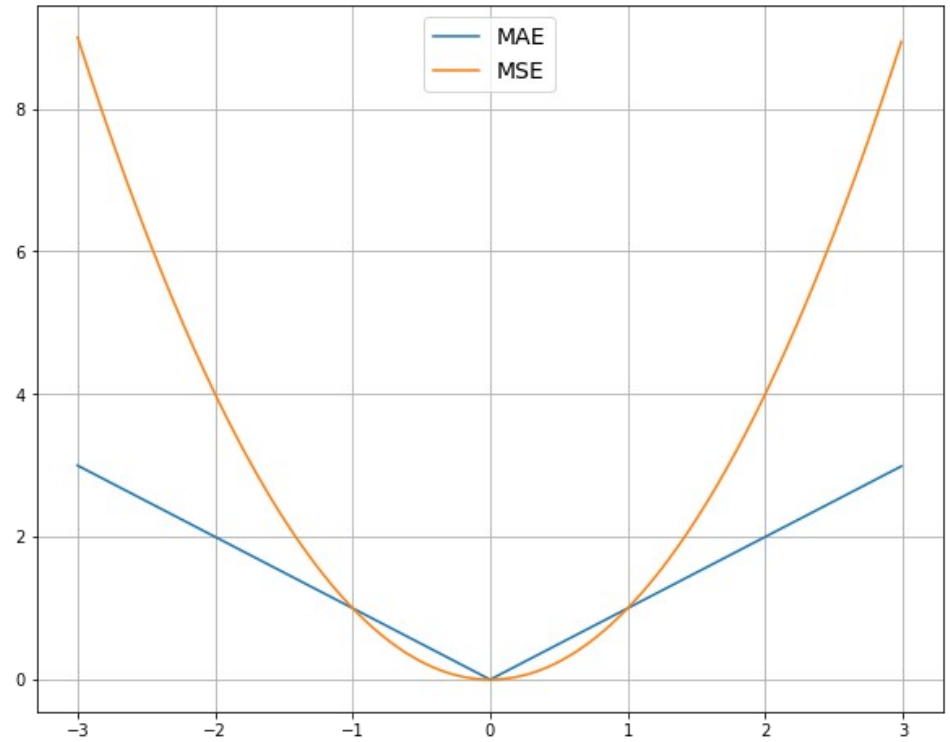


RMSE

education

RMSE (Root Mean Squared Error или среднеквадратичная ошибка) — показывает среднеквадратичное отклонение предсказанных значений от реальных

$$\text{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2} = \sqrt{\text{MSE}}$$



- Дифференцируемая
- Чувствительна к выбросам
- Интерпретация: стандартное отклонение ответа

R - квадрат

education

R^2 (R-квадрат или коэффициент детерминации) - показывает долю дисперсии (разброса) зависимой переменной, объясненную построенной регрессионной моделью

$$R^2 = 1 - \frac{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\frac{1}{N}\sum_{i=1}^{N}(y_i - \bar{y})^2} = 1 - \frac{MSE}{\frac{1}{N}\sum_{i=1}^{N}(y_i - \bar{y})^2}$$

$$\bar{y} = \frac{1}{N}\sum_{i=1}^{N} y_i$$

- Дифференцируемая
- Чувствительна к выбросам
- Хорошо интерпретируется: насколько наша модель лучше, чем константное решение

education

Метрики классификации

раздел 5

Метрики качества классификации

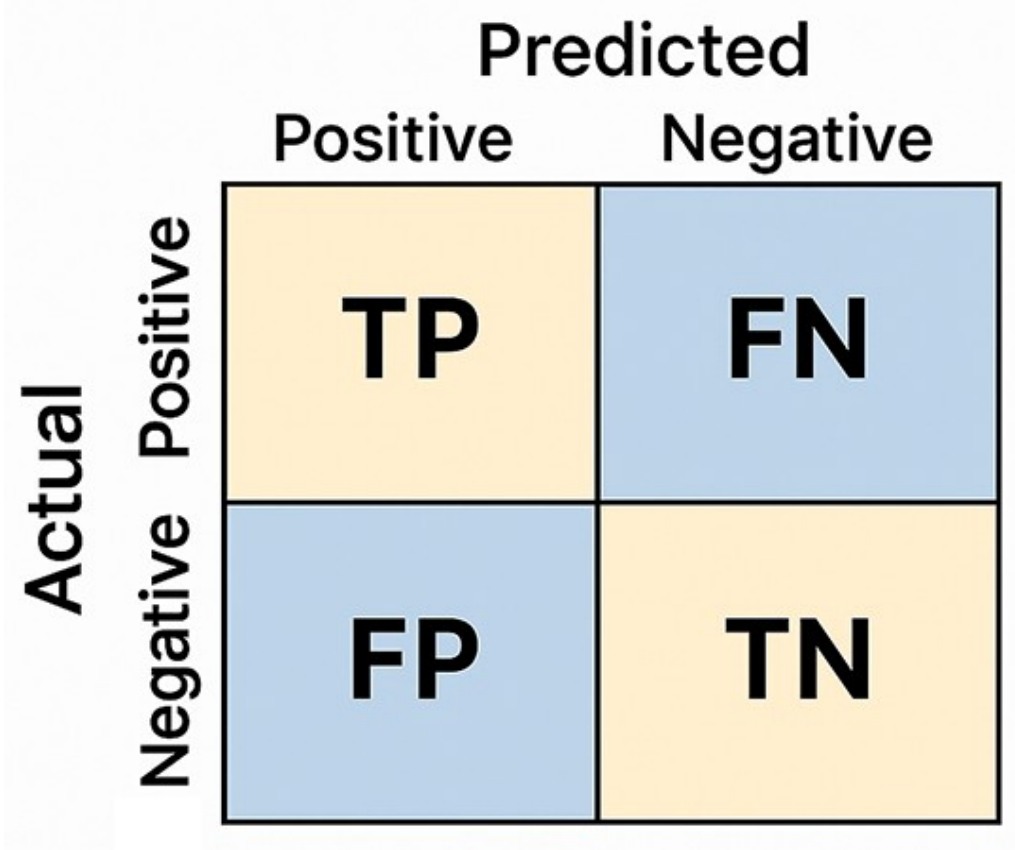
education

TP (True Positive) - Истинный положительный, модель верно предсказала позитивный класс).

FP (False Positive) - Ложное срабатывание, модель ошибочно предсказала позитивный класс, хотя объект был негативным - ошибка II рода

FN (False Negative) - Ложный отрицательный ответ, модель ошибочно предсказала негативный класс, хотя объект был позитивным - ошибка I рода

TN (True Negative) - Истинный отрицательный ответ , модель верно предсказала позитивный класс).



Метрика Accuracy

Accuracy - Доля объектов, для которых мы правильно предсказали класс

$$\text{Accuracy} = \frac{\text{correct classifications}}{\text{total classifications}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Простая
Интуитивно понятная метрика

Минусы?

СМОТРЯ КАКОЙ ACCURACY



СМОТРЯ КАКОЙ DETAILS

Метрика Accuracy

education

Accuracy - Доля объектов, для которых мы правильно предсказали класс

$$\text{Accuracy} = \frac{\text{correct classifications}}{\text{total classifications}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Минусы?

Не учитывает дисбаланс классов

Если в выборке 950 здоровых пациентов и 50 больных, простая модель, которая всегда отвечает «здоров», получит Accuracy = 95%. При этом она будет абсолютно бесполезна для поиска больных.

Метрика Recall

education

Recall - показывает, какую долю реальных объектов положительного класса смогла обнаружить модель

$$\text{Recall (or TPR)} = \frac{\text{correctly classified actual positives}}{\text{all actual positives}} = \frac{TP}{TP + FN}$$

Полнота отвечает на вопрос:
«Из всех реально существующих положительных случаев, сколько мы сумели найти?»

Метрика Precision

education

Precision - показывает долю объектов, названных моделью положительными, которые действительно являются таковыми

$$\text{Precision} = \frac{\text{correctly classified actual positives}}{\text{everything classified as positive}} = \frac{TP}{TP + FP}$$

Вопрос, на который отвечает Precision:
«Если модель предсказала положительный класс, как часто она права?»

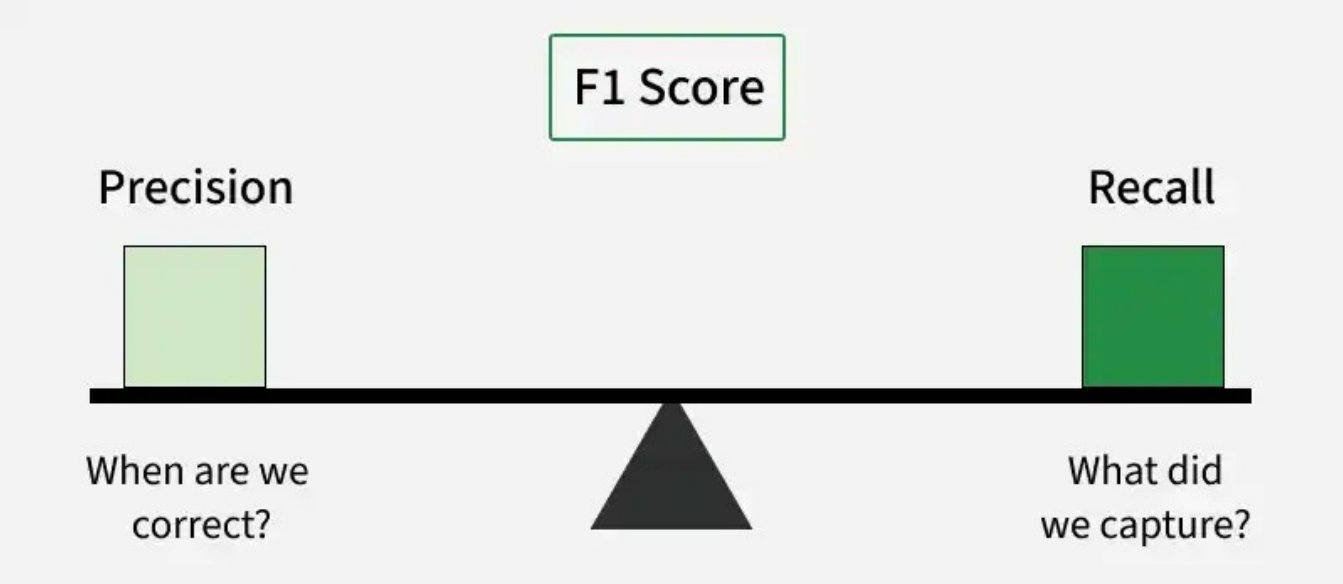

Precision
1
Recall
2



Метрика F1

F1 - представляет собой гармоническое среднее между Precision (точностью) и Recall (полнотой)

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$



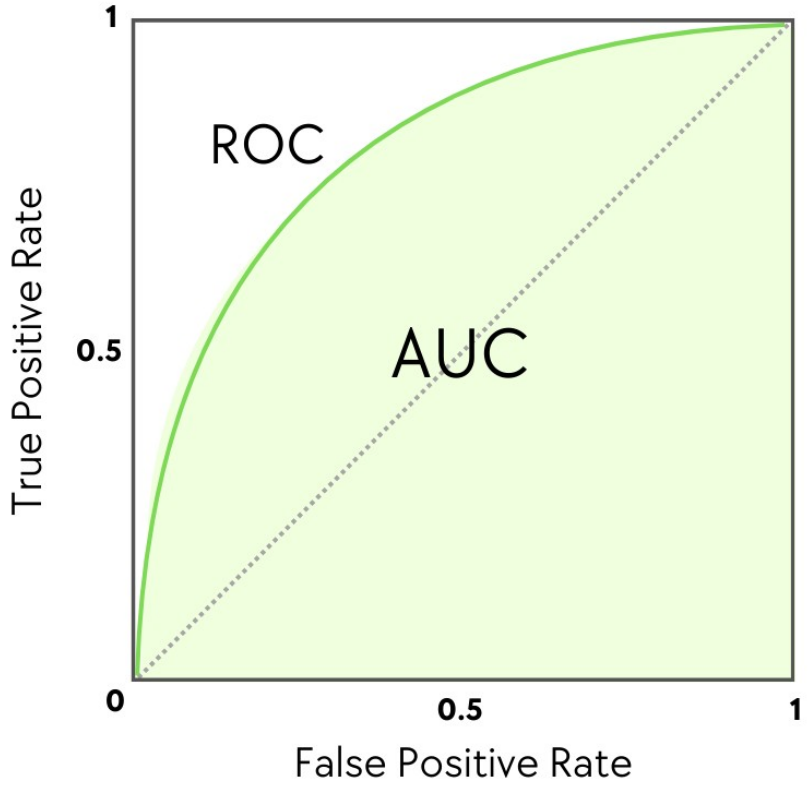
Стремится к нулю, если precision или recall близки к нулю. Коэффициент $\boldsymbol{\beta}$ отвечает за пропорцию между метриками.

Метрика ROC-AUC

ROC-AUC (Area Under the ROC curve) - определяет долю правильно проранжированных пар

$$\text{TPR (sensitivity)} = \frac{TP}{TP + FN}$$

$$\text{FPR (1-specificity)} = \frac{FP}{TN + FP}$$



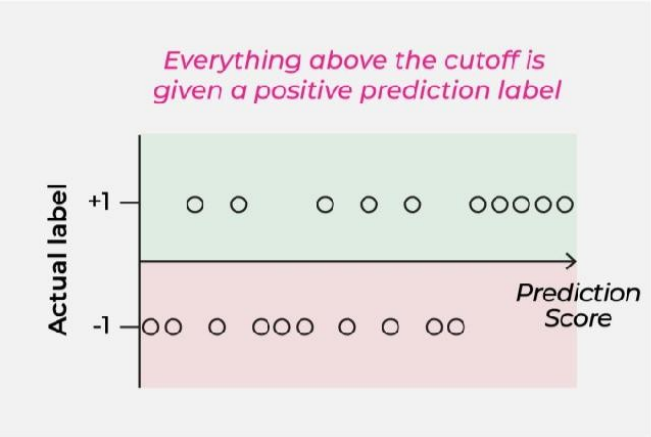
ROC-AUC

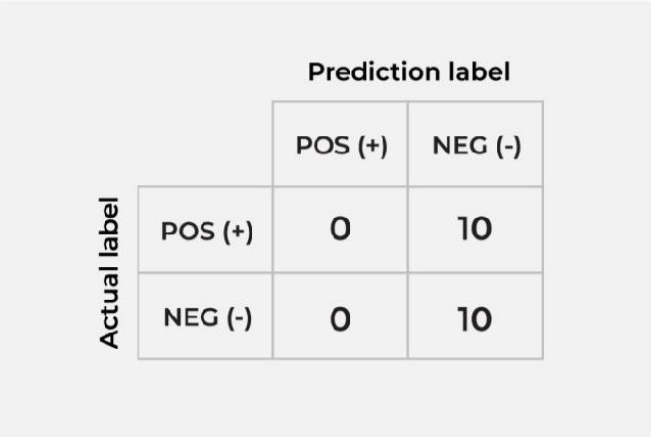
Метрика ROC-AUC

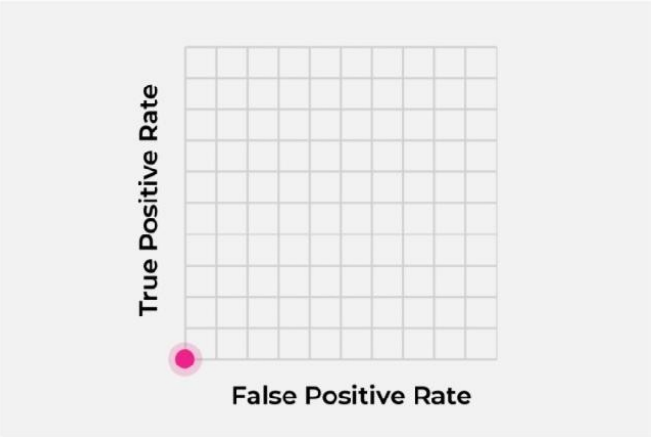
education

True Positive Rate: 0/10

False Positive Rate: 0/10







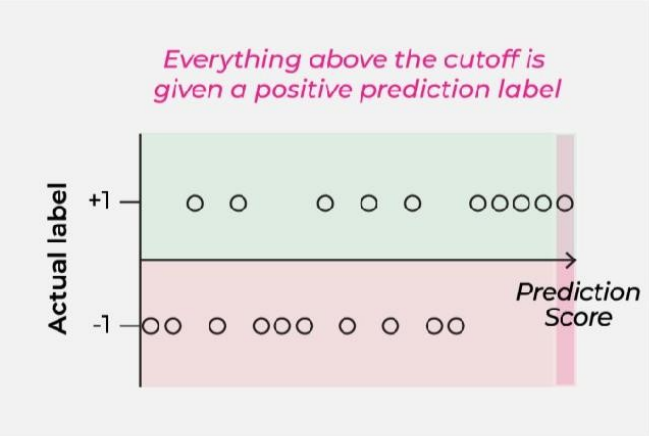
https://arize.com/blog/what-is-auc/

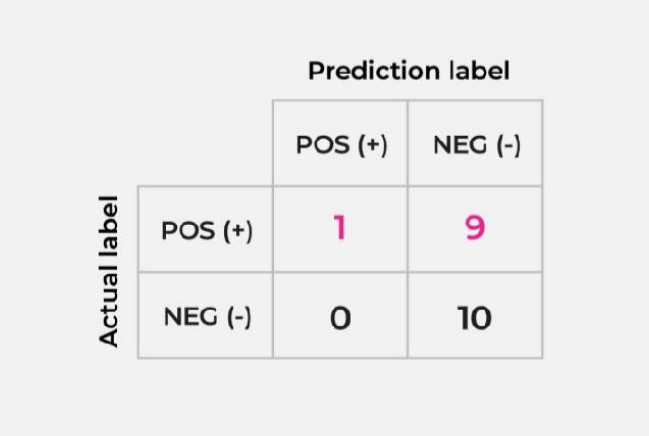
Метрика ROC-AUC

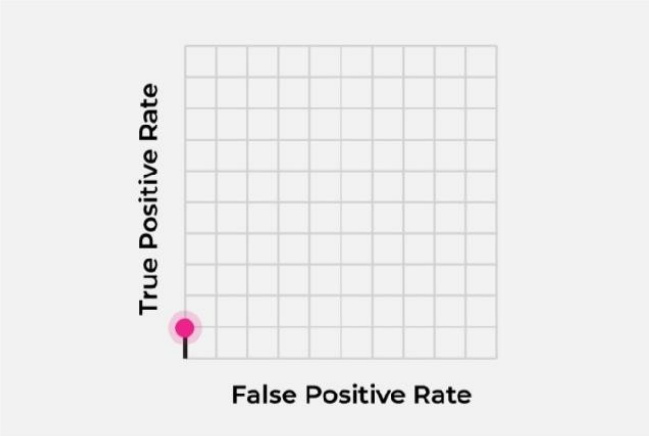
education

True Positive Rate: 1/10

False Positive Rate: 0/10







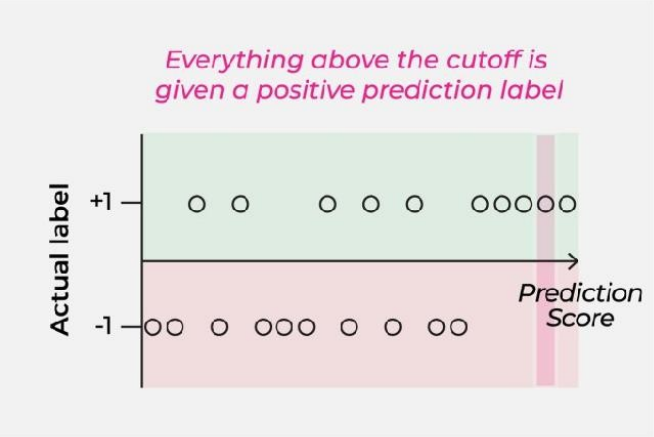
https://arize.com/blog/what-is-auc/

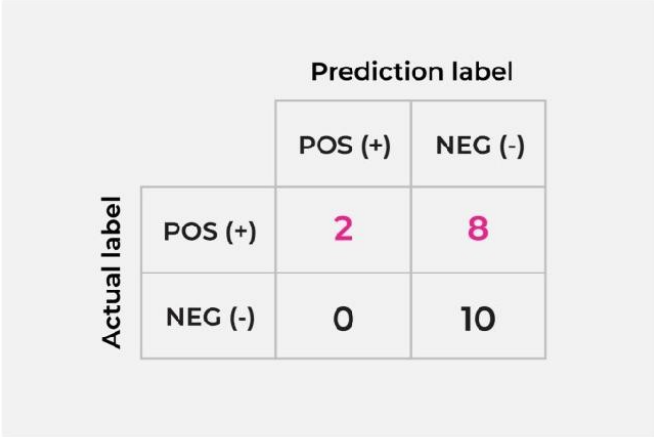
Метрика ROC-AUC

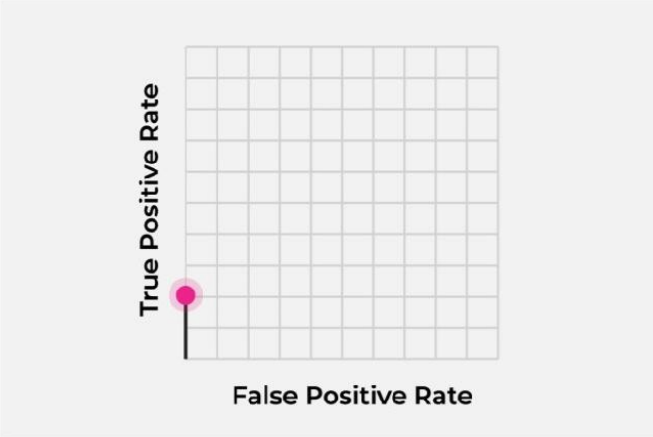
education

True Positive Rate: 2/10

False Positive Rate: 0/10







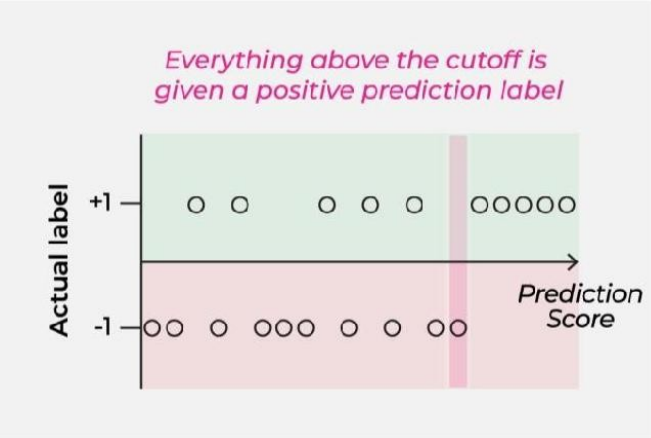
https://arize.com/blog/what-is-auc/

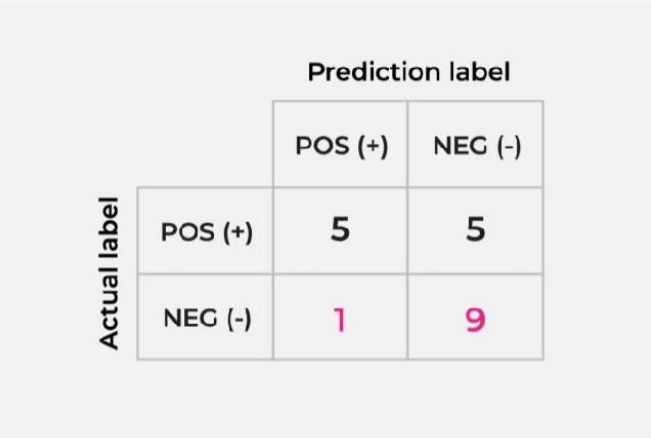
Метрика ROC-AUC

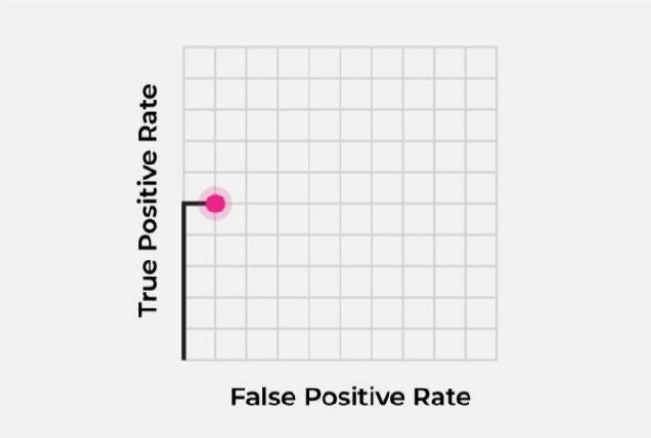
education

True Positive Rate: 5/10

False Positive Rate: 1/10







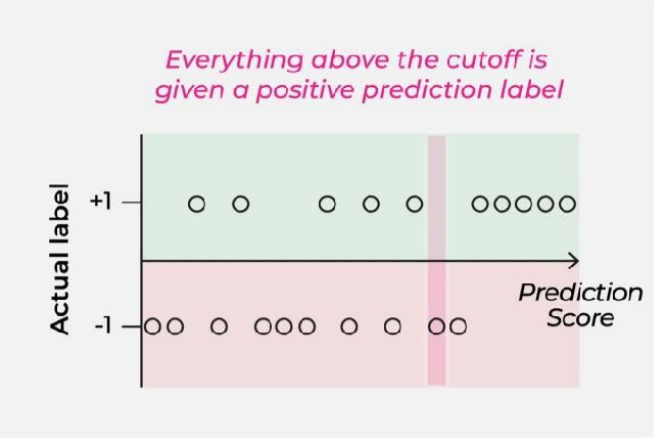
https://arize.com/blog/what-is-auc/

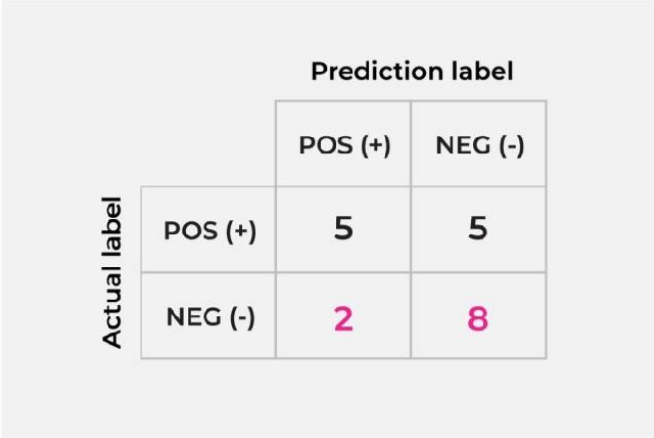
Метрика ROC-AUC

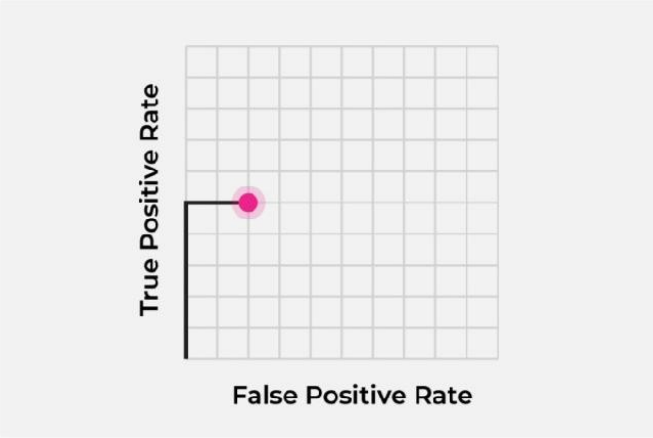
education

True Positive Rate: 5/10

False Positive Rate: 2/10







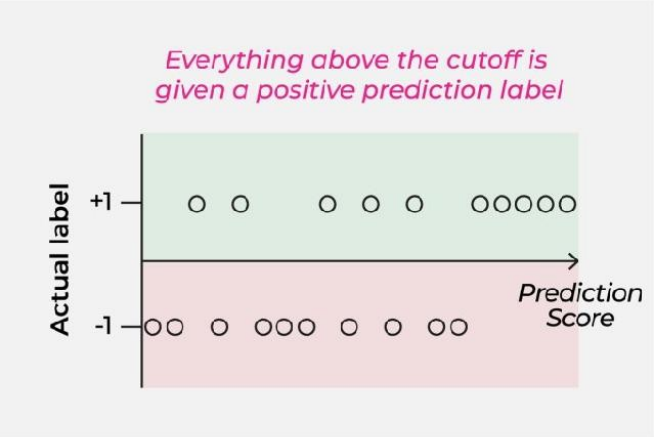
https://arize.com/blog/what-is-auc/

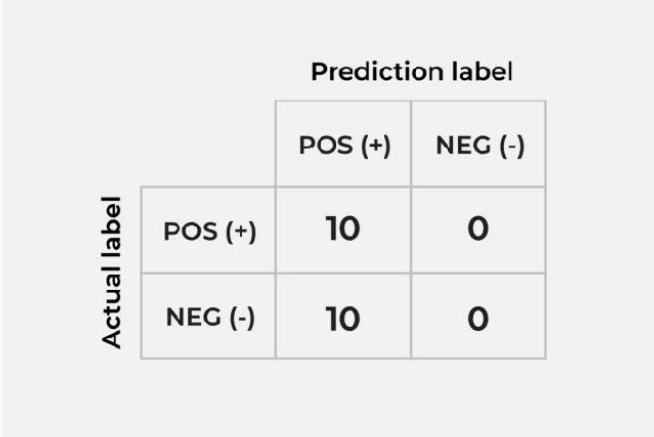
Метрика ROC-AUC

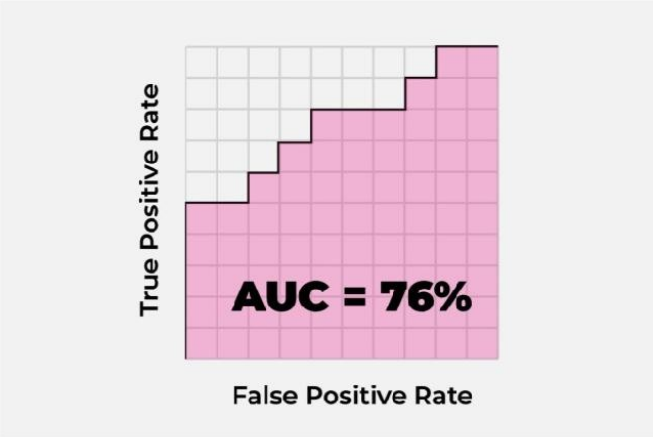
education

True Positive Rate: 10/10

False Positive Rate: 10/10



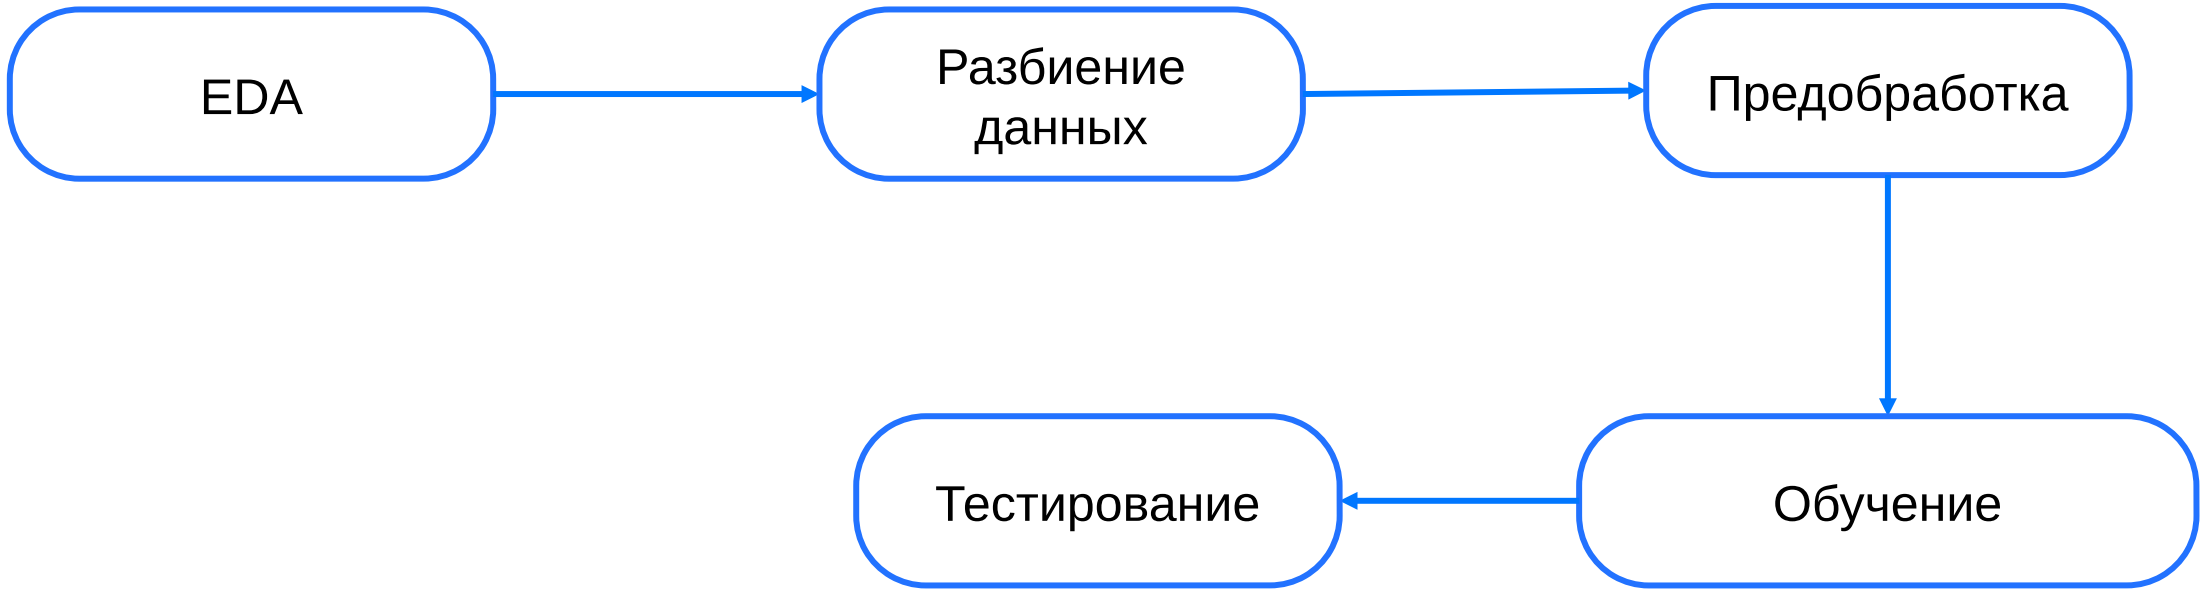




https://arize.com/blog/what-is-auc/

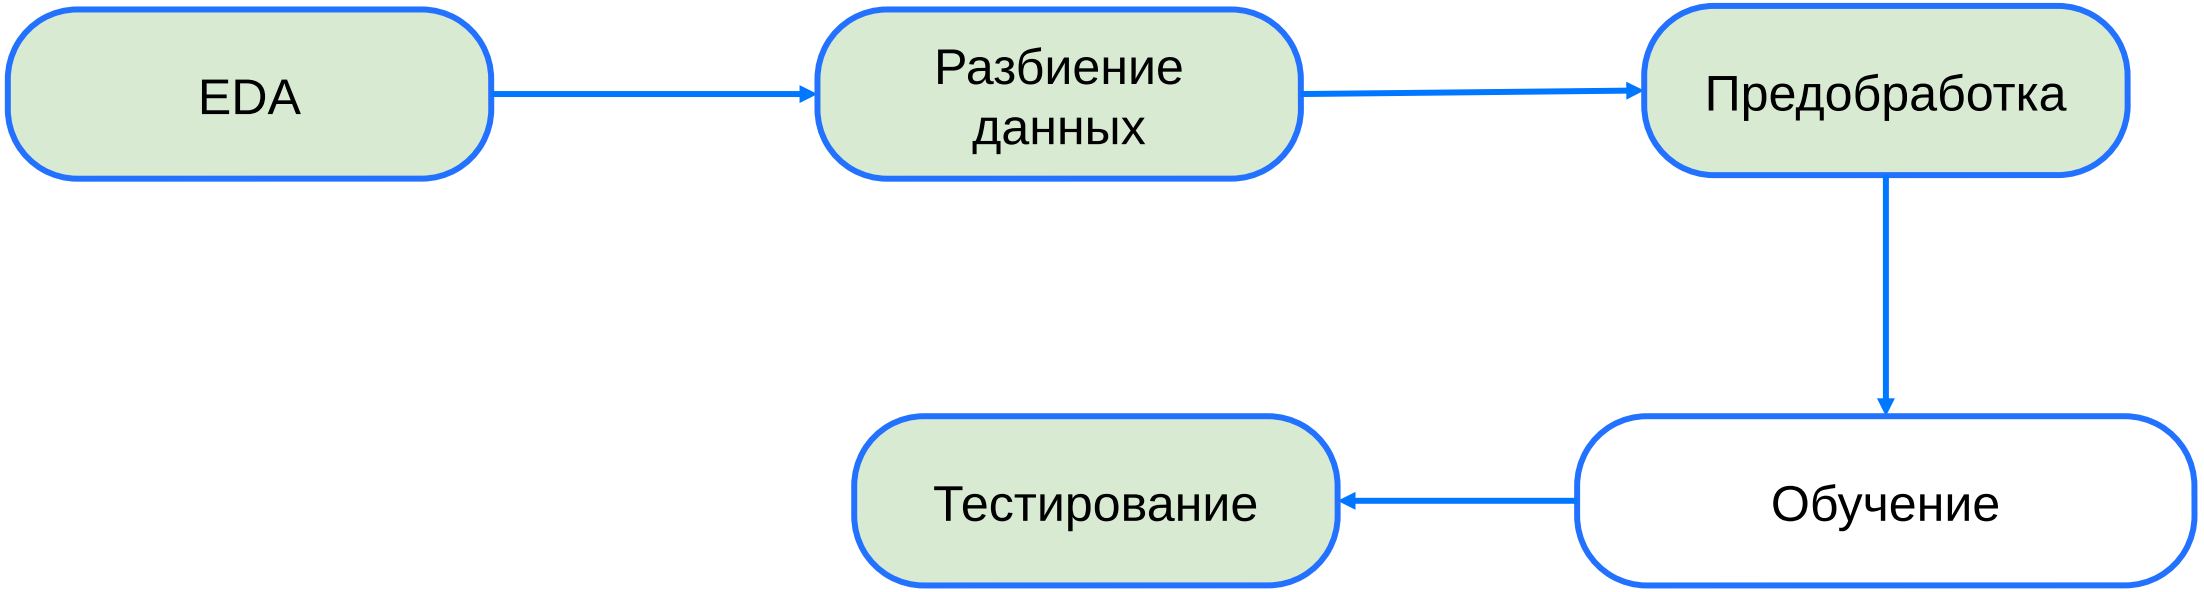
Последовательность действий

education



Последовательность действий

education



Ваши вопросы

Слайд для вашего отзыва ;)



Поставьте ~~хорошую~~
Оценку, пожалуйста

Спасибо за внимание

education

Домашнее задание

education