




Контролируемое машинное обучение



Мини-квиз: если contest считает MAE, зачем смотреть RMSE и MAPE?

Связь с прошлым занятием

Contest ранжирует по MAE — её и оптимизируем при сравнении решений.

RMSE подсвечивает крупные промахи, MAPE — относительную ошибку: это диагностика, а не замена контракту.

Сегодня на занятии



1

Регрессия: задача и метрики

2

Линейная модель и обучение

3

Регуляризация и нелинейность

4

Классификация


5

All Cups baseline

Регрессия: от у до ошибки

раздел

1



Задача регрессии начинается с контракта

$X \rightarrow y$



Регрессия предсказывает непрерывный target y : цену, спрос, время или риск.

Сначала фиксируем объект, момент прогноза и доступные признаки.

Тип регрессии — это предположение о данных

- Линейная
- $\hat{y} = w_0 + w^T x$

- Полиномиальная
- Линейна по весам, нелинейна по x

- Робастная
- Уменьшает влияние выбросов

- Практический выбор
- Сравниваем на одной validation

Честный regression-эксперимент

1	Определить объект, y и момент прогноза	что предсказываем ?
2	Разделить прошлое и будущее	когда узнаём ответ?
3	Зафиксировать метрику и baseline	как считаем ошибку?

Пять метрик — пять разных вопросов


MSE / RMSE сильнее штрафуют большие ошибки; MAE устойчивее к выбросам.

R^2 сравнивает с прогнозом среднего, MAPE даёт относительную ошибку и ломается около нуля.

Линейная регрессия: как учится

раздел

2



Линейная регрессия + OLS дают прозрачный baseline

$\hat{y} = w_0 + Xw$. Метод наименьших квадратов выбирает веса с минимальной $\sum (y - \hat{y})^2$.

MSE — та же цель, делённая на n ; коэффициенты интерпретируем только вместе с масштабом и предположениями.

Градиентный спуск: $w \leftarrow w - \eta \nabla L$

- Batch GD
- Точный gradient по всему train

- Stochastic GD
- Шумный шаг по одному объекту

- Mini-batch
- Баланс скорости и шума

- Контроль
- Scale, learning rate, stopping

От вероятностной модели к loss

Предположение

$$y = \hat{y} + \varepsilon, \varepsilon \sim N(0, \sigma^2)$$

Максимизируем
likelihood


Следствие

$$-\log L \propto \sum (y - \hat{y})^2$$

получаем OLS / MSE

Регуляризация ограничивает сложность


- L2 / Ridge: плавно сжимает веса и стабилизирует коррелированные признаки.
- L1 / Lasso: может занулять коэффициенты и выбирать признаки.
- Стандартизируйте признаки; силу penalty выбирайте только по validation.



Нелинейность и честная validation

раздел

3



Полиномиальная регрессия за три шага



1

Создать x^2 , x^3 и interactions

нелинейность

2

Обучить Ridge / Lasso

контроль весов

3

Выбрать степень по validation

ошибка на
НОВЫХ ДАННЫХ

Train и validation диагностируют СЛОЖНОСТЬ

- Underfit
- Высока train- и validation-ошибка

- Overfit
- Train хорош, validation ухудшается

- Баланс
- Минимум validation-ошибки

- Решение
- Признаки, penalty, степень, данные

Валидация должна повторять будущее



All Sips делит данные по времени: train 2011–2012, test продолжается до 2013.
Случайный split зависит качество.

Препроцессинг обучаем только на train; финальный fit делаем после фиксации протокола.

All Cups baseline: MAE ниже на 57%


На последнем 20% train: Dummy MAE 2,81 млн; Linear 1,20 млн; Ridge 1,20 млн.

Это baseline, а не потолок: следующий шаг — признаки даты и локации на том же time split.

Классификация: score $\rightarrow$ решение

раздел

4



Классификатор оценивает score; threshold превращает его в класс

- Задача
- $\hat{y} \in \{0,1\}$ или класс 1...K


- Logistic
- $p(y=1|x)=\sigma(w^T x)$

- Softmax
- K вероятностей, сумма = 1


- Решение
- Порог зависит от цены ошибок

Logistic и Softmax: один принцип

Binary




Multiclass



MLE связывает вероятности и loss

- 1. Logistic regression — MLE для Bernoulli + log-loss
- 2. Softmax — MLE для categorical target
- 3. Вероятность требует calibration;
класс — выбранного порога



Метрики классификации

1

Accuracy: доля верных ответов

2

Precision: точность положительных прогнозов

3

Recall: доля найденных положительных

4


F1: баланс precision и recall

5

ROC-AUC: качество ранжирования

Байесовская классификация

- $P(y=k|x) \propto P(x|y=k)P(y=k)$
- Prior — частота класса; likelihood — признаки.
- Naïve Bayes: быстрый baseline; признаки условно независимы.



ДЗ 4: предсказание цен на недвижимость

All Cups: предсказать price для 100 000 объектов; метрика MAE, $\text{score} = 1/(1+\text{MAE})$.

Минимум: запустить `baseline_regression.ipynb` и сдать CSV строго `id,price`.

Объяснить: `split`, выбранную метрику и одно улучшение baseline.

Проверить: `instructor/validate_submission.py`.

Домашнее задание Регрессия: цены на недвижимость

