Контролируемое обучение

education

Признаки → прогноз → проверка

Цена квартиры — число. Наличие дефекта — класс.

После объяснения: рабочий baseline и один самостоятельный эксперимент.

Цена квартиры по признакам

education

Объект: объявление

Площадь: 60 м²

Комнаты: 2

Район и дата объявления

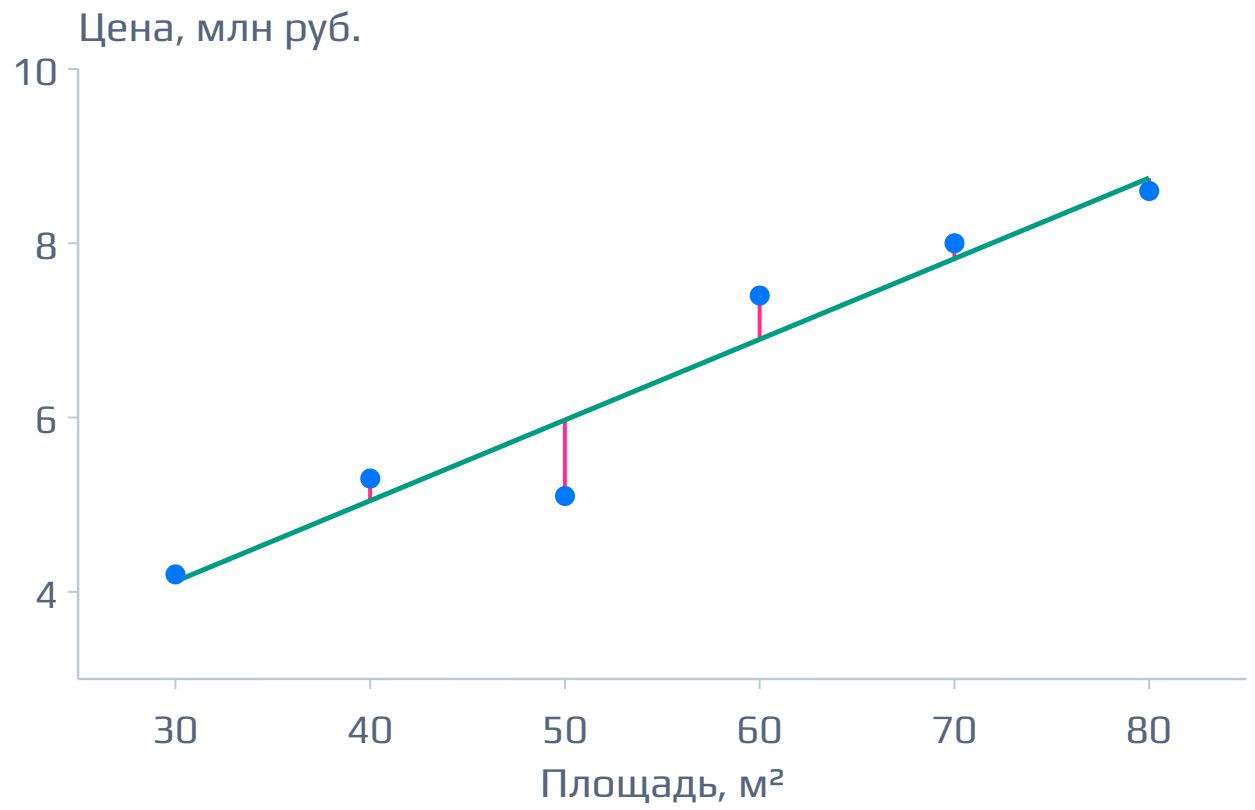
Модель

Прогноз цены

$$\hat{y}_i = w_0 + \mathbf{w}^\mathsf{T}\mathbf{x}_i$$

Сначала определяем объект, target и доступные признаки — затем выбираем модель.

Линейная модель и ошибки



$$e_i = y_i - \hat{y}_i$$

$$\min_{w_0, \mathbf{w}} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^{n} e_i^2$$

Розовый отрезок — ошибка для одного объявления.

Линейная модель подбирает веса так, чтобы уменьшить ошибки на train.

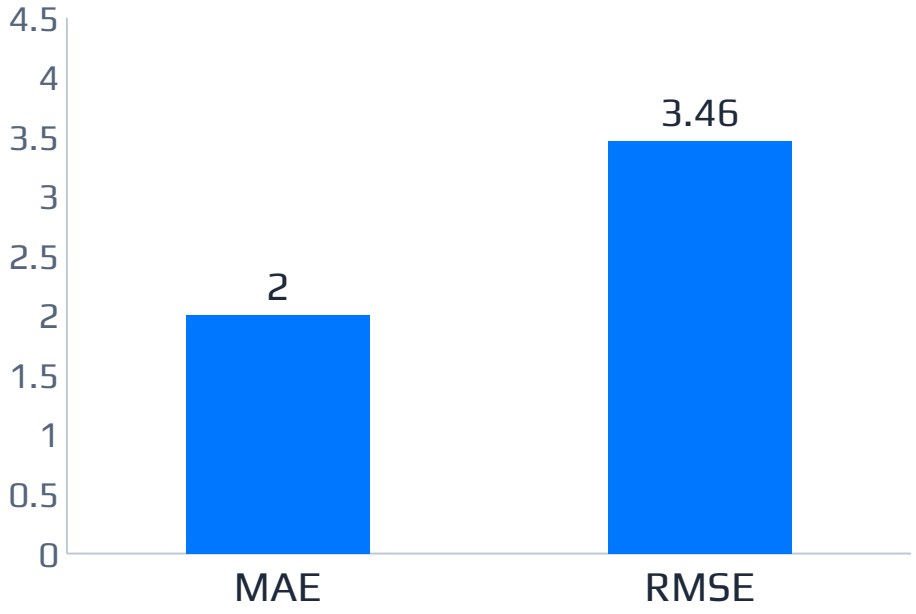
Потеря и метрика проверки

education

Ошибки: 0, 0, 6 руб.

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|e_i|$$

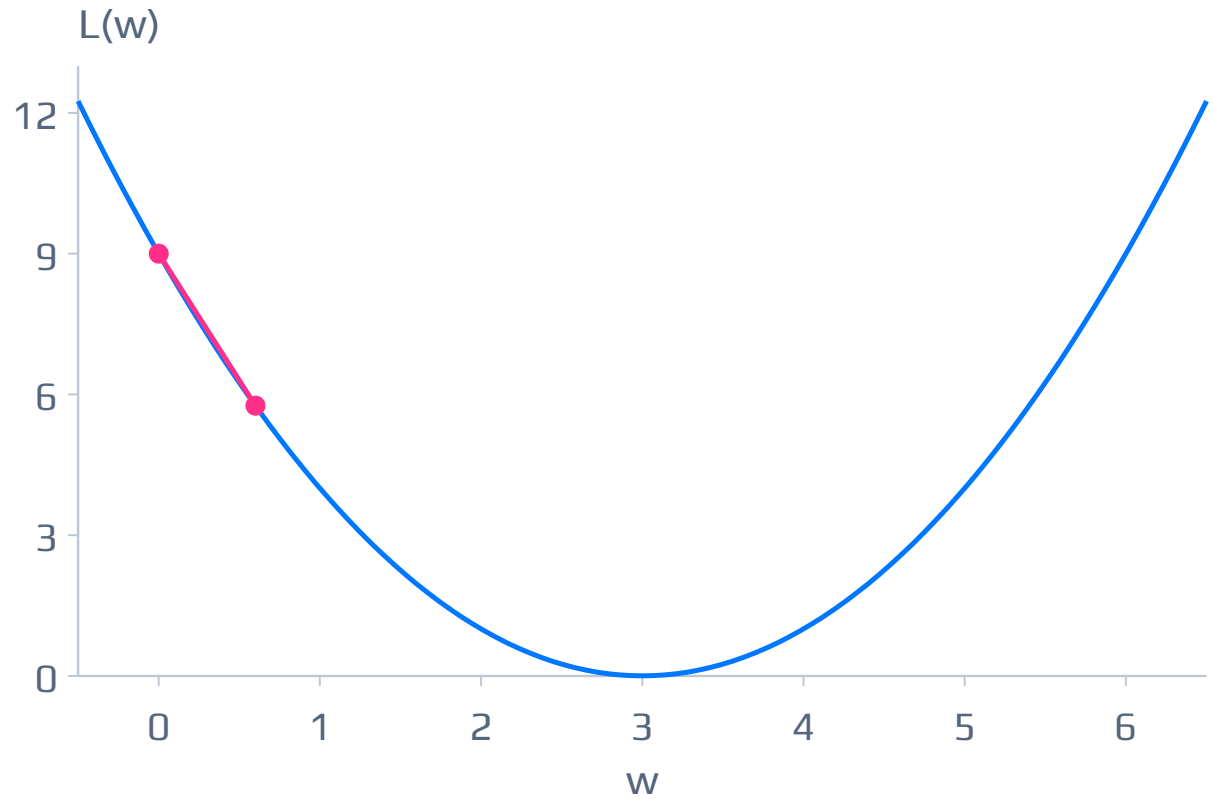
$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}e_i^2}$$



R^2 — сравнение с прогнозом среднего
MAPE — относительная ошибка

Чем учим модель и чем оцениваем результат — два отдельных решения.

Градиентный шаг



$$w^{(t+1)} = w^{(t)} - \eta L'\left(w^{(t)}\right)$$

L(w) = (w − 3)²
L′(0) = −6

$$0 - 0{,}1 \cdot (-6) = 0{,}6$$

Направление задаёт градиент, длину шага — learning rate.

Почему OLS связан с вероятностью

education

$$y_i = \hat{y}_i + \varepsilon_i, \qquad \varepsilon_i \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$$

Независимые ошибки с общей фиксированной дисперсией

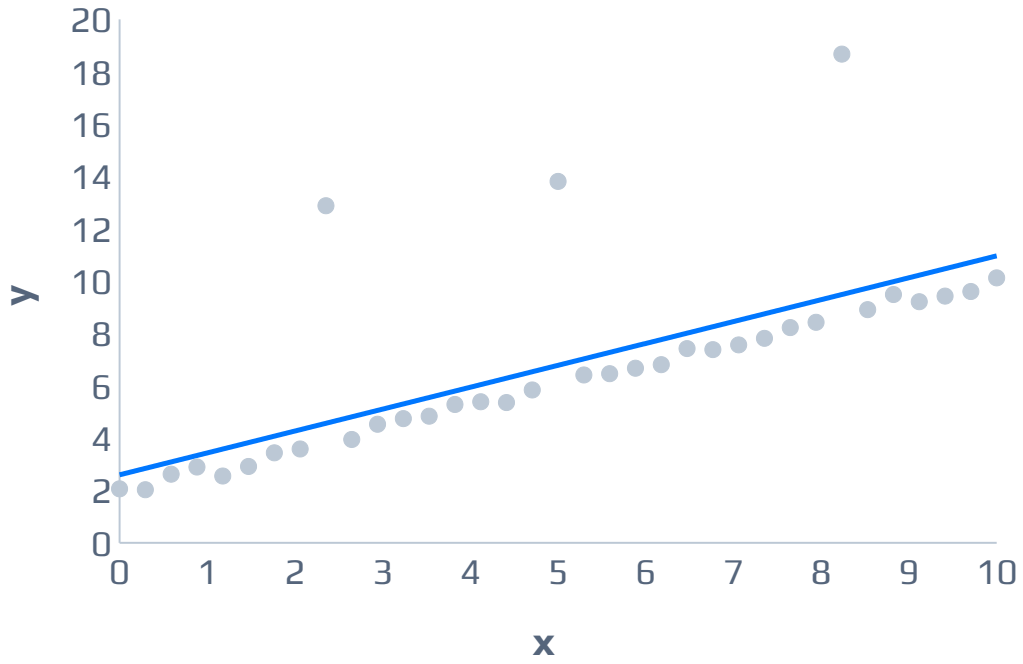
$$-\log \mathcal{L} = \text{const} + \frac{1}{2\sigma^2} \sum_{i=1}^{n} e_i^2$$

При этих предположениях максимум правдоподобия даёт минимум суммы квадратов.

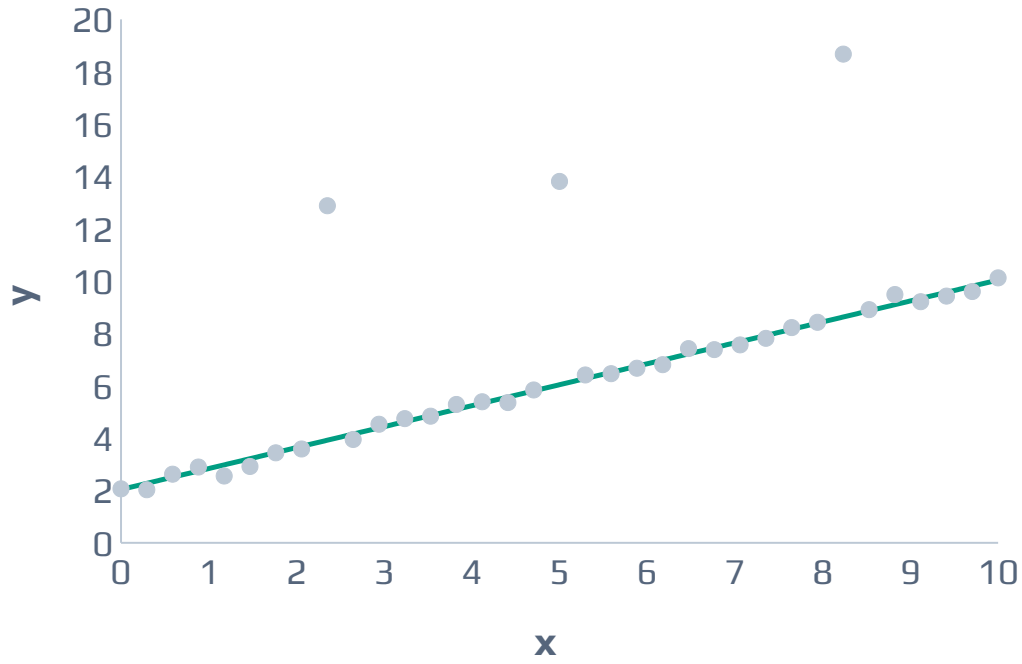
Большие ошибки и робастность

education

OLS



Huber

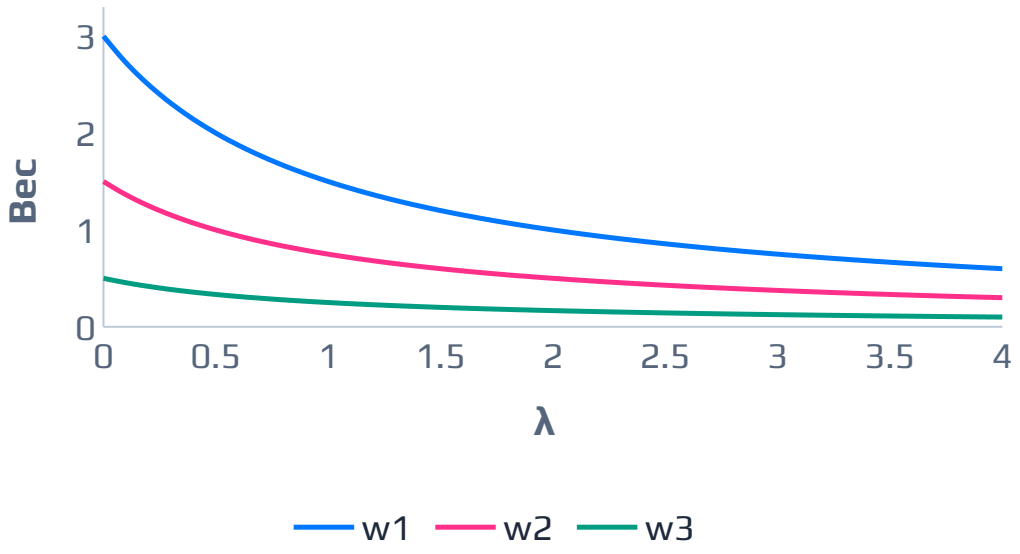


Робастная потеря может уменьшить влияние крайних ошибок на обучение.

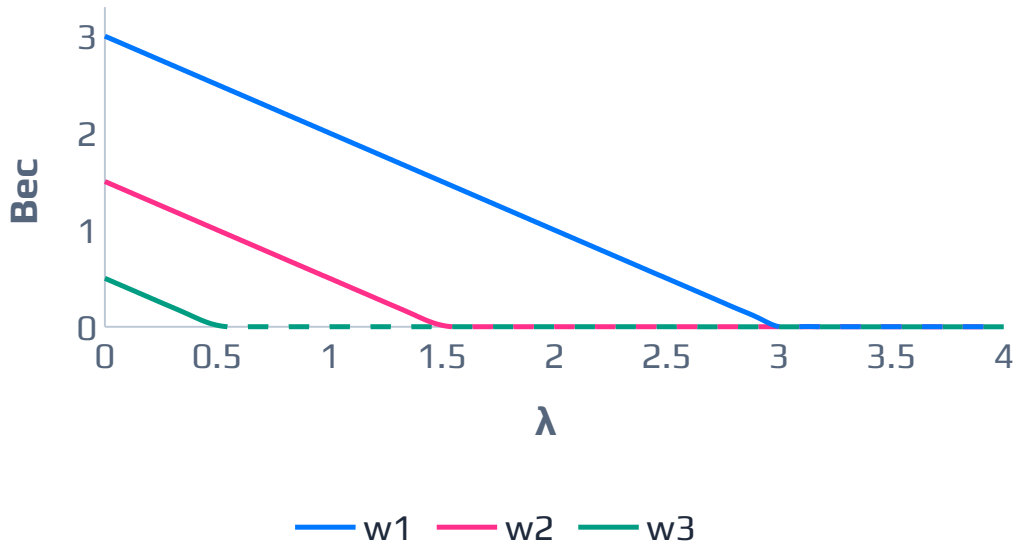
Регуляризация ограничивает веса

education

Ridge: L2



Lasso: L1



$$R_2(\mathbf{w}) = \frac{1}{2}\sum_{j=1}^{d} w_j^2$$

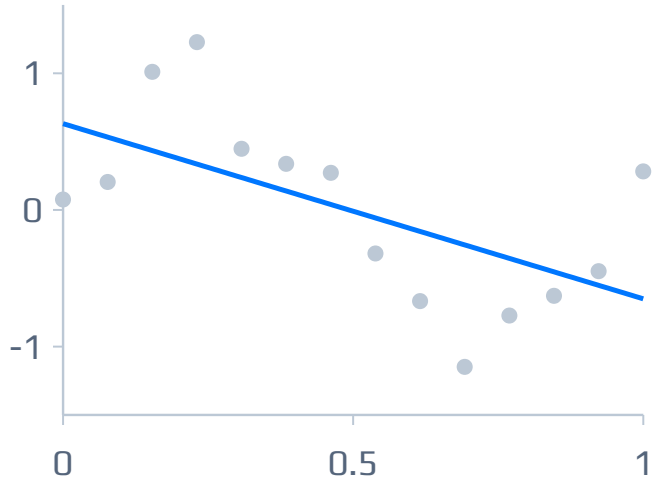
$$R_1(\mathbf{w}) = \sum_{j=1}^{d} |w_j|$$

Масштабируем признаки; силу штрафа выбираем по validation, а не по train.

Гибкость и переобучение

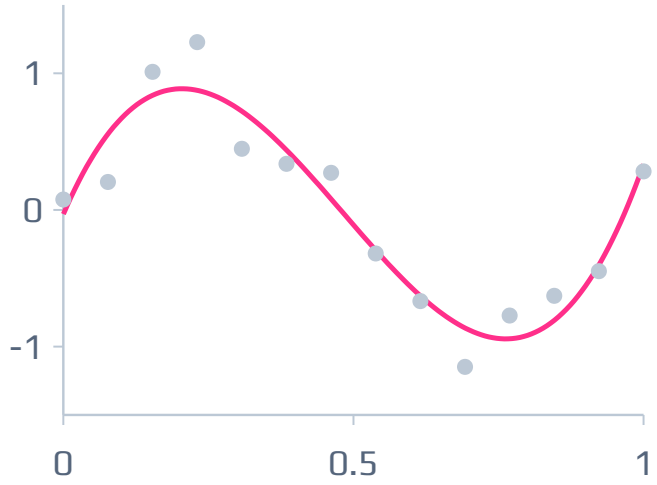
education

Степень 1



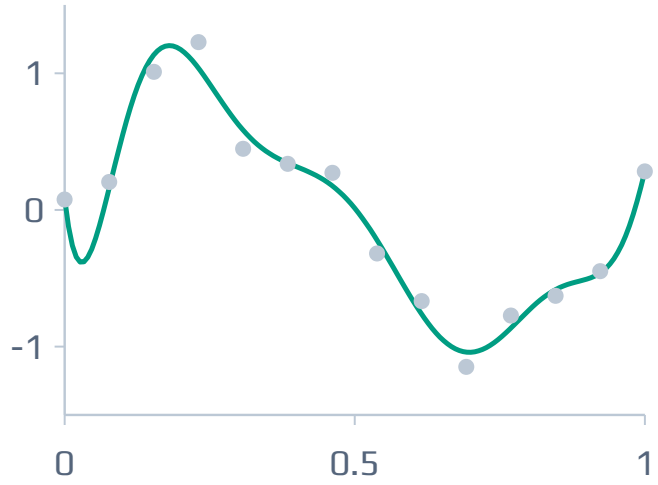
MAE train: 0.45
MAE validation: 0.42

Степень 3



MAE train: 0.17
MAE validation: 0.10

Степень 11



MAE train: 0.08
MAE validation: 0.17

Сложность выбираем по новым данным. Меньше ошибка train — ещё не лучше модель.

Проверка будущего прогноза

education

Ранние 80% train	Поздние 20%	Test
fit preprocessing + модель	transform + оценка	только прогноз

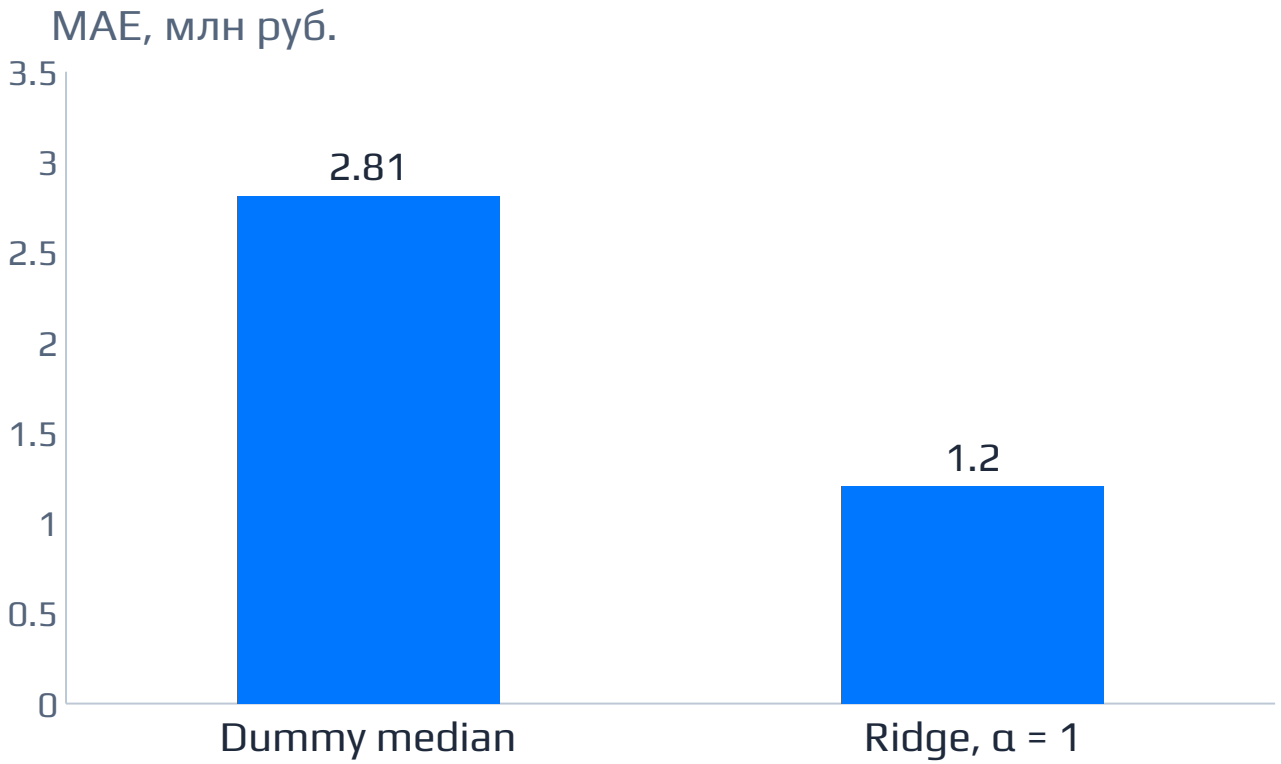
Порядок date,id →

Медианы и масштабы берём из train. Граница не обязана совпасть с месяцем.

Validation изображает будущие данные и не участвует в fit преобразований.

Старт для практики: Dummy и Ridge

education

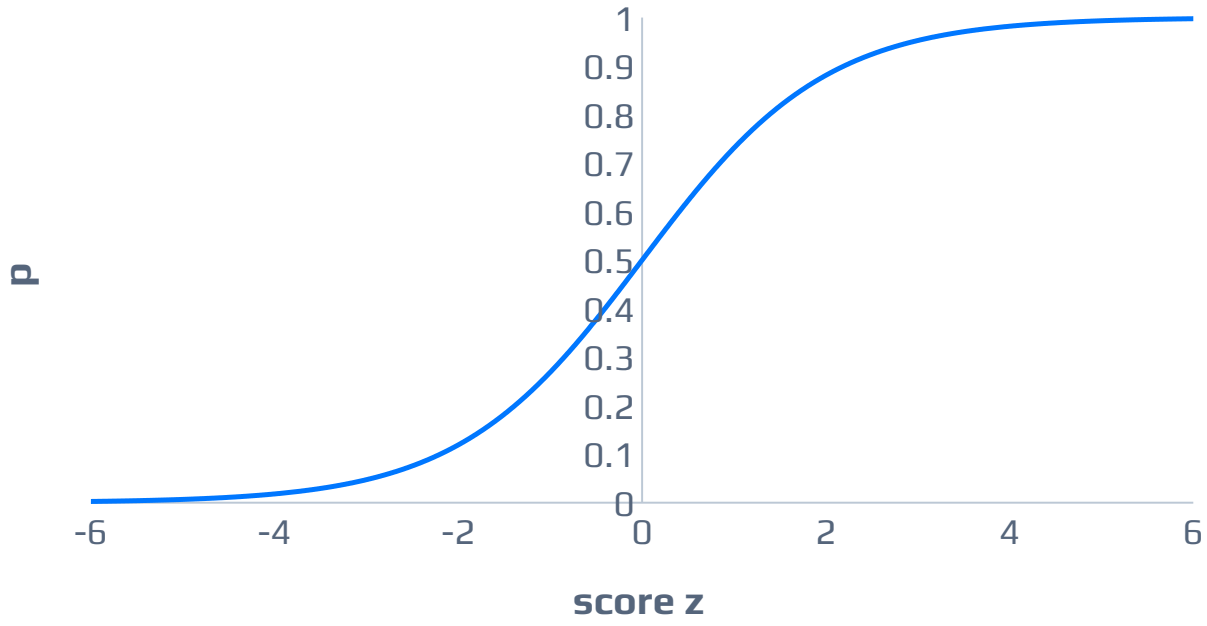


Один holdout
Одинаковый preprocessing
Одна целевая метрика

CSV: id,price

После лекции запускаем notebook; затем проверяем только α: 1 → 10.

Вероятность и решение



$$z = w_0 + \mathbf{w}^T\mathbf{x}$$

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\hat{y} = \mathbf{1}\{p \geq \tau\}$$

p = 0,7
τ = 0,5 → класс 1
τ = 0,8 → класс 0

Признаки → score → p → класс

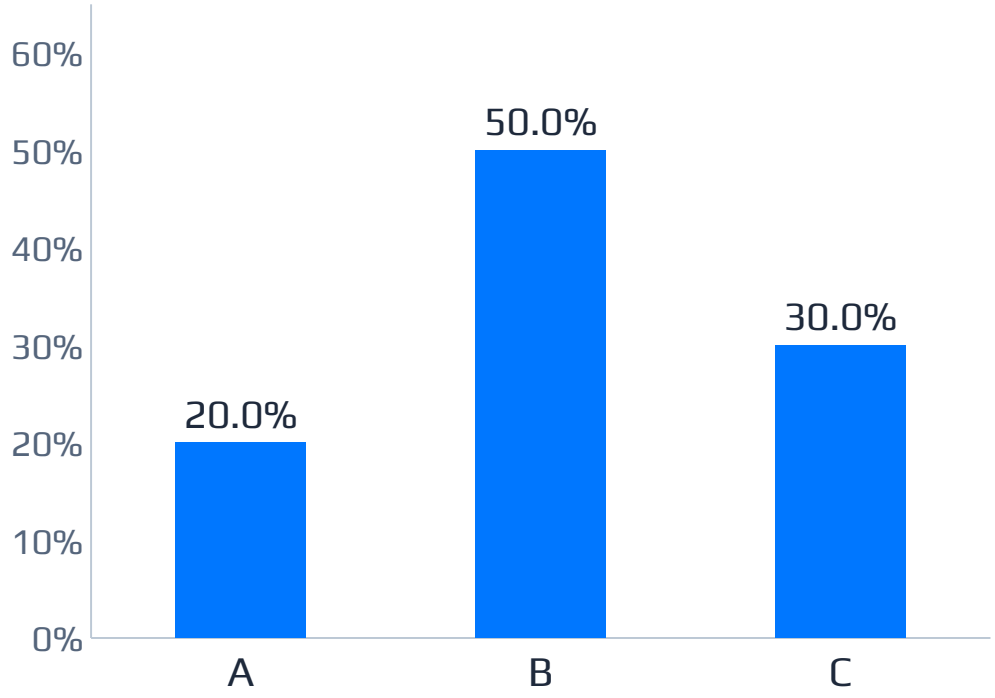
Модель оценивает вероятность; порог превращает её в решение.

Несколько классов: softmax

education

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}$$

Сумма вероятностей = 1
Выбираем максимальную



Классификация предсказывает класс; регрессия — числовое значение.

Что именно проверяет метрика

education

Precision

Какая доля найденного брака реальна?

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall

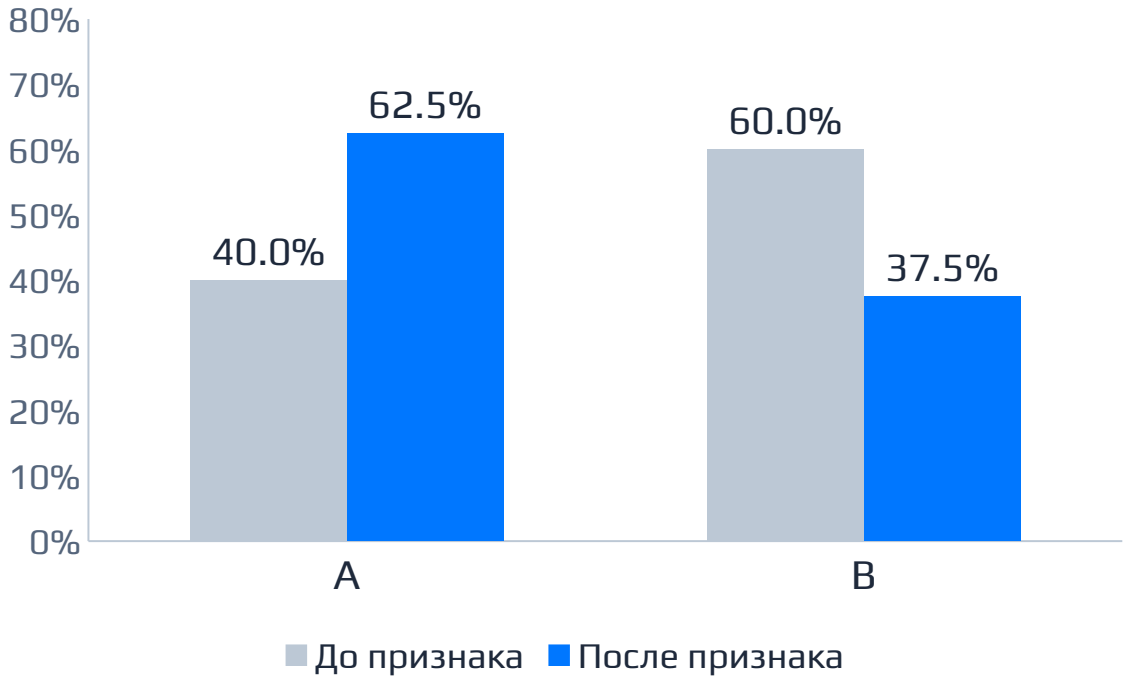
Какую долю всего брака обнаружили?

$$\text{Recall} = \frac{TP}{TP + FN}$$

Accuracy — доля верных · F1 — баланс P и R · ROC-AUC — ранжирование score

Метрика должна отвечать на вопрос задачи, особенно при редком браке.

Байес: обновляем вероятности



$$P(k \mid x) = \frac{P(x \mid k)P(k)}{\sum_j P(x \mid j)P(j)}$$

$$P(A \mid x) = \frac{0{,}5 \cdot 0{,}4}{0{,}5 \cdot 0{,}4 + 0{,}2 \cdot 0{,}6} = 0{,}625$$

Naive Bayes: условная независимость признаков внутри класса.

Дальше — практика: baseline → CSV → одно изменение → объяснение результата.

Справочно: формулы регрессии

education

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|e_i|$$

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}e_i^2$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}e_i^2}$$

$$R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2}$$

$$\mathrm{MAPE} = \frac{1}{n}\sum_{i}\frac{|e_i|}{|y_i|}$$

MAE/RMSE — единицы target; MSE — квадрат единиц; R^2 и MAPE — безразмерные.

Справочно: цель и регуляризация

education

$$J_\lambda = \frac{1}{2n}\sum_i e_i^2 + \lambda R(\mathbf{w})$$

$$R_1(\mathbf{w}) = \sum_{j=1}^{d} |w_j|$$

$$R_2(\mathbf{w}) = \frac{1}{2}\sum_{j=1}^{d} w_j^2$$

Пути весов: ортогональные стандартизованные признаки
Ridge: alpha = nλ · Lasso: alpha = λ

Параметры разных реализаций сравниваем с учётом нормировки функции потерь.

Справочно: правдоподобие и OLS

education

$$y_i = \hat{y}_i + \varepsilon_i, \qquad \varepsilon_i \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$$

$$-\log \mathcal{L} = \text{const} + \frac{1}{2\sigma^2} \sum_{i=1}^{n} e_i^2$$

$$\min_{w_0, \mathbf{w}} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

Вывод использует предположения об ошибках, а не нормальность признаков.

Справочно: метрики классификации

education

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$F_1 = \frac{2PR}{P + R}$$

ROC-AUC оценивает порядок scores по классам.
Порог выбирается отдельно под стоимость ошибок.