education

Контролируемое машинное обучение

Метрика задачи

education

Почему для цены квартиры удобно измерять ошибку в рублях?

MAE отвечает на этот вопрос. RMSE помогает увидеть крупные промахи.

Задача регрессии

education

Объект	Площадь м²	Комнаты	Цена млн руб.
Квартира A	40	1	6
Квартира B	60	2	9
Квартира C	80	3	12

Учебный пример. X — признаки объявления, y — цена.

Модели регрессии

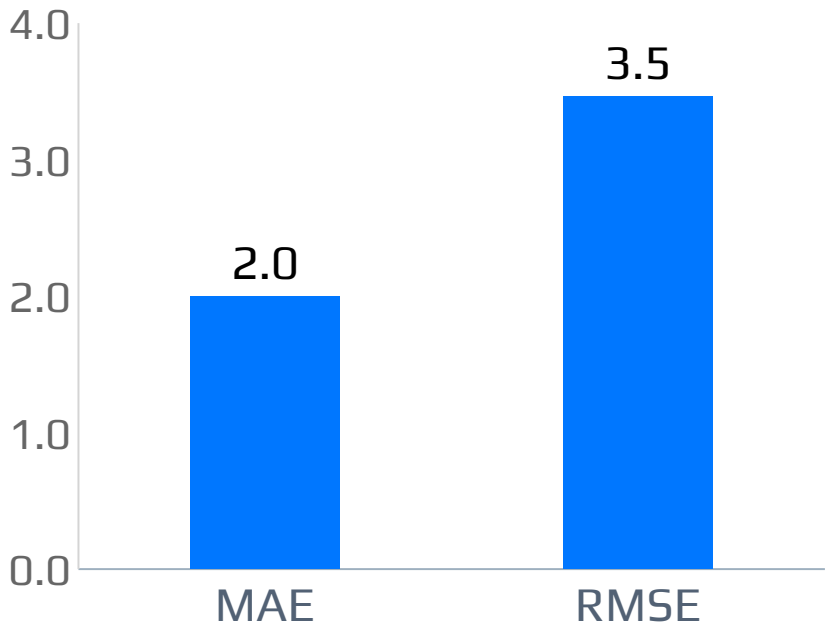
education

Модель	**Предположение или задача**
Линейная	$\hat{y} = w_0 + w_1 x$
Полиномиальная	$\hat{y} = w_0 + w_1 x + w_2 x^2$
Робастная	Снижает влияние крайних ошибок

Сравнение моделей требует одного и того же validation.

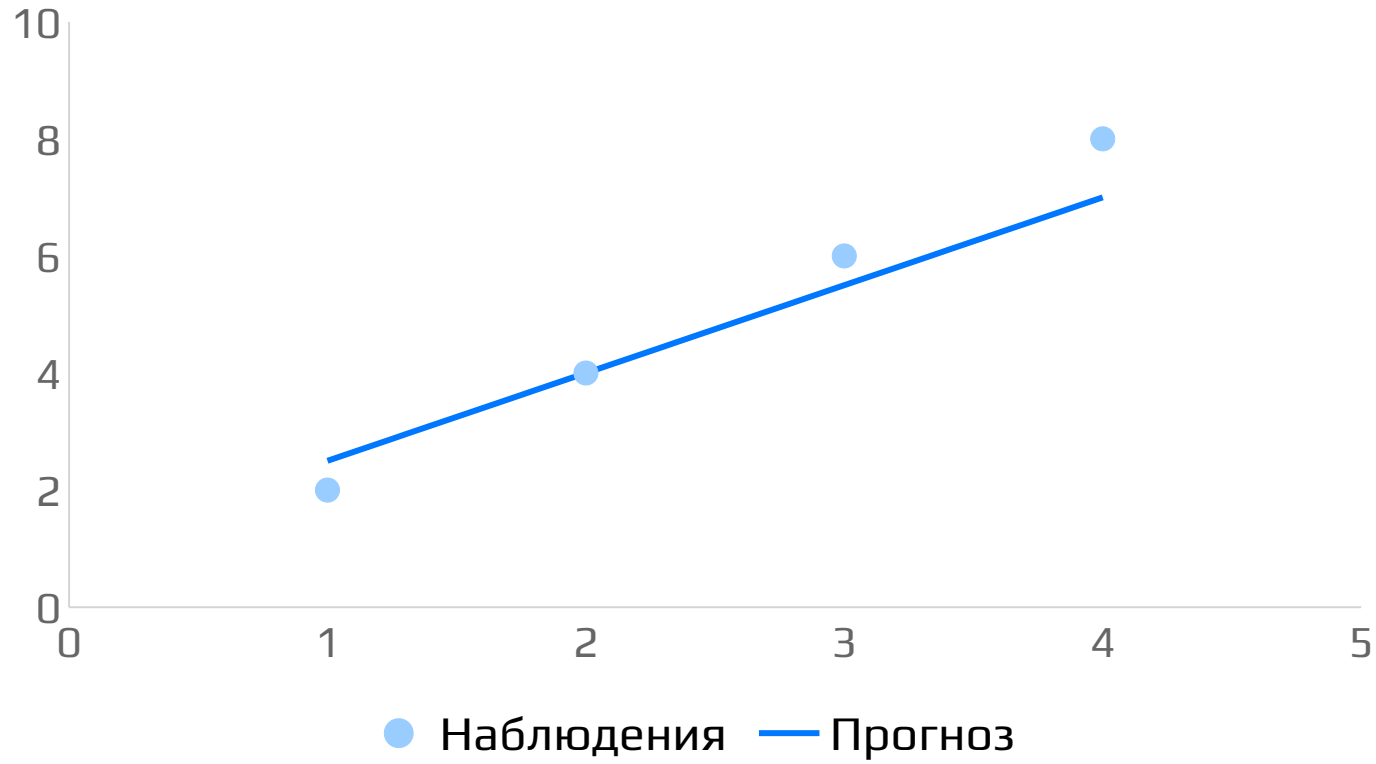
Метрики регрессии

Метрика	Что показывает
MAE	Среднее $\lvert y - \hat{y} \rvert$
MSE	Среднее $(y - \hat{y})^2$
RMSE	$\sqrt{MSE}$
R^2	Сравнение с прогнозом среднего
MAPE	Средняя относительная ошибка



Ошибки: 0, 0, 6 руб.

Линейная регрессия и OLS



$$\hat{y} = w_0 + w^T x$$

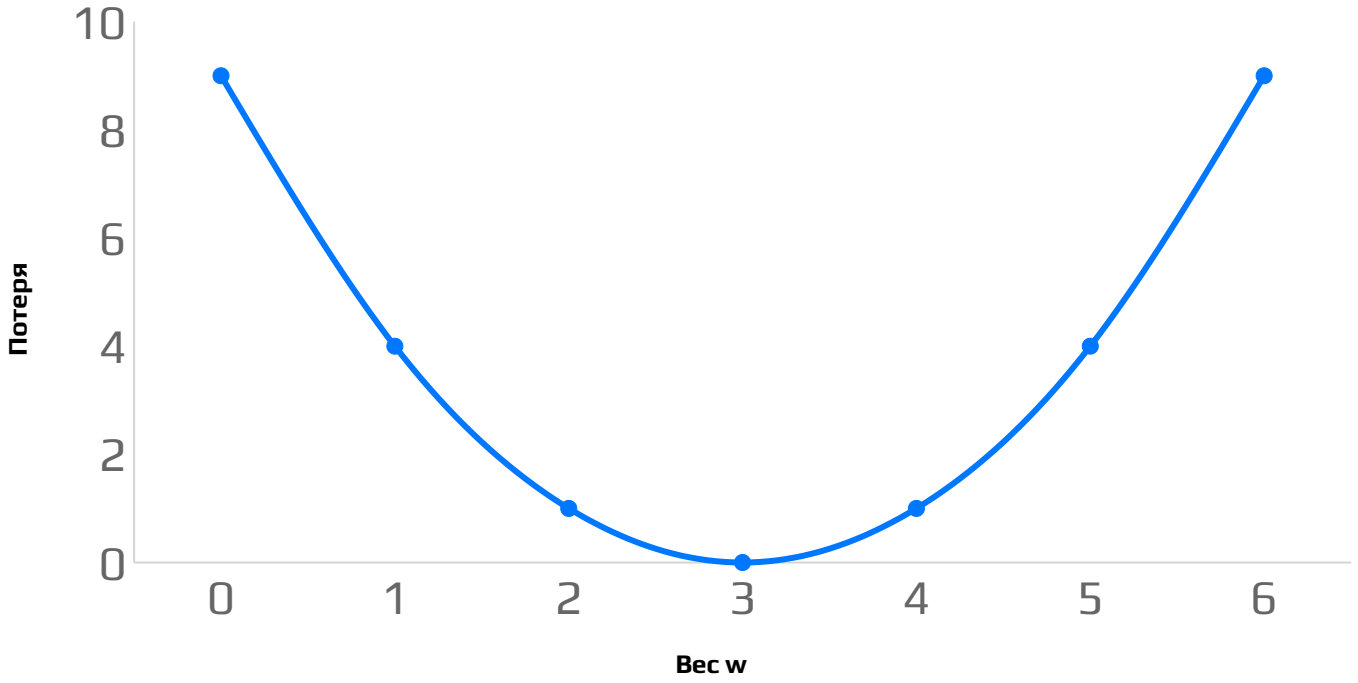
$$\text{OLS: } \min \Sigma(y - \hat{y})^2$$

$$\text{MSE} = \Sigma(y - \hat{y})^2 / n$$

Учебные данные

Градиентный спуск

education



$w_{новый} = w - \eta \nabla L$

$w = 0, \eta = 0{,}1$

$\nabla L = -6$

$w_{новый} = 0{,}6$

Batch: весь train. SGD: один объект. Mini-batch: группа объектов.

От правдоподобия к OLS

education

$$y = \hat{y} + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

Независимые ошибки с общей фиксированной дисперсией

Максимум likelihood соответствует минимуму $\Sigma(y - \hat{y})^2$

L1 и L2 регуляризация

education

Метод	Штраф на веса	Эффект
Lasso L1	$\alpha \Sigma \lvert w_j \rvert$	Может занулять веса
Ridge L2	$\alpha \Sigma w_j^2$	Сжимает веса

Признаки масштабируем. Силу штрафа выбираем по validation.

Полиномиальные признаки

education

x	x^2	x^3
1	1	1
2	4	8
3	9	27

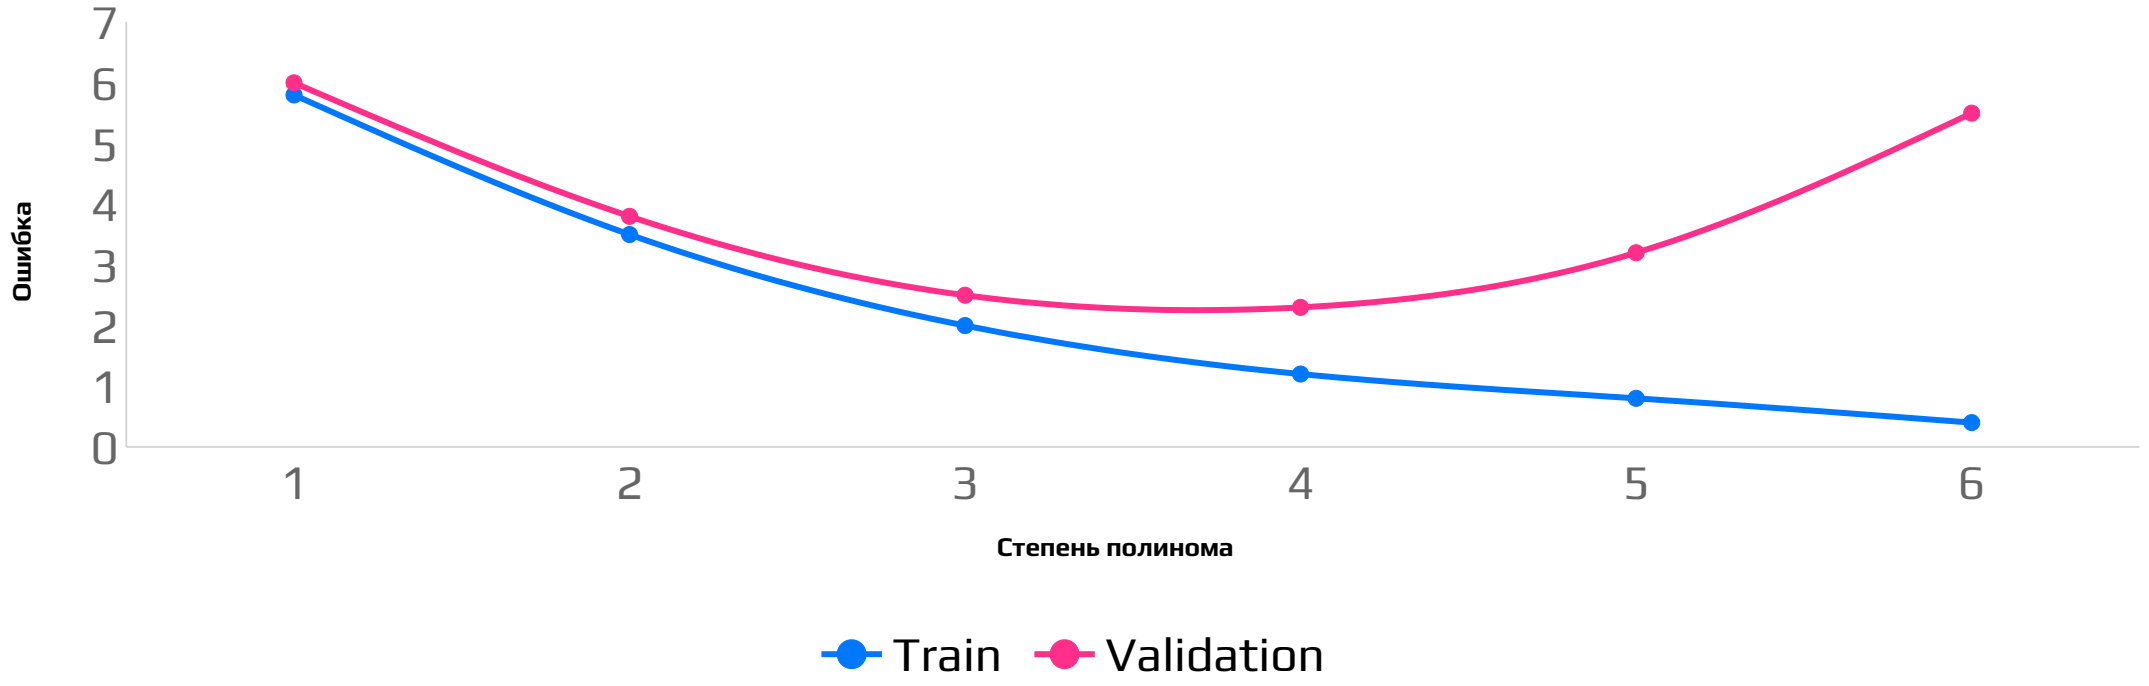
$$\hat{y} = w_0 + w_1 x + w_2 x^2$$

Степень задаёт гибкость.
Регуляризация ограничивает веса.

Выбор степени требует проверки на новых данных.

Переобучение и недообучение

education



Схематичный пример. Выбор сложности опирается на validation.

Валидация по времени

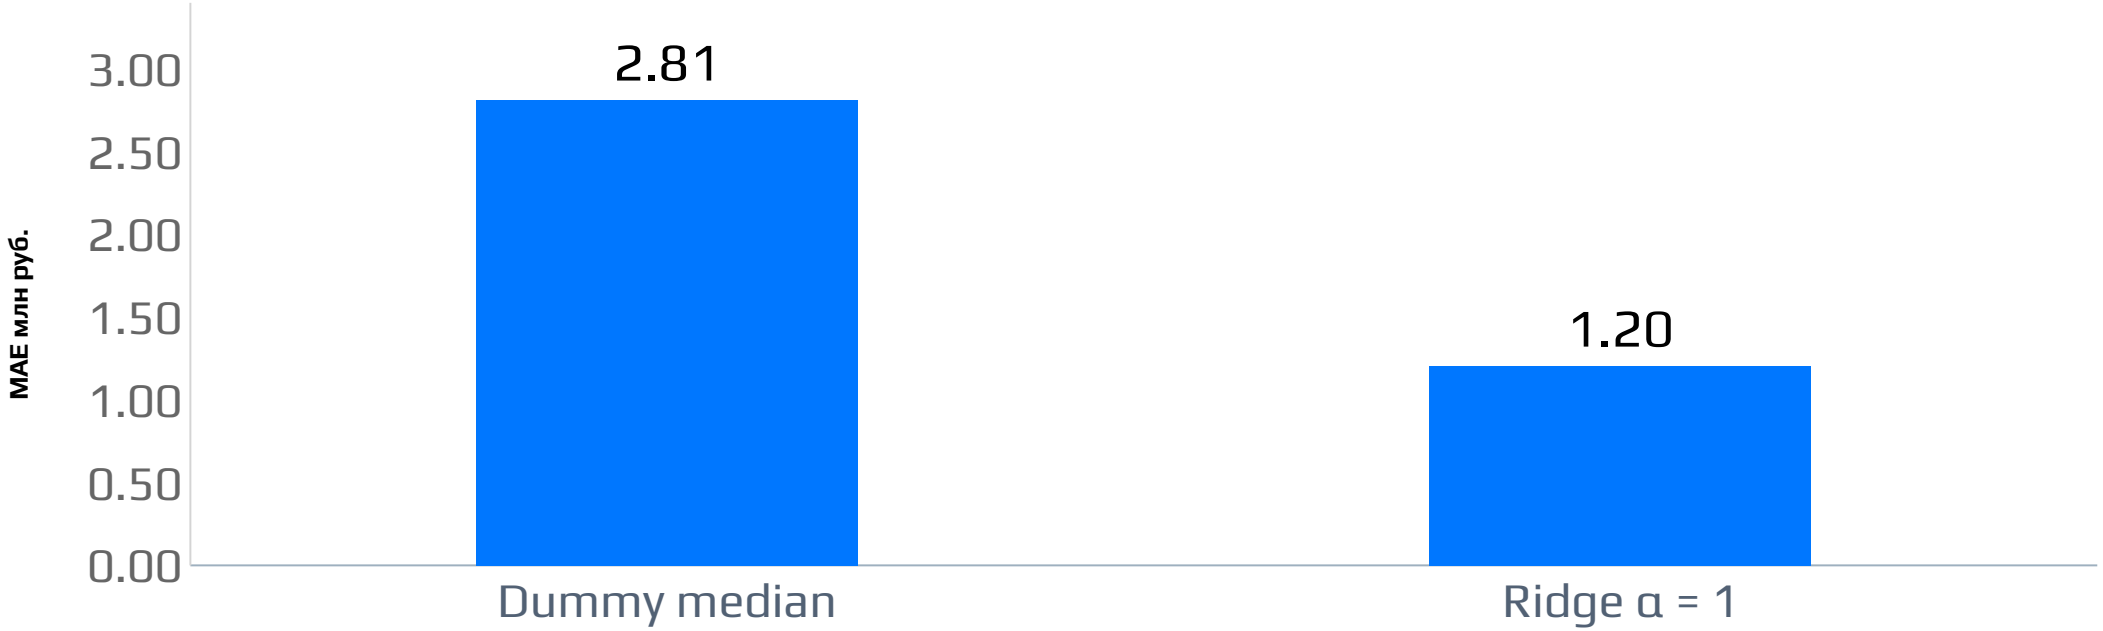
education

Часть данных	Использование
Ранние 80% train	Обучение модели и preprocessing
Последние 20% train	Оценка локальной ошибки
Более поздний test	Прогноз для отправки

Медианы и масштабы учим на train. Validation только преобразуем.

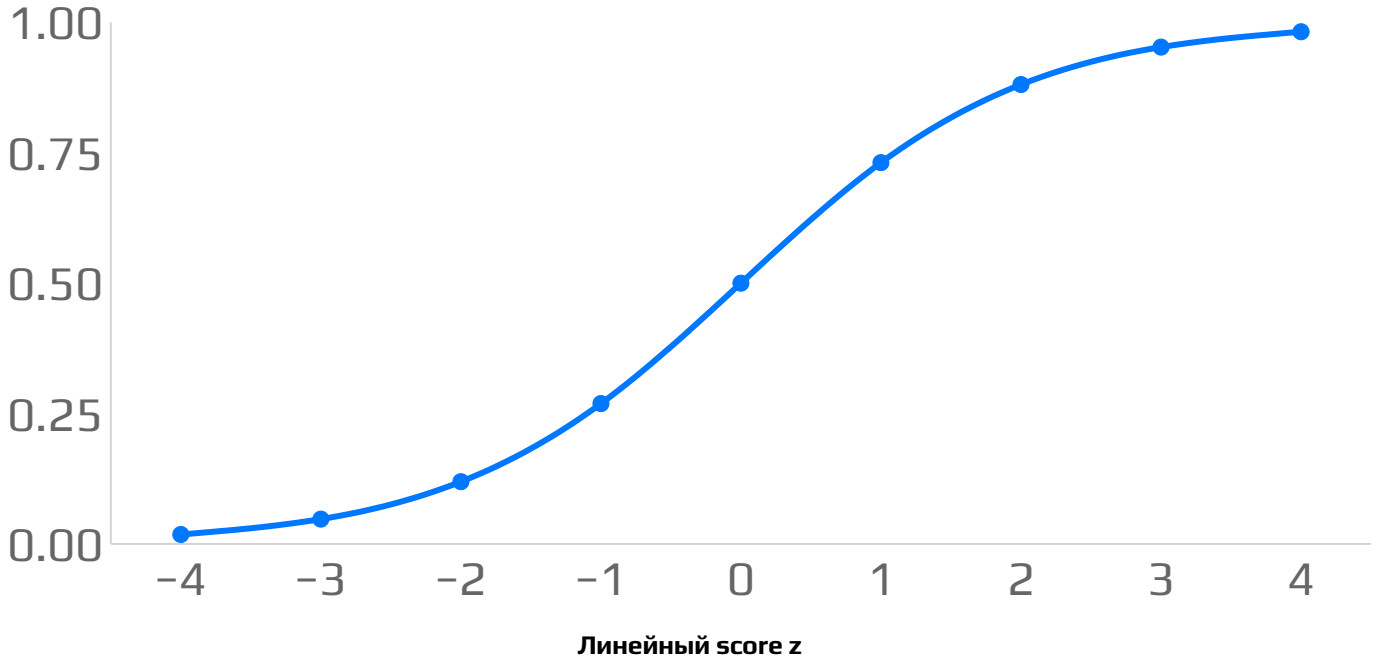
Baseline регрессии

education



Последние 20% train. Это локальный holdout, оценку All Cups получаем отдельно.

Логистическая регрессия



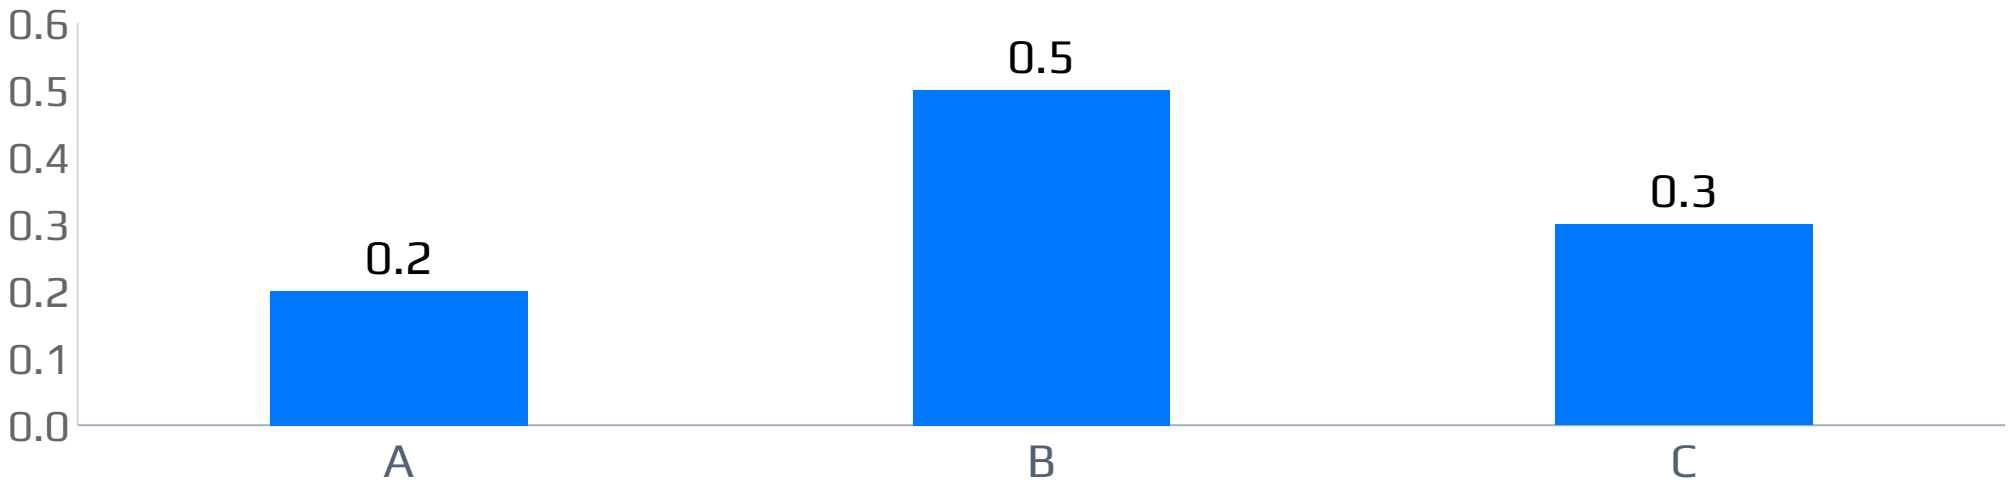
$p = \sigma(w^T x + w_0)$

При p = 0,7
порог 0,5: класс 1
порог 0,8: класс 0

Softmax

education

$$p_k = \exp(z_k) / \Sigma_j \exp(z_j)$$



Сумма вероятностей равна 1. Максимальная вероятность у класса B.

Метрики классификации

education

Метрика	Вопрос
Accuracy	Какая доля всех решений верна?
Precision	Какая доля найденного брака реальна?
Recall	Какую долю всего брака нашли?
F1	Как сбалансированы precision и recall?
ROC-AUC	Как модель ранжирует классы по score?

Байесовская классификация

education

$$P(y = k \mid x) \propto P(x \mid y = k) \cdot P(y = k)$$

Класс	Prior	Likelihood	Произведение
A	0,5	0,8	0,4
B	0,5	0,2	0,1

Naive Bayes предполагает условную независимость признаков внутри класса.

Практика регрессии

education

Шаг	Результат
Временное разбиение	Обучение на ранних объявлениях
Dummy и Ridge	Сравнение MAE на одном holdout
Финальное обучение	Прогноз цены для test
Файл CSV	Столбцы id,price без индекса

Самостоятельно: изменить α с 1 на 10 и проверить ту же validation.