




Неконтролируемое машинное обучение



Связь с прошлым занятием



Мини-квиз: **silhouette** растёт с **k** — значит, большее **k** всегда лучше?

Нет: silhouette оценивает геометрию, но не смысл кластеров.

Нужны устойчивость, интерпретация и внешний критерий — в contest это ARI по скрытым labels.

Сегодня на занятия



1

Геометрия и задача без y

2

Алгоритмы кластеризации

3

Многомерное шкалирование

4

Ассоциативные правила


5

All Cups baseline

Геометрия и задача без target

раздел

1



Критерий успеха проектирует человек



Без target алгоритм оптимизирует выбранную нами структуру: расстояние, плотность, граф или совместное появление.

Поэтому representation и критерий проверки входят в постановку задачи.

Unsupervised-методы отвечают на разные вопросы



- Кластеризация
- Разбить объекты на группы

- MDS
- Сохранить pairwise distances

- Ассоциативные правила
- Найти частые совместные события

- Представление
- Определить, что значит «похожи»

Как поставить задачу без y

1

Определить объект и доступные признаки

что
сравниваем?

2

Выбрать representation и similarity

что значит
близко?

3

Назначить проверку устойчивости и пользы

зачем
результат?

Геометрия данных — часть решения




Масштаб, пропуски и выбросы меняют расстояния; в sparse data важен выбор Euclidean или cosine geometry.

Preprocessing — часть модели, поэтому его фиксируют и проверяют вместе с алгоритмом.

Кластеризация: разные предположения

раздел

2



К-means — сильный baseline, если подходят предположения

К-means минимизирует inertia: сумму квадратов расстояний до ближайших центров.

Он ожидает компактные кластеры похожего масштаба, чувствителен к scale и требует заранее выбрать k .

К-means повторяет два шага

Инициализация

Выбираем k центров:
лучше k-means++

assign: ближайший
центр

Итерации

update: среднее
внутри кластера

до стабилизации
inertia

Алгоритм выбирают под форму структуры

- Иерархическая
- Дендрограмма и уровни

- Спектральная
- Граф близости и нелинейные формы

- DBSCAN
- Плотность, шум, один масштаб ϵ

- HDBSCAN
- Иерархия плотностей, variable density


Silhouette — внутренний диагностический сигнал

Silhouette сравнивает близость объекта к своему кластеру и соседнему: диапазон от -1 до 1 .

Высокое значение полезно, но не доказывает смысл, устойчивость или совпадение со скрытыми labels.

Как оценивать кластеры


- 1. Internal: silhouette, Davies–Bouldin, inertia
- 2. External: ARI / NMI, если есть reference labels
- 3. Stability: seeds, подвыборки, bootstrap
- 4. Profiling: размеры и отличительные признаки



MDS и ассоциативные правила

раздел

3



Многомерное шкалирование сохраняет геометрию

MDS строит координаты так, чтобы расстояния между точками были близки исходным dissimilarities.

В отличие от PCA, цель — сохранить расстояния; качество описывает stress.

MDS за три шага

1

Построить матрицу dissimilarities

метрика
близости

2

Выбрать 2–3 измерения и минимизировать stress

координаты

3

Проверить stress и интерпретировать карту

не причинная
карта

Ассоциативные правила ищут совместные события

Транзакция — множество items; правило $X \rightarrow Y$ говорит, что Y часто встречается вместе с X .

Правило описывает совместность, а не причинность; X и Y должны быть непересекающимися.

Три метрики отсекают случайные правила

- Support
- $P(X \cup Y)$: насколько правило часто

- Confidence
- $P(Y|X)$: как часто срабатывает

- Lift
- $\text{confidence} / P(Y)$: выше 1 — связь

- Фильтры
- min support, длина, доменная польза

Apriori-пайплайн: искать → фильтровать → проверять




Сначала ищем frequent itemsets, затем строим правила и фильтруем по support / confidence / lift.

Без pruning число правил взрывается; последнее слово остаётся за предметной проверкой и экспериментом.

All Cups: baseline кластеризации

раздел

4



All Sips: кластеризация разреженных данных

- 14 590 объектов
- Строки sparse-матрицы

- 77 888 признаков
- CSR, density 0,178%

- L2-нормированы
- Cosine geometry через dot product

- Метрика ARI
- CSV: ID,TARGET

Baseline runbook: CSR $\rightarrow$ submission

train.npz

SVD(64) $\rightarrow$ L2

KMeans, k=20


Diagnostics

silhouette + seed ARI

submission.csv

Baseline — стартовая гипотеза, не ответ

- 1. 64 SVD-компоненты объясняют 4,8% variance
- 2. $k=20$: cosine silhouette = 0,077
- 3. Seed stability ARI = 0,393
- 4. Leaderboard ARI может не совпасть: hidden labels задают другой критерий



Итоги занятия

1

Сформулировали задачу без target

2

Сравнили K-means, hierarchy, spectral и density

3

Разобрали MDS через distances и stress

4

Посчитали support, confidence и lift

5

Собрали воспроизводимый All Cups submission

Рефлексия

- Как representation изменил кластеры?
- Почему silhouette $\neq$ leaderboard ARI?
- Что проверите после baseline?



ДЗ 5: контеcт по кластеризации



All Curs: присвоить TARGET каждому ID; метрика Adjusted Rand Index.
Минимум: запустить `baseline_clustering.ipynb` и сдать CSV строго ID,TARGET.
Объяснить: representation, k, internal metric и stability.
Проверить: `instructor/validate_submission.py`.

Домашнее задание Кластеризация: All Cups

