Неконтролируемое обучение

education

Есть признаки. Какие группы полезны?

Представление → близость → группы → проверка

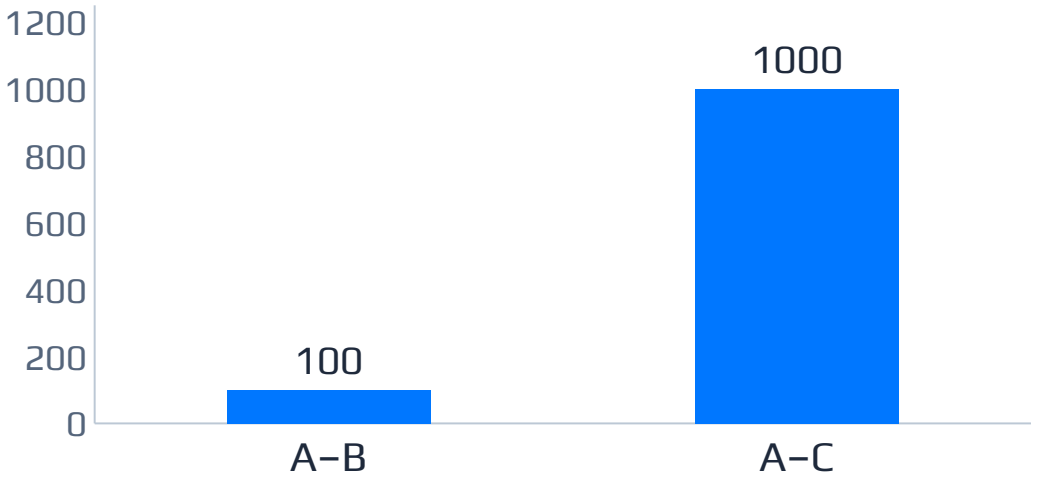
Группа становится полезной только вместе с понятной интерпретацией и проверкой.

Представление меняет близость

A: 10 часов, 1000 км

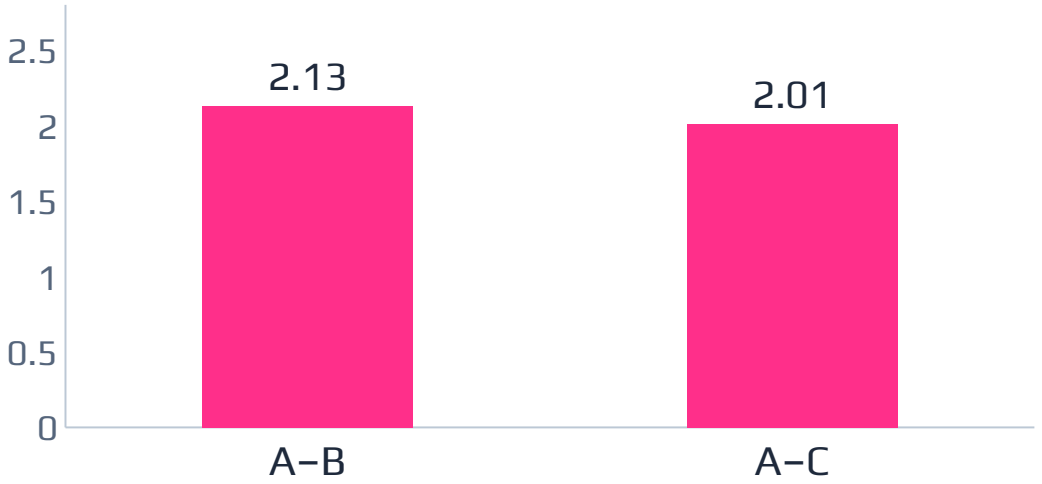
B: 11 часов, 900 км C: 10 часов, 2000 км

Исходные координаты



Ближе B

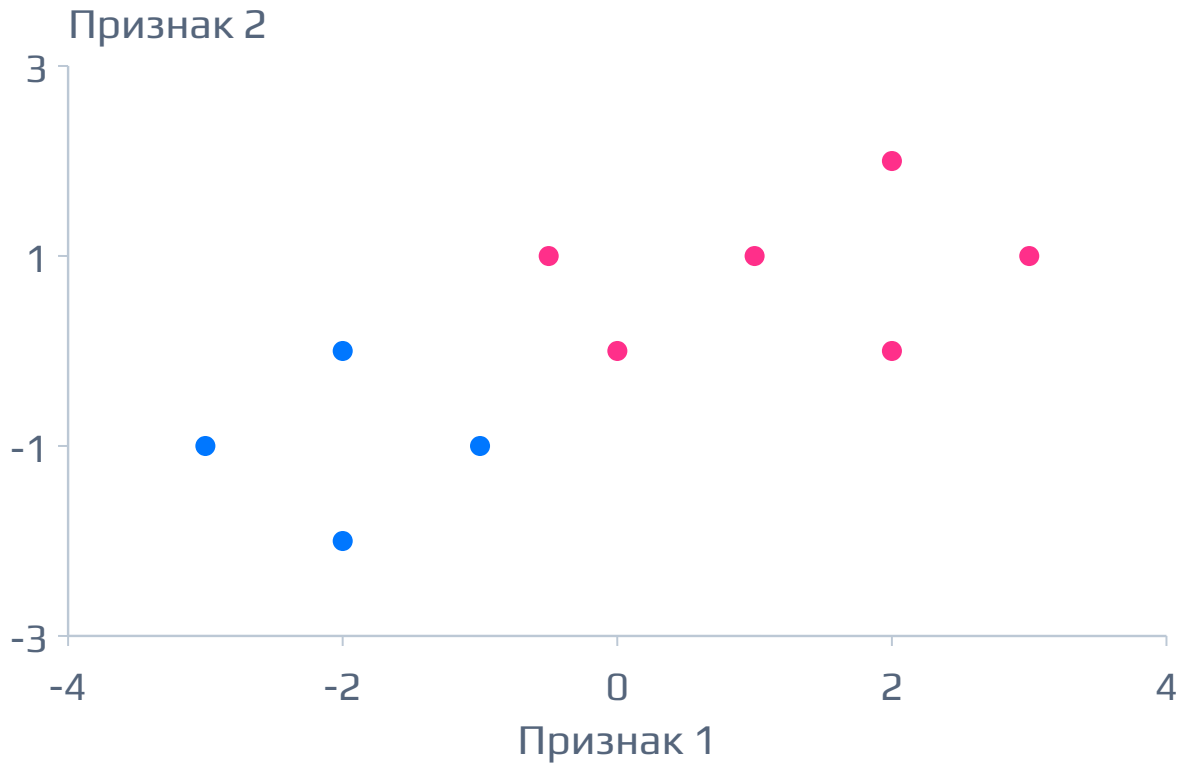
После StandardScaler



Ближе C

Близость задаём признаками, масштабом и расстоянием. Cosine сравнивает направления.

Что оптимизирует K-means



$$\min_{C_1,\ldots,C_k} \sum_{r=1}^{k} \sum_{i \in C_r} \|\mathbf{x}_i - \vec{\mu}_r\|_2^2$$

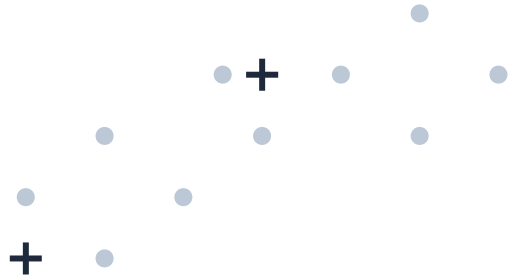
Компактные группы
Центр — среднее
k выбираем заранее

Минимум ошибки K-means — геометрический критерий, а не знание правильных классов.

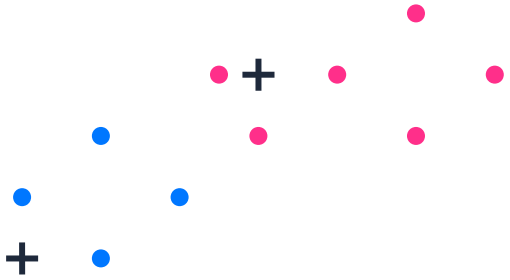
Одна итерация K-means

education

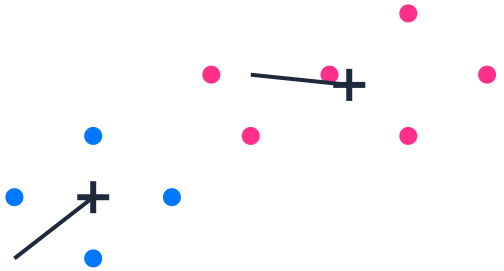
Начальные центры



Назначить ближайший



Пересчитать средние



$$\vec{\mu}_r = \frac{1}{|C_r|} \sum_{i \in C_r} \mathbf{x}_i$$

$$\frac{0 + 2 + 4}{3} = 2$$

Повторяем назначение и обновление до остановки. Кресты обозначают центры.

Иерархия: дерево объединений

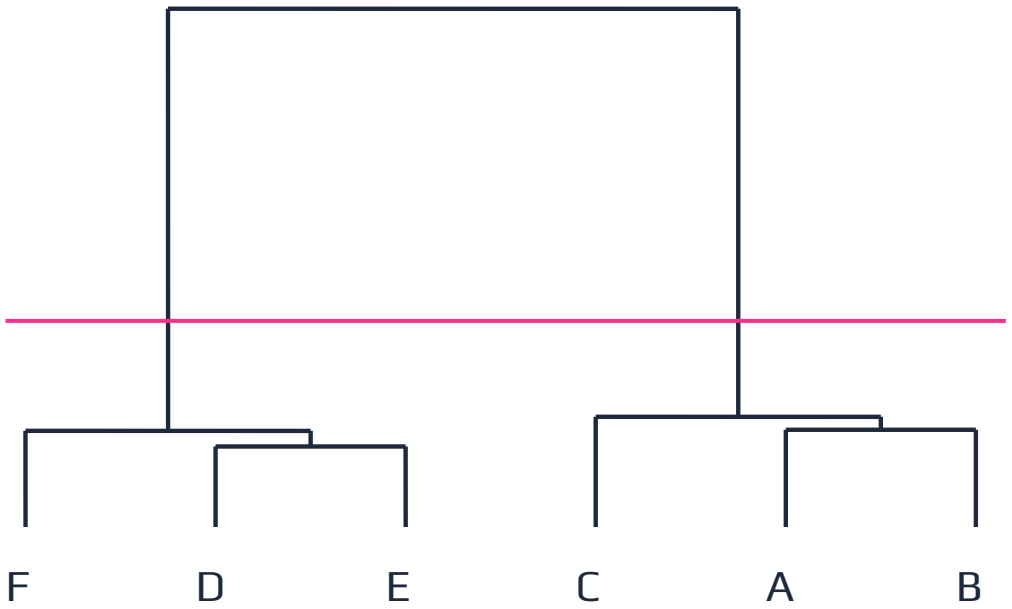
education

Одни и те же объекты



Срез дерева задаёт группы

Высота среза: 2

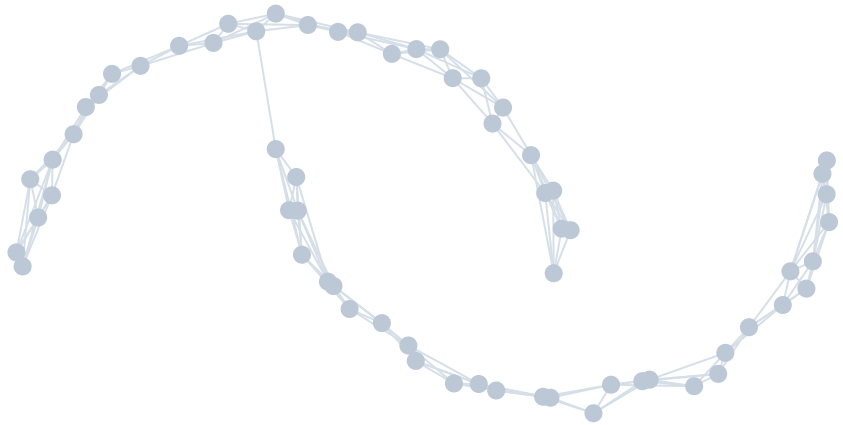


Дендрограмма показывает объединения. Выбранный срез превращает дерево в разбиение.

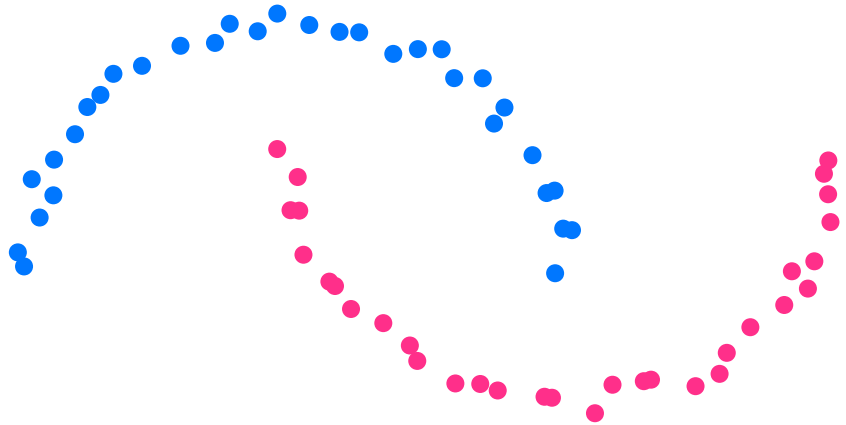
Спектральный метод: граф близости

education

Граф соседства



Группы по связям



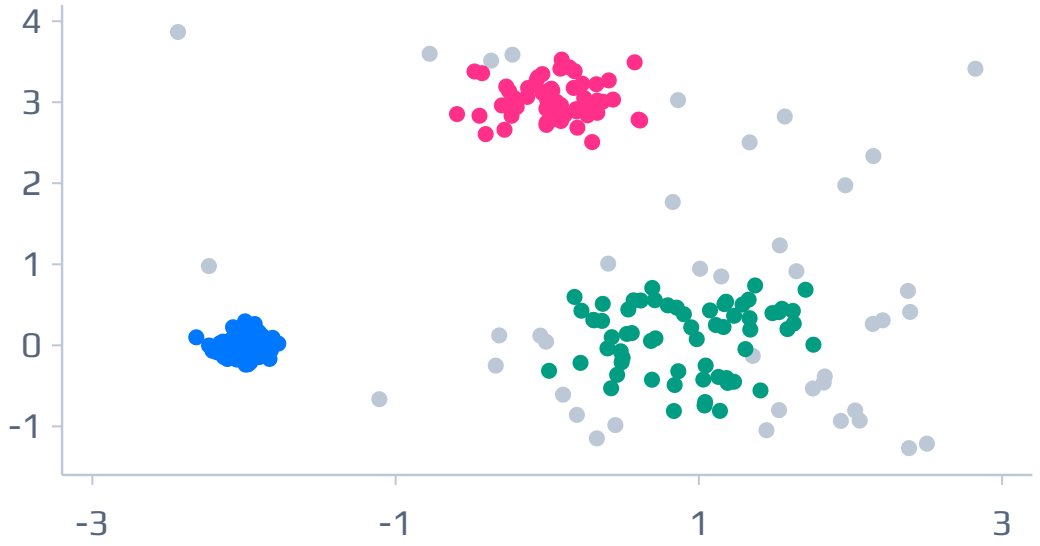
Линия означает выбранную связь соседства, а не причинность.

В основе метода — граф сходства; его устройство является частью модели.

Плотность: DBSCAN и HDBSCAN

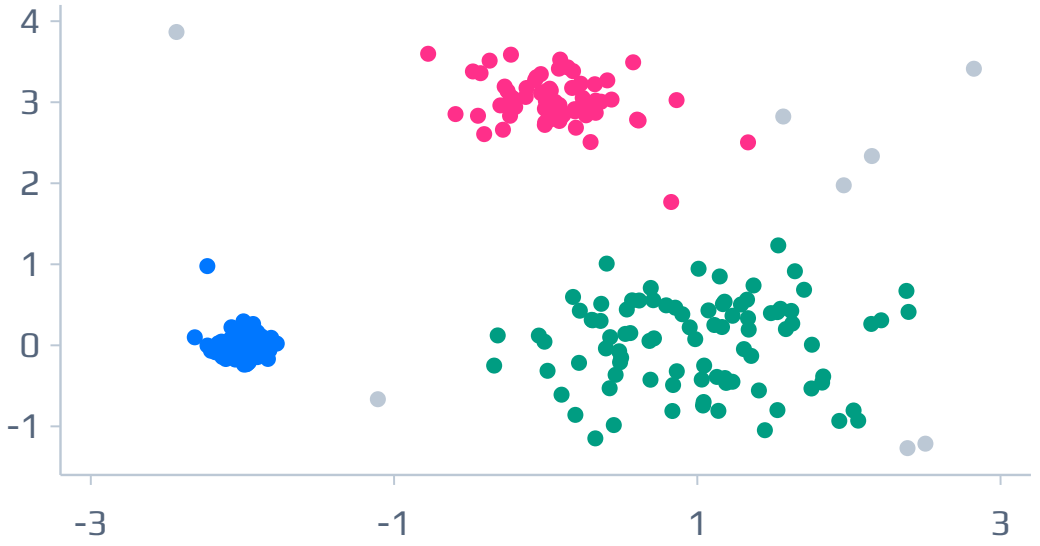
education

DBSCAN



3 группы · шум: 41

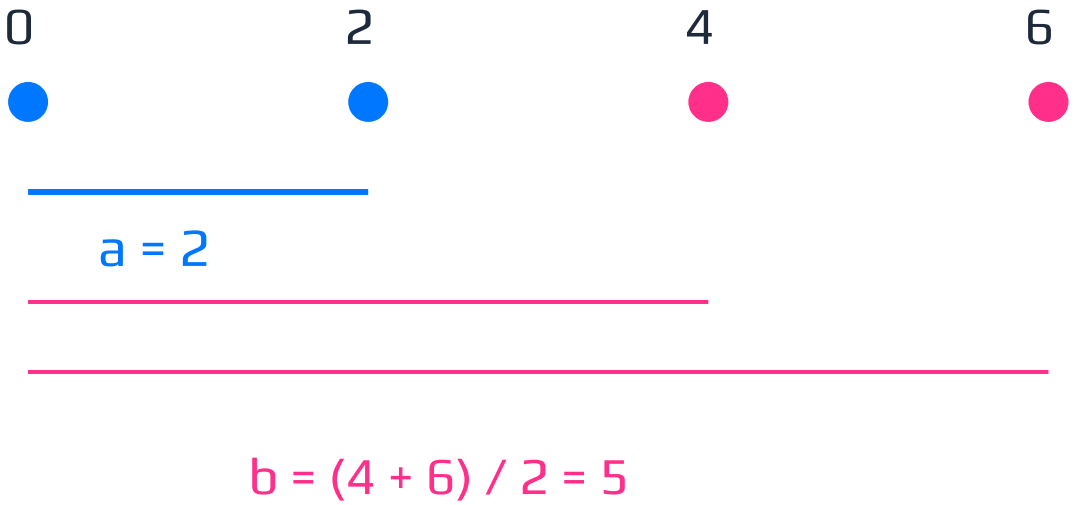
HDBSCAN



3 группы · шум: 8

Шум: объект не вошёл в плотную группу при выбранных параметрах.

Silhouette: своя и соседняя группа



$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

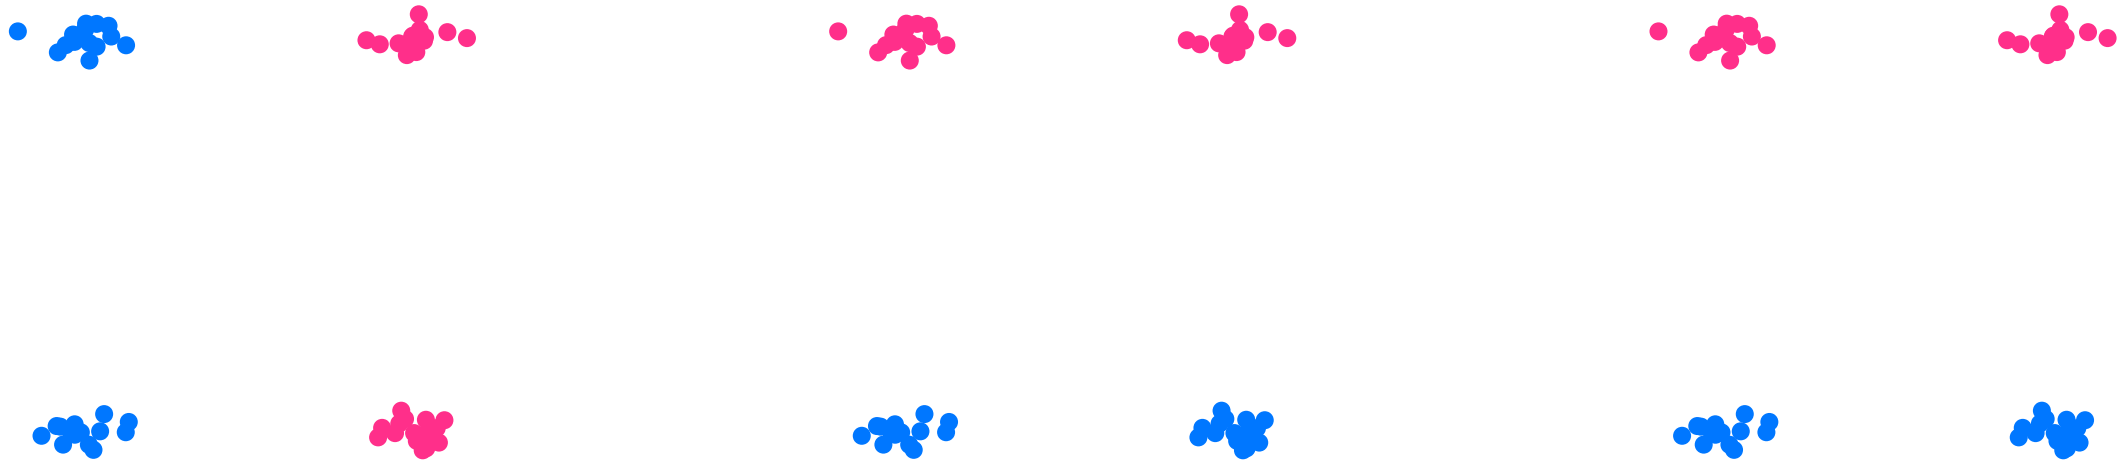
$$s = \frac{5 - 2}{\max(2, 5)} = 0{,}6$$

От −1 до 1: сравниваем средние расстояния внутри группы и до ближайшей другой.

Геометрия, эталон и устойчивость

education

Учебный эталон **Запуск 1** **Запуск 2**



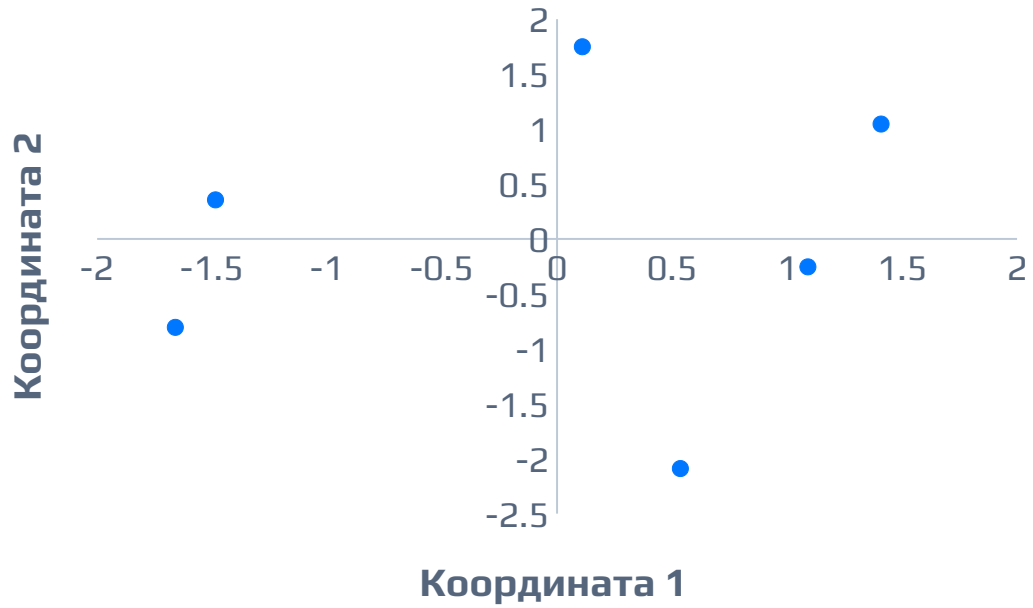
Silhouette: 0.81 ARI с эталоном: -0.02 ARI двух запусков: 1.00

Внешний ARI требует эталонных меток. Устойчивость и геометрия его не заменяют.

MDS сохраняет расстояния

education

Карта объектов



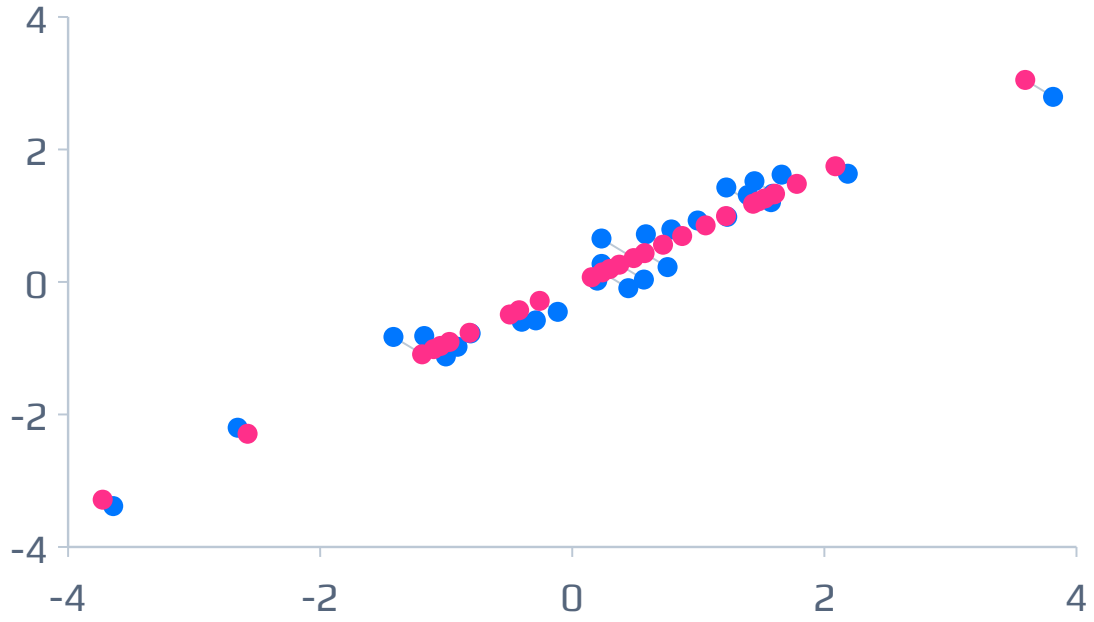
Расстояния: исходные и на карте



Stress учебной карты: 5.237

Координаты — средство; цель MDS — сохранить попарные расстояния.

PCA и SVD: компактные координаты



Синий — объект; розовый — проекция

PCA

Центрирование
Направление большой вариации

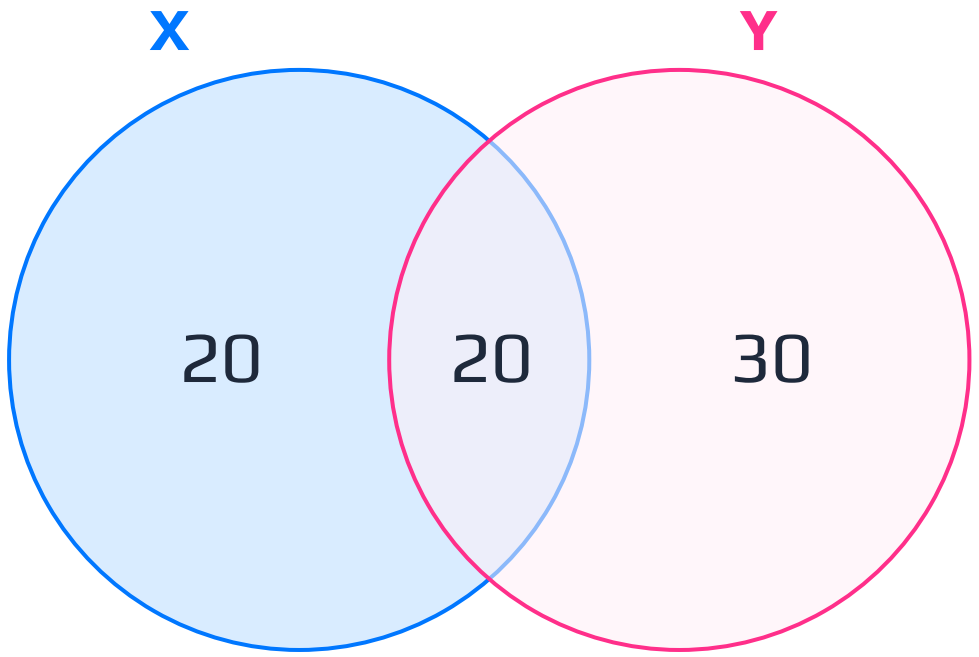
TruncatedSVD

Без центрирования
Работает с исходной CSR

Выбор представления учитывает смысл, геометрию и размер данных.

Support, confidence и lift

education



Ни X, ни Y: 30
Всего: 100 транзакций

$$\text{support}(X \Rightarrow Y) = \frac{|X \cap Y|}{N} = \frac{20}{100} = 0{,}2$$

$$\text{confidence}(X \Rightarrow Y) = \frac{|X \cap Y|}{|X|} = \frac{20}{40} = 0{,}5$$

$$\text{lift}(X \Rightarrow Y) = \frac{\text{confidence}}{P(Y)} = \frac{0{,}5}{0{,}5} = 1$$

Lift > 1 — ассоциация. Apriori отсекает надмножества нечастых наборов.

Sparse-данные: считаем память

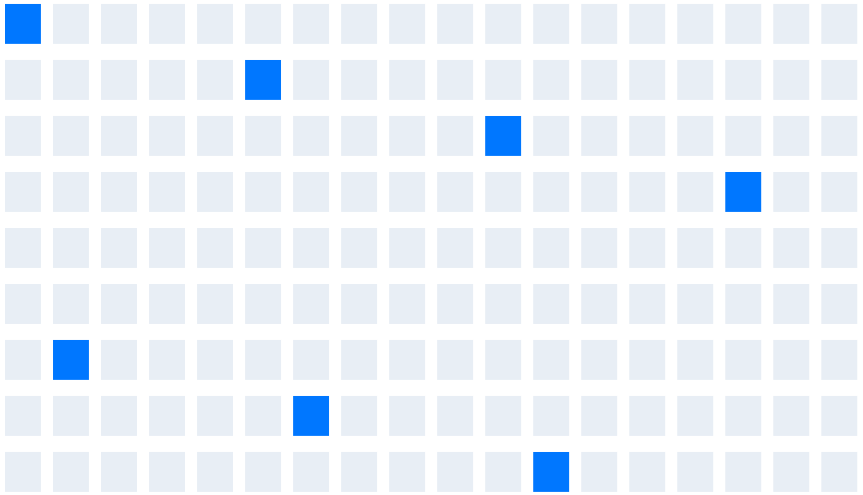


Схема разреженной матрицы

14 590 × 77 888

Ненулевых: около 0,18%
Dense float64: около 9,1 ГБ
После SVD: 14 590 × 64

Исходную CSR целиком не уплотняем. Компактное представление получаем через SVD.

Baseline: от CSR к CSV

education

CSR	SVD	L2-норма	MiniBatchKMeans	CSV
14 590 × 77 888	14 590 × 64	длина строки = 1	k = 20	ID,TARGET

Кластеры получают условные номера. Истинное число классов неизвестно.

Каждый шаг имеет понятный вход, выход и проверяемый размер.

Практика: получить и проверить ответ

education

Исходный baseline

64 компоненты → 4,78% вариации
Cosine silhouette → 0,0749
Размеры групп → 175…1206

Одно изменение

k: 20 → 15
Та же подвыборка
Сравнить и объяснить

25 минут: рабочий CSV 10 минут: эксперимент и обсуждение

Внутренние метрики — диагностика. Скрытый ARI вычисляет только All Cups.

Справочно: расстояния и silhouette

education

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_j (x_j - y_j)^2}$$

$$d_{\cos} = 1 - \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2}$$

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

Метрику близости выбираем до содержательной интерпретации групп.

Справочно: что сохраняет проекция

education

$$\text{Stress} = \sum_{i<j} \left(d_{ij} - \|\mathbf{z}_i - \mathbf{z}_j\|_2\right)^2$$

MDS: попарные расстояния
PCA: вариация центрированных данных
TruncatedSVD: аппроксимация без центрирования

Двумерная картинка помогает обсуждению, но не заменяет проверку результата.

Справочно: семейства кластеризации

education

K-means	Центры и компактность	k
Иерархический	Дерево объединений	linkage и срез
Спектральный	Граф сходства	Граф и число групп
DBSCAN / HDBSCAN	Плотность и шум	Параметры плотности

Алгоритм выражает предположение о структуре данных.

Справочно: чтение ассоциативных правил

education

$$\text{support}(X \Rightarrow Y) = \frac{|X \cap Y|}{N} = \frac{20}{100} = 0{,}2$$

$$\text{confidence}(X \Rightarrow Y) = \frac{|X \cap Y|}{|X|} = \frac{20}{40} = 0{,}5$$

$$\text{lift}(X \Rightarrow Y) = \frac{\text{confidence}}{P(Y)} = \frac{0{,}5}{0{,}5} = 1$$

Частые наборы → правила → предметная проверка.