education

Неконтролируемое машинное обучение

Проверка без открытого target

education

У нас есть признаки объектов, но нет открытых правильных классов.

Как проверить, что найденные группы полезны?

Постановка задачи кластеризации

education

Решение	Пример
Объект	Профиль пользователя или изделие
Представление	Числовые признаки объекта
Близость	Евклидово или cosine расстояние
Польза	Устойчивая и интерпретируемая группа

Масштаб меняет близость

education

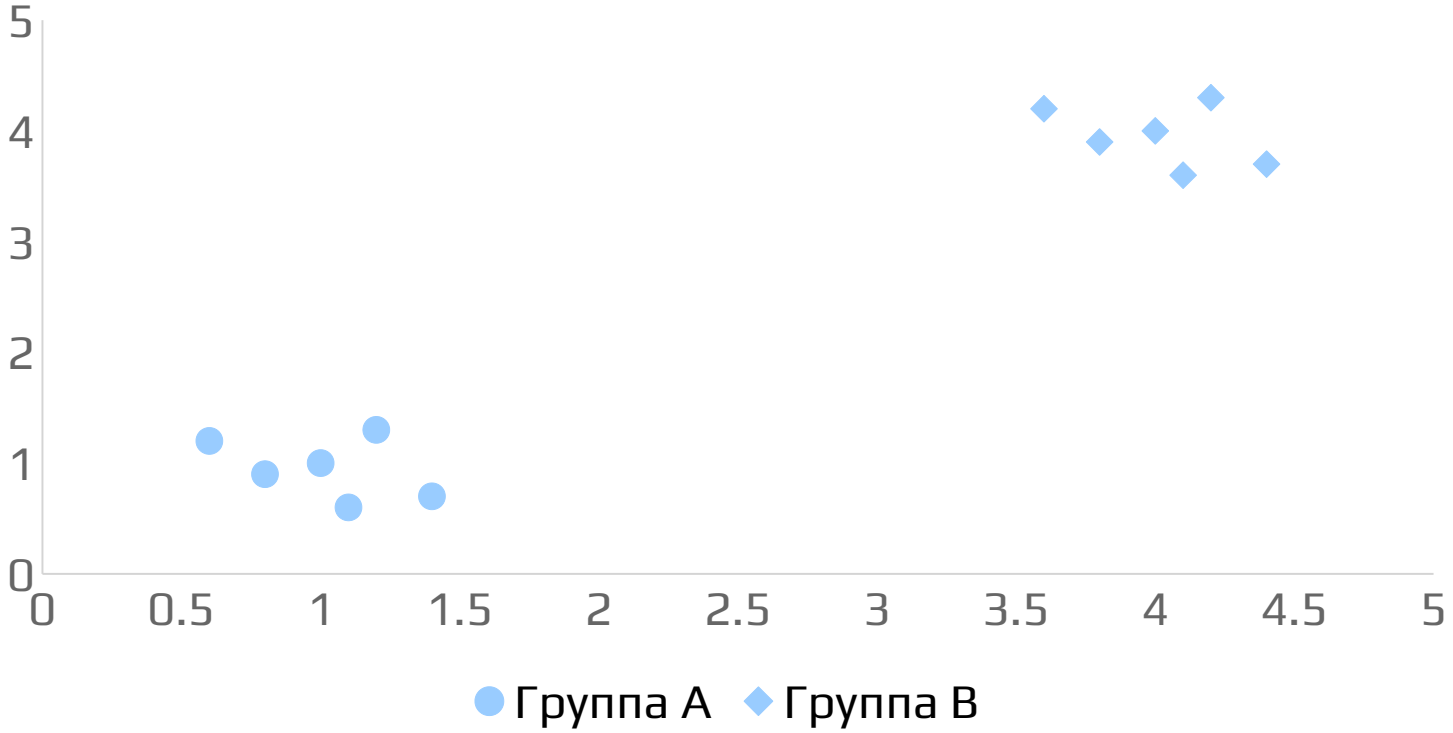
Объект	Время часы	Пробег км
A	10	1000
B	11	1100
C	10	2000

Разность 1000 км может подавить разность 1 часа.

Масштабирование меняет расстояния.

Евклидово расстояние сравнивает координаты. Cosine сравнивает направления.

K-means и компактные кластеры



Учебные точки

Минимизируем сумму квадратов расстояний до центров.

k выбираем заранее.

Два шага K-means

education

Шаг	Действие
Назначение	Каждый объект получает ближайший центр
Обновление	Центр становится средним своих объектов
Повторение	Итерации продолжаются до остановки

Пример: точки 0, 2, 4 дают новый центр (0 + 2 + 4) / 3 = 2.

Дерево и граф сходства

education

Метод	Структура	Выбор групп
Иерархический	Дерево объединений	Срез дендрограммы
Спектральный	Граф близости объектов	Разделение графа

Агломеративный шаг объединяет ближайшие группы по выбранному linkage.

Полные попарные расстояния ограничивают масштаб.

DBSCAN и HDBSCAN

education

Метод	Принцип	Шум
DBSCAN	Радиус ε и минимальная плотность	Допускается
HDBSCAN	Иерархия плотностей	Допускается

Шум означает, что объект не вошёл в плотную группу при выбранных параметрах.

Silhouette

education

a — среднее расстояние до объектов своего кластера
b — наименьшее среднее расстояние до другого кластера

$$s = (b - a) / \max(a, b)$$

При a = 2 и b = 5: s = 0,6. Диапазон от −1 до 1.

Как проверять кластеры

education

Проверка	Что сравниваем	Пример
Внутренняя	Объекты и кластеры	Silhouette
Внешняя	Решение и эталон	ARI по hidden labels
Устойчивость	Два запуска алгоритма	ARI между seed

ARI между seed проверяет согласованность запусков. Hidden ARI требует эталона.

Многомерное шкалирование

education

Пара объектов	Исходное расстояние	На новой карте
A и B	2	2,1
A и C	5	4,8
B и C	3	3,1

Учебный пример. Stress измеряет расхождение расстояний.

MDS, PCA и SVD

education

Метод	Основная идея
Метрический MDS	Приблизить попарные расстояния
PCA	Сохранить вариацию центрированных данных
TruncatedSVD	Снизить размерность без центрирования

Для большой CSR-матрицы используем TruncatedSVD.

Support, confidence, lift

education

100 транзакций: X в 40, Y в 50, вместе в 20

Метрика	Расчёт	Значение
Support	20 / 100	0,2
Confidence	20 / 40	0,5
Lift	0,5 / 0,5	1

Lift выше 1 показывает ассоциацию. Причинность требует отдельной проверки.

Поиск ассоциативных правил

education

Этап	Результат
Частые наборы	Наборы items с достаточным support
Правила X ⇒ Y	Confidence и lift для кандидатов
Проверка	Предметная польза и проверяемая гипотеза

Apriori сокращает поиск через свойство частых наборов.

Разреженные данные All Cups

education

Представление	Размер
Исходная CSR-матрица	14 590 × 77 888
Ненулевые значения	Около 0,18%
После SVD	14 590 × 64
Плотная исходная копия float64	Около 9,1 ГБ

TruncatedSVD обрабатывает CSR. Исходную матрицу целиком не уплотняем.

Baseline кластеризации

education

Шаг	Выход
TruncatedSVD 64	Компактные координаты
L2 нормализация	Единичная длина строк
MiniBatchKMeans k = 20	Метка каждой строки
CSV	Столбцы ID,TARGET

k = 20 — стартовая гипотеза. Истинное число групп неизвестно.

Диагностика baseline

education

Наблюдение	Локальный результат
64 компоненты SVD	4,78% объяснённой вариации
Cosine silhouette на 1200 строках	0,0749
Размеры 20 кластеров	От 175 до 1206 объектов

Скрытый ARI вычисляет All Cups. Эти результаты его не заменяют.

Интерпретация результата

education

Что означает близость после выбора признаков и нормализации?

Как отличить геометрическую оценку от совпадения с эталоном?

Какое одно изменение проверим следующим?

Практика кластеризации

education

Аудит CSR, SVD, кластеризация, диагностика и CSV

Самостоятельно: изменить k с 20 на 15 и сравнить те же диагностики.