




Временные ряды в машинном обучении




- 01 Компоненты временного ряда
- 02 Признаки и преобразования
- 03 Методы прогнозирования
- 04 Оценка точности прогноза



01

Компоненты ряда

Как описать тренд и сезонность
временного ряда?



Задача прогнозирования



Прогнозируем спрос на следующие h дней по прошлым наблюдениям.

История наблюдений

$y_1, y_2, \dots, y_t$


Прогнозируемые значения

$\hat{y}_{t+1}, \dots, \hat{y}_{t+h}$

Горизонт h — число шагов вперёд; здесь один шаг равен одному дню.

Компоненты временного ряда

$$y_t = T_t + S_t + R_t$$




Компоненты

T_t — тренд
 S_t — сезонная
компонента
 R_t — остаточная
компонента

Компоненты помогают выбрать признаки и метод прогнозирования.


Тренд

Тренд — долгосрочная тенденция роста или снижения значений временного ряда.



Сезонность


Сезонность — повторяющиеся колебания с постоянным периодом.



Годовая сезонность в месячных данных: период — 12 месяцев.

Аддитивная и мультипликативная декомпозиция


Аддитивная: амплитуда постоянна



$$y_t = T_t + S_t + R_t$$

Размах сезонных колебаний
примерно постоянен.

Мультипликативная: амплитуда растет с трендом



$$y_t = T_t \times S_t \times R_t$$


Размах сезонных колебаний
пропорционален уровню ряда.

Остаточная компонента

Аддитивная декомпозиция: $R_t = y_t - T_t - S_t$

Проверка декомпозиции


Если в остатках
сохранились тренд
или сезонность,
декомпозицию стоит
пересмотреть.



02

Признаки и преобразования

Как использовать прошлые наблюдения
при построении модели?



Лаговые признаки

Лаговый признак y_{t-k} — значение ряда за k шагов до момента t .

Прогноз на	Вчера	2 дня назад	Неделю назад	Спрос
День 8	100	98	90	103
День 9	103	100	95	102
День 10	102	103	100	?

**На исторических данных известны признаки и целевые значения.
Для нового прогноза целевое значение неизвестно.**

Скользящее среднее как признак

$$m_t = (y_{t-1} + \dots + y_{t-w}) / w$$

10 12 14

Три предыдущих наблюдения

Среднее = 12

**Сдвиг на один шаг
перед усреднением**


`y.shift(1).rolling(3).mean()`

Сдвиг исключает прогнозируемое
значение y_t .

Скользящее и расширяющееся окно


Для прогноза y_t используем только наблюдения, полученные до t .

Скользящее окно



Используются последние 3 наблюдения.


Расширяющееся окно



Используются все прошлые наблюдения.

Разности первого порядка

Разности могут устранить тренд в среднем значении ряда.
Пользу разностей проверяют по точности прогноза исходных значений.



$$\Delta y_t = y_t - y_{t-1}$$

Модель прогнозирует приращение, а затем мы восстанавливаем значение ряда.


Обратное преобразование: $\hat{y}_{t+1} = y_t + \Delta \hat{y}_{t+1}$



03

Методы прогнозирования


Какие модели использовать
для прогнозирования ряда?



Наивные методы прогнозирования

Наивный метод: прогноз равен последнему наблюдению.

Сезонный наивный метод: значение в той же точке предыдущего сезона.




$$\hat{y}_t = y_{t-1}$$

$$\hat{y}_t = y_{t-s}$$

Базовые методы
для сравнения
моделей.

Сравнение со сложной моделью

Я неделю обучал
сложную модель



Прогноз «как вчера»



Линейная регрессия для прогноза ряда

Прогнозируем спрос на следующий день по значениям за предыдущие дни.

$$\hat{y}_t = b + w_1 y_{t-1} + w_2 y_{t-2} + w_7 y_{t-7}$$

Признаки модели


Для прогноза на день t :
спрос за 1, 2 и 7 дней
до прогнозируемого дня.

Обучение модели

Коэффициенты b , w_1 , w_2 , w_7
оценивают при обучении
модели на train.

Дерево решений для прогнозирования

Дерево решений прогнозирует спрос на завтра.
В этом примере единственный признак — спрос сегодня.



Учебный пример. Порог и значения в листьях определяют при обучении.

Признаки для прогнозирования бустингом

Прогноз спроса на день t по признакам x_t : $\hat{y}_t = F(x_t)$.

Прошлые значения

Спрос за 1, 2 и 7 дней до дня t :
 $y_{t-1}, y_{t-2}, y_{t-7}$.

Среднее по окну

Средний спрос за 7 дней,
предшествующих дню t .

Календарные признаки

День недели и признак праздника
для прогнозируемого дня t .

Такие же признаки можно использовать в линейной регрессии.

Градиентный бустинг для прогноза спроса



Деревья используют лаги, средние по окнам и календарные признаки. Каждое новое дерево корректирует прогноз уже построенного ансамбля.

Прогноз = начальная оценка + сумма поправок

Взаимодействие признаков

Связь между спросом сегодня и завтра может различаться для будних и выходных дней.

Обучение при квадратичной ошибке

Новое дерево предсказывает разность между фактическими значениями и текущим прогнозом.

Простое экспоненциальное сглаживание



Для ряда без тренда и сезонности прогнозируем текущий уровень.
Параметр α ($0 < \alpha < 1$) задаёт вес нового наблюдения.

$$\text{Новая оценка} = \alpha \times \text{наблюдение} + (1 - \alpha) \times \text{старая оценка}$$

Учебный пример

Старая оценка — 100 заказов.
Новое наблюдение — 120.
При $\alpha = 0,2$ прогноз на завтра:

$$\begin{aligned} &0,2 \times 120 + 0,8 \times 100 \\ &= 104 \text{ заказа} \end{aligned}$$

Сглаживание с трендом и сезонностью



Метод Хольта

Экспоненциальное сглаживание с оценкой уровня и скорости роста.
Прогноз на h шагов: $\text{уровень} + h \times \text{прирост за один шаг}$.

Метод Хольта — Уинтерса

Дополнительно оценивает повторяющийся сезонный эффект.
В аддитивном варианте прибавляет его к прогнозу с трендом.

После каждого наблюдения оценки компонентов обновляются.

Одношаговый и многошаговый прогноз



Прогноз на следующий день

В понедельник строим прогноз спроса на вторник.

Во вторник получаем новое наблюдение и строим прогноз на среду.

Прогноз на всю неделю

В понедельник строим прогноз сразу на следующие семь дней.

Фактический спрос за эти дни пока неизвестен. Все семь значений прогнозируем по доступной истории.

Многошаговый прогноз

В момент t строим прогноз на h шагов вперёд.

Рекурсивный метод

Одну и ту же модель
применяют последовательно.

Предыдущие прогнозы заменяют
неизвестные наблюдения.
Ошибки могут накапливаться.

Прямой метод

Отдельная модель
для каждого шага вперёд.

Все модели используют данные,
доступные в момент t .

Многошаговый прогноз линейной модели

Учебный пример: $\hat{y}_{t+1} = 10 + 0,8y_t$. Последнее наблюдение — 70.


Горизонт	Расчёт прогноза	Результат
1	$10 + 0,8 \times 70$	66
2	$10 + 0,8 \times 66$	62,8
3	$10 + 0,8 \times 62,8$	60,24

Первый прогноз рассчитан по наблюдению 70.
Для следующих шагов вместо наблюдений подставляем прогнозы.

04

Оценка точности прогноза

Как оценить точность прогноза
на новых наблюдениях?



Когда в признаки попало будущее

**Метрики на validation
с data leakage**



**Метрики на test
без data leakage**



При случайном split в train могут попасть наблюдения, полученные позже наблюдений из validation.

День 1 День 2 День 3 День 4 День 5 День 6 День 7 День 8

The diagram shows a sequence of 8 days. Days 1, 3, 4, 6, and 8 are blue, representing training days. Days 2, 5, and 7 are pink, representing validation days.

■ train ■ validation

Для прогноза дня 2 недоступны наблюдения за дни 3–8. Случайное разбиение этого ограничения не учитывает.

Train / validation / test

Данные делим по времени: train → validation → test.



train

Обучаем модель.

validation


Выбираем модель
и гиперпараметры.

test

Оцениваем качество
выбранной модели.

Кросс-валидация временных рядов

В каждом фолде validation расположен позже train.



В каждом фолде модель обучаем заново на train.

Параметры предобработки также оцениваем только на train.

Data leakage: использование будущих данных



Вечером понедельника прогнозируем спрос на вторник.

Корректный признак

Средний спрос за субботу, воскресенье и понедельник.

Все три значения уже известны.

В исторических данных будущие значения есть, но использовать их нельзя.

Признак с утечкой

Средний спрос за понедельник, вторник и среду.

Вторник и среда ещё не наступили.
Их фактический спрос неизвестен.

Сравнение точности прогнозов



MAE

Средняя абсолютная ошибка
в единицах прогнозируемой величины.

RMSE

Сильнее реагирует на большие ошибки,
чем MAE.

MAPE

Средняя абсолютная процентная ошибка.
Не определена при нулях; малые фактические
значения могут давать большие проценты.

Выбор модели — по метрикам на *validation*.

Итоговая оценка — на *test* при одинаковом горизонте прогноза.

Вопросы для самопроверки

- 01 Всегда ли использование фактических значений из test в лагах означает утечку?
- 02 Почему дереву решений сложно экстраполировать тренд?
- 03 Почему прогнозировать изменение ряда может быть проще, чем его значение?
- 04 Может ли модель быть лучше по MAE, но хуже по RMSE?

Для самостоятельного изучения



ARIMA и SARIMA

ARIMA объединяет авторегрессию, разности и зависимость от прошлых ошибок прогноза. SARIMA дополнительно учитывает сезонность.

Рекомендуемое чтение

Forecasting: Principles and Practice, глава 9.
Начать с разделов о стационарности, разностях и авторегрессии.

На семинаре

Построим лаговые признаки.

Сравним линейную регрессию
с наивным прогнозом.

Рассчитаем метрики
на отложенном test.

